

西安交通大学学报
Journal of Xi'an Jiaotong University
ISSN 0253-987X, CN 61-1069/T

《西安交通大学学报》网络首发论文

题目：一种高效运动想象脑电信号浅层卷积解码网络
作者：李文平，徐光华，张凯，张四聪，赵丽娇，李辉
收稿日期：2023-03-06
网络首发日期：2023-07-11
引用格式：李文平，徐光华，张凯，张四聪，赵丽娇，李辉. 一种高效运动想象脑电信号浅层卷积解码网络[J/OL]. 西安交通大学学报.
<https://kns.cnki.net/kcms2/detail/61.1069.t.20230710.1820.002.html>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

一种高效运动想象脑电信号浅层卷积解码网络

李文平¹, 徐光华^{1,2}, 张凯¹, 张四聪¹, 赵丽娇³, 李辉¹

(1. 西安交通大学机械工程学院, 710049, 西安; 2. 西安交通大学机械制造系统工程国家重点实验室, 710054, 西安;
3. 西安交通大学经济与金融学院, 710061, 西安)

摘要: 针对现有的运动想象脑机接口 (MI-BCIs) 中, 基于深度学习的脑电信号 (EEG) 解码网络 (EEGNet) 时域-空域-频域耦合特征学习能力差、模型训练与推理时间长的问题, 提出了一种高效运动想象脑电信号浅层卷积解码网络 (Faster-EEGNet)。该网络将第一层二维平面串行卷积优化为所有通道同时进行的串行卷积, 第一层完成了各通道信号的时域滤波与空间滤波; 中间深度卷积层对空间模式提取信号进行时域卷积特征提取, 然后由深度分离卷积再次提取信号时间-空间耦合特征进行模式识别。采用公开数据集进行实验验证, 结果表明: Faster-EEGNet 网络的运动想象识别准确率与信息传输率相较于 EEGNet 网络有更好的表现, 在本实验的小样本训练场景下也能够取得较好的识别效果; 此外, Faster-EEGNet 网络比 EEGNet 网络的训练时间减少了 44.8%, 模型推理时间减少 43.6% 以上。实验结果证明了所提 Faster-EEGNet 网络能够提升运动想象脑机接口系统的识别准确性、便捷性与快速响应性能。

关键词: 脑电信号; 脑机接口; 运动想象; 深度学习; 脑电解码算法

中图分类号: Q983.5; TP242 **文献标志码:** A **文章编号:** 0253-987X(2023)10-0000-00

An Efficient Shallow Convolution Decoding Network for Motor Imagery Electroencephalography Signals

LI Wenping¹, XU Guanghua^{1,2}, ZHANG Kai¹, ZHANG Sicong¹, ZHAO Lijiao³, LI Hui¹

(1. School of Mechanical Engineering, Xi'an Jiaotong University, Xi'an 710049, China;
2. State Key Laboratory of Mechanical Manufacturing System Engineering, Xi'an Jiaotong University, Xi'an 710054, China;
3. School of Economics and Finance, Xi'an Jiaotong University, Xi'an 710061, China)

Abstract: To address the issues of poor temporal-spatial-frequency coupling feature learning and long training and inference times in existing motor imagery-based brain-computer interfaces (MI-BCIs) using deep learning-based electroencephalography (EEG) signal decoding networks (EEGNet), a more efficient shallow convolutional decoding network called Faster-EEGNet is proposed. In this network, the first layer of two-dimensional serial convolution is optimized to perform parallel convolution on all channels simultaneously. The first layer accomplishes temporal filtering and spatial filtering of signals from each channel. The intermediate deep convolutional layers extract temporal convolutional features from spatial pattern-extracted signals. Then, the depthwise separable convolution is used to extract the temporal-spatial coupling features of the signals for pattern recognition. Experimental validation is conducted using publicly available datasets. The results demonstrate that the Faster-EEGNet network exhibits better performance in motor imagery recognition accuracy and information transfer rate compared to the EEGNet network. It also achieves good recognition results in small-sample training scenarios. Furthermore, the Faster-EEGNet network reduces training time by 44.8% and model inference time at least 43.6%, respectively compared to the EEGNet network. The experimental results demonstrate that the proposed Faster-EEGNet network can enhance the recognition accuracy, convenience, and rapid response performance of the motor imagery brain-computer interface system.

Key words: EEG signals, brain-computer interfaces, motor imagery, deep learning, EEG decoding algorithm

脑-机接口 (Brain-Computer interface, BCI) 是一种允许使用者使用大脑神经信号来控制如假肢、外骨骼、轮椅等外部设备的系统^[1-3]。基于运动想象 (Motor imagery, MI) 范式的脑-机接口系统, 其典

型过程是采集大脑在动作想象时的电信号, 经过数据预处理与特征提取, 再对想象任务进行识别与分类, 最后形成相对应的控制指令^[4]。目前用于运动想象脑-机接口系统的脑电信号有植入脑电、皮层脑电

收稿日期: 2023-03-06。作者简介: 李文平 (1999—), 男, 硕士生; 徐光华 (通信作者), 男, 教授, 博士生导师。基金项目: 国家重点研发计划资助项目 (2021ZD0204300); 陕西省重点研发计划资助项目 (2021GXLH-Z-008); 广州市科技计划资助项目 (202206060003)。

和头皮脑电^[5]。头皮脑电使用电极帽或者电极平贴于头皮上记录得到,是一种非侵入式的信号。与其他脑电信号相比具有非侵入式、易用、低成本、便携的优点,但同时也牺牲了信噪比与空间分辨率^[6,7]。因此,基于运动想象的脑-机接口系统的性能主要取决于信号解码算法的性能,提高解码算法的信息传输率对于提升脑-机接口系统的性能有关键性作用。

共空间模式(Common Spatial Pattern, CSP)特征提取方法,结合支持向量机(SVM)等机器学习分类算法,对于二任务的运动想象脑电解码取得了较好的效果^[8-10]。之后许多的学者对于初始的 CSP 方法进行了诸多改进研究, Kai Keng^[11]针对 CSP 方法中频带选择问题,提出了滤波器组共空间模式算法(FBCSP),算法使用等频宽的滤波器组对信号进行分解,在每个频段信号提取 CSP 特征,再使用互信息的特征选择方法进行特征选择。鉴别滤波器组 CSP(DFBCSP)^[12]、共时空频 CSP 算法^[13](Common Time Frequency Spatial Pattern, CTFSP)、双谱熵^[14](BECSP)等优化算法相继被提出,以期能提取更加显著的运动想象脑电信号特征。但是上述的运动想象解码算法需要手动对信号进行特征提取,因此解码的性能十分依赖于较专业的相关知识与经验。

基于人工神经网络(ANN)的深度学习的方法很大程度上缓解了人工参与特征提取的需求,具体而言,在计算机视觉(CV)^[15]与语音识别(Audio Recognition)^[16]领域实现了远超前于人工提取特征的识别效果,获得了最先进的性能。近几年来,许多研究已经关注到使用深度学习算法在脑电信号处理上的应用^[17]。Schirmer^[18]提出一种适用于脑电信号分类的深度卷积网络(DeepConvNet)。Lawhern^[19]提出了可以跨范式、跨被试且效果较好的 EEGNet,模型具有很强的泛化能力。刘晓林^[20]提出时间和通道注意卷积网络(TCACNet),实现对脑电信号的分类。上述基于深度学习的算法通过自适应训练的深度网络实现对原始脑电信号的模式识别,在大量数据的支持下能够取得很好的识别效果。

但是深度学习在脑电信号识别领域仍存在以下的问题。首先是运动想象作为一种内源性的脑-机接口范式,神经电信号来源于特定区域、特定时间以及个体差异性的节律,特征表征呈现出较强的时间-空间-频率耦合特性^[13, 21, 22],加之头皮脑电对神经信号质量的折损,如何自适应提取到这些强耦合的特征是需要研究的点^[23];其次深度网络的训练参数随网络深度与广度的增加而增加,随之带来的是更多的训练数据样本需求^[24],为算法的实际应用造成阻碍;最后,在脑-机接口的实际应用场景之中,要想普及更多的设备使用场景,就要追求比较高的信号解码准确率,还需要更快的神经网络训练速度与更低的计算资源占用^[25]。

针对上述问题,本文在 EEGNet 的基础之上,提出了一种改进的 Faster-EEGNet,通过新的神经网络

结构增强神经网络对运动想象时间-空间-频率耦合特征的提取能力,同时网络可训练参数只有 10^4 量级,对训练样本数量要求比较低,还通过结构的优化使得网络卷积运算速度明显提升,实验中训练用时减少 44.8%。

1 基于深度学习的运动想象解码算法

1.1 EEGNet 结构

EEGNet 是 Lawhern^[19]由 FBCSP 算法启发构建的一个紧凑式的,可以用于运动想象脑电信号识别的可训练神经网络,其网络结构如图 1 所示。

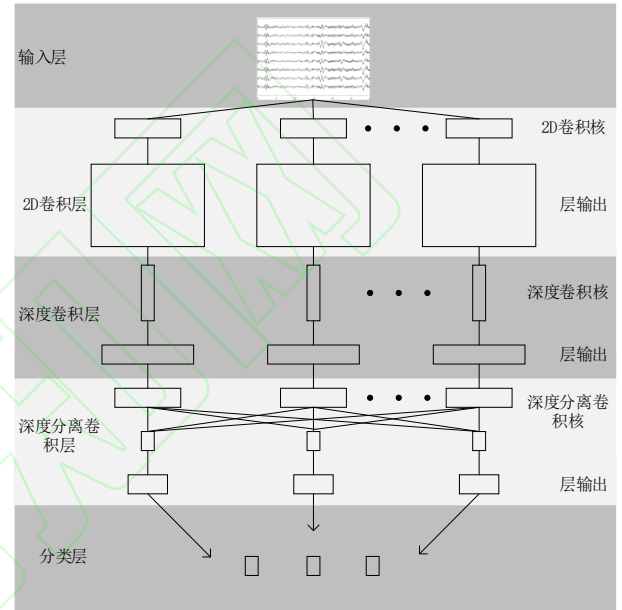


图 1 EEGNet 网络结构

Fig.1 Structure of EEGNet network

网络的输入是通道数 \times 采样数的脑电信号,紧接的第一层是二维卷积层,使用的卷积核长度为 0.5s 脑电数据相等长度,宽度为 1。该卷积层的卷积操作是对脑电信号逐行卷积运算,操作类似于对脑电信号进行逐通道滤波,再经过激励函数实现特征图的输出,过程数学表达如下

$$\mathbf{y}_j = f((\mathbf{X} * \mathbf{w}_j) + \mathbf{b}_j) \quad (1)$$

式中: \mathbf{y}_j 表示第 j 个特征图; \mathbf{X} 表示该层的输入信号; \mathbf{w}_j 表示第 j 个卷积核的权重矩阵; \mathbf{b}_j 表示第 j 个卷积的偏差值; f 表示激活函数。

第 2 层是深度卷积层,卷积核形状为通道数 $\times 1$,与第 1 层的卷积的区别在于,在深度为 1 时,进行卷积操作时一个特征图输入对应一个卷积核^[26],而普通卷积层的每个卷积核会与每个输入的特征图进行卷积操作,计算公式为

$$\mathbf{y}_{j,h} = f\left(\sum_j (\mathbf{X}_j * \mathbf{w}_{j,h}) + \mathbf{b}_{j,h}\right) \quad (2)$$

式中: h 表示深度卷积的深度; $\mathbf{y}_{j,h}$ 表示第 j 个卷积核

对应的深度为 h 的输出; \mathbf{X}_j 表示第 j 个输入的特征图, $\mathbf{w}_{j,h}$ 表示第 j 个深度为 h 的卷积核; f 表示激活函数。

深度卷积的意义就在于对输入的每个特征图单独操作, 实现了特征图的独立特征提取^[26]。同时相比于普通卷积, 深度卷积的运算量、可训练参数量也会大大减少。深度卷积层的卷积计算类似于 CSP 算法中的空间滤波计算, 是对各通道信号的加权滤波, 因此该层输出变为一维的信号。

中间层的最后一层为深度分离卷积^[26], 此卷积过程是深度卷积与点卷积的组合, 因此有两层的卷积过程。点卷积的卷积核大小为 1×1 , 因此卷积不会改变特征图大小, 但是也能特征降维、增加模型的非线性表达能力。

上一层输出的特征图首先经过深度卷积过程, 进一步提取时域特征, 再经历式 (3) 所示的点卷积过程:

$$\mathbf{y}_j = f\left(\left(\sum_i (\mathbf{X}_i * \mathbf{w}_j) + \mathbf{b}_j\right)\right) \quad (3)$$

式中: \mathbf{y}_j 表示第 j 个特征图输出; \mathbf{X}_i 表示第 i 个特征图输入; \mathbf{w}_j 表示第 j 个点卷积核; \mathbf{b}_j 表示卷积偏置; f 表示激活函数。

可以看出点卷积核会与每一个输入的特征图进行卷积, 求和之后得到特征图输出, 深度分离卷积过程增加了网络对脑电信号的时空耦合特征提取学习能力。

最后在输出层进行全连接与分类结果输出, 实现脑电信号解码。

1.2 Faster-EEGNet 网络结构

本文的研究主要是在 EEGNet 网络模型的基础上进行优化, 提出下图 2 所示的适用于运动想象脑电信号解码的 Faster-EEGNet 紧凑式深度学习网络。网络的输入数据导联数为 C , 数据长度为 T , F_l 与 D 表示网络的一组可调整超参数, 由 F_l 与 D 可以确定网络的结构。

本研究提出的网络模型重点对 EEGNet 第一层与第二层结构进行改造, 在网络构建过程中也选用了一维卷积核加快卷积速度, 相比于 EEGNet 也有更强的单通道信号的不同频段、不同通道信号以及信号时域信息的耦合特征学习, 实现更快的网络训练速度与更强的特征提取能力。

表 1 中详细列出了 Faster-EEGNet 网络的结构与参数, 首先是输入层, 对于采集到的原始脑电信号, 需要预先进行适当的预处理, 如通道选择、去线性趋势、带通滤波等, 数据形状为采样点数 \times 通道数 ($T \times C$)。中间层的第一层是大小为 32 的 F_l 个 1D 卷积滤波器, 对多通道的脑电信号进行时域特征提取, 数学计算公式如式:

$$\mathbf{y}_j^l = f\left(\left(\sum_{i \in M} (\mathbf{X}_i^{l-1} * \mathbf{w}_{i,j}^l) + \mathbf{b}_j^l\right)\right) \quad (4)$$

式中, \mathbf{y}_j^l 表示第 l 层第 j 个特征图输出, \mathbf{X}_i^{l-1} 表示输入 l 层的第 i 个特征图, $\mathbf{w}_{i,j}^l$ 表示第 i 个特征图的第 j 个卷积权重矩阵, \mathbf{b}_j^l 表示偏置, f 表示激活函数。




图 2 Faster-EEGNet 网络结构
Fig.2 structure of Faster-EEGNet

表 1 Faster-EEGNet 网络结构与参数

Table 1 Faster-EEGNet network structure and parameters

网络层	卷积核数	核大小	层可训练参数	输出尺寸	激活函数	备注
Input				(T, C)		
Conv1D	F_l	32	$32CF_l$	(T, F_l)	Linear	采用 same 卷积
BatchNorm			$4F_l$	(T, F_l)		
Depthwise	F_l	16	$16DF_l$	$(T-15, F_l D)$	Linear	采用 valid 卷积

Conv1D						
BatchNorm			$4F_1D$	$(T-15, F_1D)$		
Activation				$(T-15, F_1D)$	Relu	
Average Pool1D	4			$((T-15)/4, F_1D)$		
Dropout				$((T-15)/4, F_1D)$		丢弃概率 0.25 或 0.5
Seperable Conv1D	DF_1	16	$16DF_1$	$((T-15)/4, F_1D)$	Linear	采用 same 卷积
BatchNorm			$4F_2$	$((T-15)/4, F_1D)$		
Activation				$((T-15)/4, F_1D)$	Relu	
Average Pool1D	8			$((T-15)/32, F_1D)$		
DropOut				$((T-15)/32, F_1D)$		丢弃概率 0.25 或 0.5
Flatten				$(T-15)/32F_1D$		
Dense			$N(T-15)/32F_1D$	N		

与 EEGNet 的第一层相比,该层卷积对所有通道采用不同的卷积权重,滤波之后进行叠加,虽然大大增加了该层的可训练参数,但是也增强了对时空耦合特征的学习能力。在卷积核的大小选择上,选择了更小的 32,以增加时间分辨率。不仅如此,由于采用的卷积在运算过程中是对所有的通道同时进行,因此相比于 EEGNet 计算速度提升较大,实现了在参数增多的情况下计算速度加快。之后的批次标准化的计算起到了正则化的作用,减小数据的分布变化。第二层是大小为 16 的深度卷积层,深度卷积的特点就是卷积核不与上一层所有的特征图连接,一方面的作用是减少该层参数量,另一方面的作用是单独对上一层输出的时空特征图进行时域特征学习。在激活函数的选择上,没有依照 EEGNet 使用指数线性单元(elu),而是选择了整流线性单元(Relu)函数,其数学表达式为:

$$y = \begin{cases} x, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (5)$$

式中, y 表示激活函数输出, x 表示激活函数的输入。

由于 Relu 会将输入为负的激励输出为 0,起到了特征选择的作用,同时将部分神经元输出置零也加快了网络计算的速度。

深度卷积之后使用大小为 4 的平均池化,将 250hz 的信号降采样到 64hz,池化计算也大大降低了特征图大小,减少了计算量。紧随的神经元丢弃(DropOut)操作使部分神经元失活,起到了防止过拟合的作用,失活率可以根据训练过程中的过拟合情况选择 0.25 或者 0.5。中间层的最后一层是深度分离卷积,与 EEGNet 一样,借鉴了共空间模式算法的思想,此层的作用是进一步提取时间-空间域上的特征,输出的特征图经历 BatchNorm、Relu 激活、平均池化、Dropout,生成该层输出。尺寸为 8 的平均

池化进一步降低了特征图大小,减少了后续计算量。最后经过全连接展平,将所有的特征与输出层连接。

Faster-EEGNet 将第一层二维平面串行卷积变为所有通道同时进行的串行卷积,第一层完成了各通道信号的时域滤波、空间滤波,中间深度卷积层对空间模式提取信号进行时域卷积特征提取,最后由深度分离卷积再次提取信号时间-空间耦合特征。虽然可训练参数量有所增加,但是计算速度与特征学习能力增强。

2 实验材料与实验设计

2.1 数据集介绍

本文使用 2022 年世界机器人锦标赛-BCI 脑控机器人人大赛公开的运动想象 RankB 赛题数据作为验证数据集,实验数据使用博瑞康 64 导脑电采集设备采集,含一个 trigger 信息通道,信号采样频率为 250hz。每次实验包含 2s 的任务提示、4s 的运动想象、2s 的休息,一组实验包含 30 次实验,任务类型包含左手运动、右手运动、双脚运动的想象,每种任务各有十次且随机出现。数据集采集了 5 名被试运动想象数据,每名被试 3 组共 90 个试次。为了模拟真实的在线识别场景,本文的脑电解码实验使用的训练集与测试集数据均来自不同的实验组,以减少训练集与测试集的相似性。

2.2 模型训练与验证实验设计

为验证本文提出的 Faster-EEGNet 的性能,设计与 EEGNet 在所选公开数据集上运动想象解码性能对比实验。同时给出模型训练的过程如下:

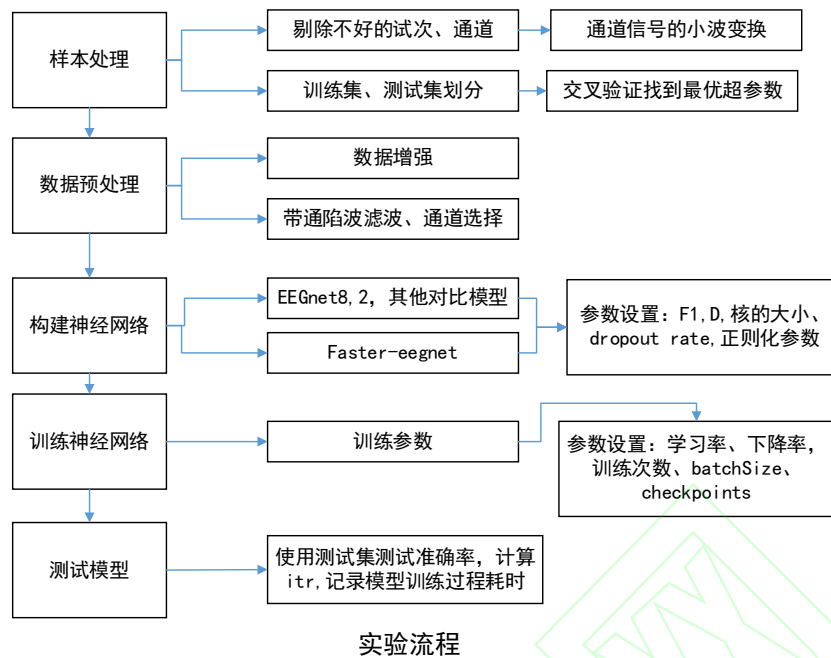


图 3 模型训练与实验过程

Fig.3 Model training and experiment process

实验使用 python 语言平台进行, 计算机配置为 12 核 intel Core i7-8700, 编程环境: Windows10 + python3.10。不使用 GPU 的原因是在前期实验过程中发现在数据量与神经网络都很小的情况下, GPU 训练的速度很大程度上取决于 CPU 处理与载入数据的速度, 因此训练耗时差异很小, 因此使用 CPU 进行训练可以更好对比神经网络训练速度差异。

样本处理步骤, 实验中对每个被试的所有通道每个试次的数据进行小波变换, 绘制试次信号的时频图。根据经验去掉噪声比较大的脑电信号通道与试次样本, 在其他学者的研究工作中, 通道选取对于运动想象解码的性能是影响较大的实验参数, 本实验的通道选择如下:

表 2 脑电通道号选取
Table 2 Selection of EEG channel number

被试	脑电信号通道号选择
S1	17-22, 25-31, 34-39
S2	17-22, 25-31, 34-39
S3	1-22, 24-31, 33-39, 41-43, 45-46, 48-59
S4	1-31, 33-40, 42-43, 45-59
S5	17-22, 25-31, 34-39

对于每个被试训练集与测试集的划分, 首先为了消除训练数据与测试数据相似度对测试结果的影响, 先使用第一个实验组的数据作为测试集, 第二、三组的数据作为训练集, 得到测试集准确率之后依次再使用第二组、第三组数据作为测试集, 即使用交叉验证的方法, 使用三组测试集的准确率平均值作为模型的分类识别准确率。

下一步骤是数据预处理步骤, 由于数据集中每个被试的数据样本只有 90 个试次, 训练集样本只有

60 试次, 因此本文采用移动剪裁的方法进行数据增强, 使用长度为 120 的窗, 移动间隔为 30 的裁剪方法对 4s 的运动想象数据进行裁剪, 可以将数据样本扩大 30 倍。之后对增强后的样本进行去线性趋势、8-30hz 滤波。

构建 EEGNet8,2 时按照 Lawhern^[19]所述的网络参数进行构建, Faster-EEGNet 按照表 1 的参数进行设置, $F1$ 设置为 16, D 设置为 2, $F2$ 设置为 32, 第一个 Dropout 的丢弃概率设置为 0.5, 第二个 Dropout 的丢弃概率设置为 0.25

模型训练的 batch size 设置为 32, EEGNet 的学习率设置为 0.01, Faster-EEGNet 学习率设置为 0.0001, 学习率设置梯度衰减, 防止训练前期收敛太慢与训练后期过拟合。需要说明的是, 为了发挥两种网络的最佳性能, 两种网络学习率与 batch size 的设置是在训练调参过程中不断调整后的一个较优的参数。

2.3 性能评价方法

2.3.1 模型准确率

为验证本文所提出模型的先进性, 首先使用 3.2 中所述的模型训练方法, 分别训练 EEGNet8,2, 与 Faster-EEGNet 网络。EEGNet8,2 训练次数设置 200 次, 且使用 Lawhern^[19]中所述的 Checkpoint 方法, 选择验证集上损失函数最小的模型作为输出模型。本文提出的 Faster-EEGNet 则不使用 Checkpoint 方法, 训练 200 次之后以最后一次训练得到的模型作为输出模型。采用 3 折交叉验证的方法得出模型的识别准确率 (分别用第 1 组、第 2 组、第 3 组的数据作为测试样本, 另外两组数据作为训练样本), 且每个

被试均重复 20 次实验, 记录每次实验的交叉验证准确率。

2.3.2 信息传输率

信息传输率是描述数据传输系统的重要技术指标之一, 是描述脑-机接口性能的重要指标, 其计算公式为:

$$R_{IT} = 60 \left[\text{lb}N + P \text{lb}P + (1 - P) \text{lb} \left(\frac{1 - P}{N - 1} \right) \right] / L \quad (6)$$

式中, R_{IT} 表示信息传输率, N 表示目标数, P 表示识别准确率, L 表示平均试次时长。

在本实验中, 使用的脑电数据长度为 0.48s, 但是考虑到实际使用场景, 加上了模拟的 0.5s 休息时长, 因此在计算过程中 L 取 0.98。

2.3.3 模型训练速度

使用 S04 被试的数据, 从训练 10 个 epoch 开始, 逐步增加 10 个 epoch, 一直增加到 100 个 epoch, 每次训练网络时, 在训练前后分别记录时间, 以记录每次实验的训练耗时, 此实验也重复 20 次, 记录每次训练耗时结果。

2.3.4 模型推理速度

模型的推理速度受测试数据的长度以及脑电数据的通道数影响。为评价测试数据的长度对模型推理速度的影响, 首先使用 S04 被试的数据, 选择第 1 组与第 2 组共 60 个试次的 59 通道脑电数据, 按照 2.2 节中所述方法对样本进行预处理为长度为 0.5s、1.0s、1.5s、2.0s、2.5s、3s, 分别训练 Faster-EEGNet 网络与 EEGNet8,2 网络, 训练次数设置为 200, EEGNet8,2 使用 Checkpoint 方法选择输出模型。测试集使用 2.2 节中所述方法增强到 360 个样本, 每个长度样本对应的实验重复 3 次, 记录两种模型对测试集所有样本进行推理所消耗的时间。

2.3.5 结果的假设检验

对于上述的性能评价指标实验结果, 视作同一组数据的不同处理或测量结果的均值差异, 可以使用双样本 t 检验 (paired t-test) 的方法来比较均值大小, 即构建式(7)的 t 检验统计量对两组样本的均值进行检验, 其自由度的数目由 Satterthwaite 逼近给出。

$$t = (\bar{x} - \bar{y}) / \left(\sqrt{\frac{s_x^2}{n} + \frac{s_y^2}{m}} \right) \quad (7)$$

式中, \bar{x} 与 \bar{y} 是样本均值, s_x 与 s_y 是样本标准差, n 与 m 是样本大小。

如均值相等检验通过则结果无明显差异, 否则进行单侧检验比较均值大小。

3 实验结果与讨论

3.1 网络可训练参数

本研究对比了 Faster-EEGNet、EEGNet8,2、DeepConvNet 以及 ShallowConvNet 网络四种网络的可训练参数量。

表 3 几种运动想象解码网络的可训练参数对比
Table 3 Comparison of trainable parameters of several motor imagery decoding networks

网络类型	可训练参数
Faster-EEGNet	12,227
ShallowConvNet	32,363
EEGNet 8,2	2,043
DeepConvNet	146,203

表 3 展示了 Faster-EEGNet 网络与其他研究者所提出的神经网络可训练参数, 其中 DeepConvNet 的可训练参数量最大, 达到了 10^5 数量级, ShallowConvNet 与 Faster-EEGNet 的数量级都在 10^4 , EEGNet8,2 的可训练参数是最少的。总体而言, Faster-EEGNet 的可训练参数量是相对较少的, 因此在小样本训练场景也能获得较好的模型拟合效果, 相比于 EEGNet, 由于第一层的卷积层为每个通道都分配了单独的卷积核, 导致参数量增加, 但同时也换来了更强的耦合特征提取学习能力。

3.2 运动想象脑电信号解码准确率与信息传输率

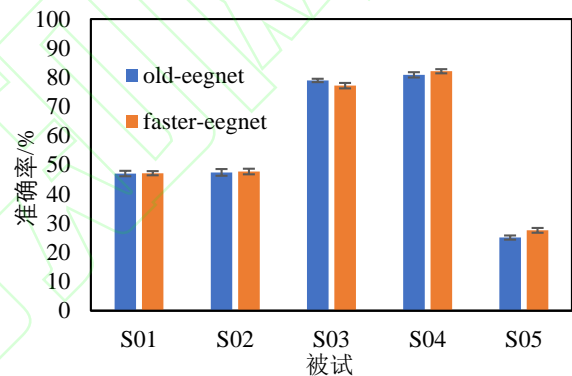


图 4 EEGNet8,2 与 Faster-EEGNet 分类准确率
Fig.4 Classification accuracy of EEGNet8,2 and Faster-EEGNet

表 4 EEGNet8,2 与 Faster-EEGNet 信息传输率

被试	EEGNet8,2		Faster-EEGNet	
	R_{IT} /bit/min	方差	R_{IT} /bit/min	方差
S01	3.5625	0.4861	3.6104	0.3715
S02	3.7664	0.6071	3.9135	0.5092
S03	38.7724	1.0317	35.6577	1.5718
S04	42.2812	1.6905	44.6392	1.4204
S05	0	0	0	0

图 4 展示了 EEGNet8,2 与 Faster-EEGNet 在世界机器人锦标赛上运动想象 B 榜三分类数据集上的识别准确率结果, 所有的数据样本长度均为 0.48s, 首先在 S04 与 S05 被试的表现上, 分别取得了 82.12% 与 27.57%, Faster-EEGNet 识别准确率优于 EEGNet8,2 (在 $p < 0.001$ 的显著水平上), S03 被试则是 EEGNet8,2 取得了更好的识别准确率。S01 与 S02 被试上两种算法无明显差异, 平均准确率 Faster-EEGNet 比 EEGNet 提升 0.46%。识别结果也

显示出不同的被试间, 运动想象信号的质量差异也比较大。

表 4 展示了 EEGNet8,2 与 Faster-EEGNet 在实验中运动想象解码信息传输率的结果, 由于被试 S05 的三分类准确率低于 1/3, 因此信息传输率都为 0, Faster-EEGNet 在 S04 上的信息传输率结果更优 (在 $p<0.001$ 的显著水平上), 在 S01 与 S02 数据上两种算法无明显差异。

3.3 神经网络训练速度对比结果

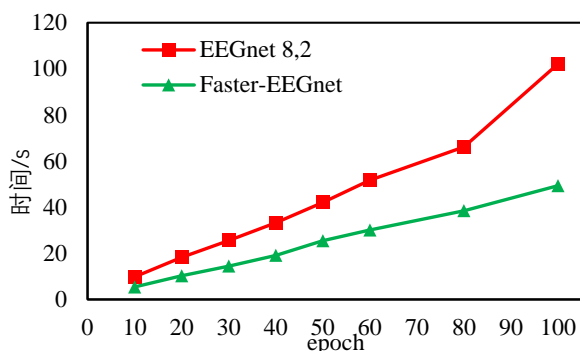


图 5 训练模型耗费时间
Fig.5 Time spent training model

图 5 为两种神经网络在 S04 被试上训练耗时, 结果显示在训练代数 10-100 的所有实验中, Faster-EEGNet 的模型训练耗时都明显于 EEGNet8,2 (在 $p<0.001$ 的显著水平上), 本文提出的模型能够在训练模型时减少 44.8% 的训练耗时, 因此在训练速度上有较明显的提升效果。模型训练速度的加快得益于, Faster-EEGNet 将第一层二维平面串行卷积变为所有通道同时进行的串行卷积, 第一层使用较小的卷积核完成了各通道信号的时域滤波、空间滤波, 而不同于 EEGNet 的第一层为所有的通道分配一个卷积滤波器, 后者在卷积计算时使用的是比较大的卷积核逐次串行对所有通道进行卷积, 因而第一层只完成了时域滤波过程, 第一层的输出特征图也比较大, 提升了后续计算的复杂度。

3.4 模型推理速度对比结果

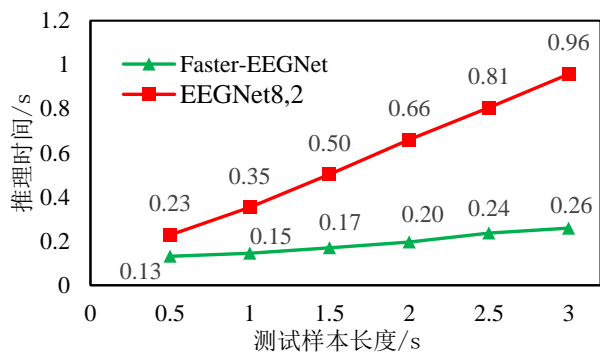


图 6 测试集预测所耗时间

Fig.6 Time spent on test sample prediction

图 6 展示了 Faster-EEGNet 网络模型与 EEGNet 网络模型, 在大小为 360 的测试样本上的预测推理消耗时间结果。可以发现两种算法的推理时间都随着样本长度的增加而近似线性增加, 但 Faster-EEGNet 网络模型的推理时间在所有测试样本长度下均小于 EEGNet8,2 网络模型 ($p<0.001$ 的显著性水平下), 在样本长度为 0.5s 时推理时间减少 43.6%, 样本长度为 3s 时推理时间减少 73.0%; 从单样本推理时间来看, 样本长度为 3s 时最长, Faster-EEGNet 网络模型推理耗时 0.73ms, 而 EEGNet 网络模型推理耗时 2.66ms; 结果显示 Faster-EEGNet 网络模型推理速度相较于 EEGNet 有较大的提升。

4 结论

本文针对现有深度学习方法在运动想象脑电信号识别领域面临的挑战, 解决基于运动想象的脑-机接口在实际应用中对于快速模型训练、想象任务准确识别、小样本训练的需求, 在 EEGNet 网络的结构基础上, 提出了紧凑型的 Faster-EEGNet 网络, 并详细给出了该网络的结构参数设置以及训练方法。与其他学者提出的神经网络相比, 网络参数量较少, 因此对于小样本的训练场景也能够获得较好的模型拟合效果。在所选的三分类运动想象数据集上的分类结果表明, 所提出的神经网络平均识别准确率与信息传输率高于 EEGNet, 部分被试结果显著高于 EEGNet, 显示出较好的解码性能。在模型训练速度上, Faster-EEGNet 有着较为显著的优势, 在本研究的实验中, 所有试次平均训练速度提升 44.8%。在基于运动想象的脑机接口系统中, 一般都需要针对使用者训练单独的脑电解码模型, 所提出的 Faster-EEGNet 网络能够在保证较好的解码性能的情况下, 显著减少解码模型的训练耗时, 提升了运动想象脑机接口系统的便利性; 此外所提出的 Faster-EEGNet 网络, 模型推理速度提升 43.6% 以上, 大大增加了脑机接口系统的快速响应性能。

参考文献:

- [1] WOLPAW J R, BIRBAUMER N, HEETDERKS W J, et al. Brain-computer interface technology: A review of the first international meeting [J]. Ieee Transactions on Neural Systems and Rehabilitation Engineering, 2000, 8(2): 164-173.
- [2] 王维振, 曲皓, 雷杨浩, et al. 下肢运动想象脑机接口的研究进展及康复应用 [J]. 北京生物医学工程, 2023, 42(02): 204-211.
WANG Weizhen, QU Hao, LEI Yanghao, et al. Research progress and rehabilitation application of brain-computer interface based on lower-limb motor imagery [J]. Beijing Biomedical Engineering, 2023, 42(02):204-211.
- [3] 张海军, 王浩川. 多导联 eeg 信号分类识别研究 [J]. 计算机工程与应用, 2008, No.619(24): 228-230.
ZHANG Haijun, WANG Haochuan. Research on classification and recognition of multi-channel EEG Signal

- [J]. Computer Engineering and Applications, 2008,619(24):228-230.
- [4] KUMAR J S, BHUVANESWARI P. Analysis of electroencephalography (eeg) signals and its categorization—a study [J]. Procedia Engineering, 2012, 38: 2525-2536.
- [5] LI Z, O'DOHERTY J E, HANSON T L, et al. Unscented kalman filter for brain-machine interfaces [J]. PLOS ONE, 2009, 4(7).
- [6] VAN ERP J B F, LOTTE F, TANGERMANN M. Brain-computer interfaces: Beyond medical applications [J]. Computer, 2012, 45(4): 26-34.
- [7] 王迪, 陶庆, 张小栋, et al. 采用改进共空间模式算法的四类表情辅助脑电信号识别方法 [J]. 西安交通大学学报, 2022, 56(12): 136-143.
WANG Di, TAO Qing, ZHANG Xiaodong. Recognition of Four-class facial expression electroencephalogram data using improved common spatial pattern algorithm [J]. Journal of Xi'an Jiaotong University, 2022, 56(12): 136-143.
- [8] MÜLLER-GERKING J, PFURTSCHER G, FLYVBJERG H. Designing optimal spatial filters for single-trial eeg classification in a movement task [J]. CLINICAL NEUROPHYSIOLOGY, 1999, 110(5): 787-798.
- [9] GRAIMANN B, HUGGINS J E, LEVINE S P, et al. Visualization of significant erd/ers patterns in multichannel eeg and ecog data [J]. CLINICAL NEUROPHYSIOLOGY, 2002, 113(1): 43-47.
- [10] SONG X M, YOON S C, PERERA V, et al. Adaptive common spatial pattern for single-trial eeg classification in multisubject bci [C]//Proceedings of the 6th International IEEE EMBS Conference on Neural Engineering (NER). Piscataway, NJ, USA: IEEE, 2013: 411-414.
- [11] KAI KENG A, ZHANG YANG C, HAIHONG Z, et al. Filter bank common spatial pattern (fbcs) in brain-computer interface [C]// 2008 IEEE International Joint Conference on Neural Networks (IEEE World Congress on Computational Intelligence). Piscataway, NJ, USA: IEEE, 2008: 2390-2397.
- [12] HIGASHI H, TANAKA T. Simultaneous design of fir filter banks and spatial patterns for eeg signal classification [J]. IEEE Transactions on Biomedical Engineering, 2013, 60(4): 1100-1110.
- [13] MIAO Y, JIN J, DALY I, et al. Learning common time-frequency-spatial patterns for motor imagery classification [J]. Ieee Transactions on Neural Systems and Rehabilitation Engineering, 2021, 29: 699-707.
- [14] HOU Y, CHEN T, LUN X, et al. A novel method for classification of multi-class motor imagery tasks based on feature fusion [J]. Information Sciences, 2022, 176: 40-48.
- [15] VOULODIMOS A, DOULAMIS N, DOULAMIS A, et al. Deep learning for computer vision: A brief review [J]. Computational Intelligence and Neuroscience, 2018: 1-13.
- [16] GAVAT I, MILITARU D. Deep learning in acoustic modeling for automatic speech recognition and understanding - an overview [C]// Proceedings of the 8th International Conference on Speech Technology and Human-Computer Dialogue (SPED). Piscataway, NJ, USA: IEEE, 2015: 37-44.
- [17] ANTONIADES A, SPYROU L, TOOK C, et al. Deep learning for epileptic intracranial eeg data [C]// Proceedings of the 26th IEEE International Workshop on Machine Learning for Signal Processing (MLSP). Piscataway, NJ, USA: IEEE, 2016: 1-6.
- [18] SCHIRMEISTER R T, SPRINGENBERG J T, FIEDERER L D J, et al. Deep learning with convolutional neural networks for eeg decoding and visualization [J]. Human Brain Mapping, 2017, 38(11): 5391-5420.
- [19] LAWHERN V J, SOLON A J, WAYTOWICH N R, et al. Eegnet: A compact convolutional neural network for eeg-based brain-computer interfaces [J]. Journal of neural engineering, 2018, 15(5).
- [20] LIU X, SHI R, HUI Q, et al. Tcacnet: Temporal and channel attention convolutional network for motor imagery classification of eeg-based bci [J]. Information Processing & Management, 2022, 59(5).
- [21] 宋耀莲, 殷喜喆, 杨俊. 基于时空特征学习 transformer 的运动想象脑电解码方法 [J]. 南京大学学报(自然科学), 2023, 59(02): 313-321.
SONG Yaolian, YIN Xiji, YANG Jun. Transformer based on temporal-spatial feature learning for motor imagery electroencephalogram signal decoding [J]. Journal of Nanjing University(Natural Science), 2023, 59(02): 313-321.
- [22] NIU X, WU X, XIE P, et al. A time-frequency analysis of event-related desynchronization/synchronization based on gabor filter [C]//Proceeding of the 11th World congress on intelligent control and automation. Piscataway, NJ, USA: IEEE, 2014: 5179-5184.
- [23] PADFIELD N, ZABALZA J, ZHAO H M, et al. Eeg-based brain-computer interfaces using motor-imagery: Techniques and challenges [J]. SENSORS, 2019, 19(6): 1423.
- [24] CHAI W. Prodsumnet: Reducing model parameters in deep neural networks via product-of-sums matrix decompositions arxiv [J]. 2018. DOI: 10.48550 / arXiv.1809.02209.
- [25] FLESHER S N, DOWNEY J E, WEISS J M, et al. A brain-computer interface that evokes tactile sensations improves robotic arm control [J]. Science, 2021, 372(6544): 831-+.
- [26] CHOLLET F. Xception: Deep learning with depthwise separable convolutions [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.

(编辑 李慧敏 刘杨)