

# 杭州电子科技大学

## 硕士学位论文

题目：基于深度学习和注意力机制的运动想象脑电信号分类研究

研究生 吴进辉

专业 电子信息

指导教师 吴占雄 副教授

完成日期 2023 年 05 月

杭州电子科技大学硕士学位论文

基于深度学习和注意力机制的运动想象脑电  
信号分类研究

研 究 生：吴进辉

指导教师：吴占雄      副教授

2023 年 05 月

**Dissertation Submitted to Hangzhou Dianzi University**

**For the Degree of Master**

**Research on Classification of Motor Imagery  
EEG Signals Based on Deep Learning and  
Attention Mechanism**

**Candidate: Jinhui Wu**

**Supervisor: Associate Prof. Zhanxiong Wu**

**May, 2023**

## 摘要

脑电(Electroencephalogram, EEG)信号的特征提取与分类识别是脑机接口系统的重要组成部分。其中运动想象脑机接口系统可以将大脑产生的神经信号转化为辅助设备的控制指令,能够为残疾患者提供一种康复方法,具有较高的实用价值。但如何精确地提取脑电信号的时域、空域特征,从而提高脑电信号的分类精度,依然是亟需解决的难题。为此,本文使用深度学习方法对 GIGA 公开数据集中两类手运动想象脑电信号进行分类研究。本论文的主要工作概括如下:

(1) 首先根据运动想象脑电信号的频率特性,采用 8Hz-30Hz 的带通滤波器进行滤波处理;然后使用重参考和独立成分分析去除噪声和伪迹的影响。并对实验数据进行时间切分和降采样处理,构建了两类手运动想象脑电信号数据集,为后续的分类研究奠定了基础。

(2) 基于深度学习方法对运动想象脑电信号进行分类研究。本文首先采用 EEGNet、EEG-Inception 模型对两类手运动想象脑电信号进行分类。针对 EEGNet、EEG-Inception 模型分类性能不佳的问题,本文设计了一种基于卷积神经网络(Convolutional Neural Network, CNN)的分类模型(CNN-Net),使用四种通道信号组合对两类手运动想象脑电信号进行了分类研究。实验结果表明, CNN-Net 的分类性能优于 EEGNet、EEG-Inception,取得了更好的分类效果,并通过对比现有的研究方法,进一步验证了 CNN-Net 模型的有效性。CNN-Net 在使用 4 通道(FC3-FC4, C1-C2)信号的情况下分类效果最好,两类手运动想象脑电信号分类的平均准确率达到 94.90%。

(3) 为了探索注意力机制对 CNN-Net 模型分类性能的影响,在工作(2)的基础上将 SENet (Squeeze-and-Excitation Network)、ECA (Efficient Channel Attention)、CBAM (Convolution Block Attention Module)注意力机制分别与 CNN-Net 模型融合。对比分析了不同注意力机制引入方式对 CNN-Net 分类性能的影响。实验结果表明,注意力机制引入到网络的中间层相比于网络的浅层和深层取得的分类效果更好。在最佳引入方式下,融合 SENet 的 CNN-Net 模型,分类的平均准确率达到 95.79%,相比于 CNN-Net 模型的性能得到进一步提升,其分类性能优于现存的大部分方法,并避免了复杂的特征提取过程。这些结果为运动想象脑电信号的分类研究提供了新的参考。

**关键词:** 深度学习, 运动想象, 脑电信号, 卷积神经网络, 注意力机制

## ABSTRACT

Feature extraction and classification of Electroencephalogram (EEG) signals is an important part of the Brain-computer Interface (BCI) system. Motor-imagery (MI) BCI system can convert EEG signals into control instructions for auxiliary equipment, providing a rehabilitation method for motion-disabled patients, which has high practical value. However, how to accurately extract temporal-spatial features of EEG signals to improve the classification accuracy of MI BCI is still a problem that needs to be solved urgently. To this end, this study uses deep-learning techniques to classify two types of hand (Left-hand and right-hand motion) MI EEG signals in the GIGA public-available dataset. The main work of this paper is summarized as follows:

(1) First, based on the frequency characteristic of MI EEG, the band-pass filter of 8Hz-30Hz was used to filter EEG signals. Then, common average reference and independent component analysis were used to remove noise and artifact. Last, EEG signals were time-sliced and down-sampled. Two types of hand MI EEG datasets were obtained, which laid the foundation for the subsequent classification research.

(2) Classification of MI EEG signals based on deep-learning methods. EEGNet and EEG-Inception models were used to classify two types of hand MI EEG signals. To address the inadequate classification performance of EEGNet and EEG-Inception models, a classification model based on convolutional neural network (CNN-Net) was designed. Left-hand and right-hand MI EEG signals were classified using four pairs motor-related EEG channels. The experimental results show that CNN-Net outperforms EEGNet and EEG-Inception, and achieves better classification effect. And by comparing existing research methods, the effectiveness of the CNN-Net model was further verified. CNN-Net has the best classification effect when using 4-channel (FC3-FC4, C1-C2) signals, and the average accuracy rate of classification reaches 94.90%.

(3) To explore the effect of attention mechanism on performance of CNN-Net model, SENet (Squeeze-and-Excitation Network), ECA (Efficient Channel Attention), and CBAM (Convolution Block Attention Module) attention mechanisms were respectively incorporated into CNN-Net model designed in (2). Influence of different attention mechanisms on the classification performance of CNN-Net were comparatively analyzed. The experimental results show that the integration of attention mechanism into the middle layers of the network achieves better classification results than the shallow and deep layers of CNN-Net. Under the

optimal incorporation method, the CNN-Net model incorporated with SENet achieved an average accuracy of 95.79% in classification. Compared with the CNN-Net model, its classification performance was further improved. Its classification performance is better than most existing methods and avoids the complex feature extraction process. These results provide new references for the classification of motor imagery EEG signals.

**Keywords:** Deep Learning, Motor Imagery, Electroencephalogram, Convolutional Neural Network, Attention Mechanism

## 目录

摘要 .....	I
ABSTRACT .....	II
目录 .....	IV
第 1 章 绪论 .....	1
1.1 研究背景与意义 .....	1
1.2 国内外研究现状 .....	2
1.2.1 运动想象脑机接口研究现状 .....	2
1.2.2 运动想象脑电信号分类研究现状 .....	4
1.3 本文主要研究内容 .....	6
1.4 本文组织结构 .....	7
第 2 章 运动想象脑电信号分析的基础理论 .....	8
2.1 脑机接口系统 .....	8
2.1.1 脑机接口系统组成 .....	8
2.1.2 脑电信号范式种类 .....	10
2.2 脑电信号基础 .....	11
2.2.1 脑电信号生理基础 .....	11
2.2.2 事件相关同步/去同步现象 .....	12
2.3 卷积神经网络基本原理 .....	12
2.3.1 卷积神经网络构成 .....	13
2.3.2 激活函数和优化算法 .....	15
2.3.3 卷积神经网络的特点 .....	17
2.4 本章小结 .....	18
第 3 章 基于深度学习的运动想象 EEG 分类研究 .....	19
3.1 引言 .....	19
3.2 实验数据介绍与预处理 .....	19
3.2.1 实验数据介绍 .....	19
3.2.2 实验数据预处理 .....	20

3.3 基于 EEGNet 的运动想象 EEG 分类研究 .....	24
3.3.1 实验环境与评价指标 .....	25
3.3.2 实验结果与分析 .....	26
3.4 基于 EEG-Inception 的运动想象 EEG 分类研究 .....	27
3.4.1 实验环境与评价指标 .....	27
3.4.2 实验结果与分析 .....	28
3.5 基于 CNN-Net 的运动想象 EEG 分类研究 .....	29
3.5.1 实验环境与评价指标 .....	30
3.5.2 网络模型最优参数 .....	30
3.5.3 对比实验 .....	33
3.6 实验结果与分析 .....	34
3.6.1 对比分析 .....	34
3.6.2 综合对比分析 .....	36
3.7 本章小结 .....	37
第 4 章 融合注意力机制的 CNN-Net 的运动想象 EEG 分类研究 .....	38
4.1 引言 .....	38
4.2 注意力机制种类 .....	38
4.2.1 SENet 注意力机制 .....	38
4.2.2 ECA 注意力机制 .....	39
4.2.3 CBAM 注意力机制 .....	40
4.3 融合注意力机制的 CNN-Net 的运动想象 EEG 分类对比实验 .....	41
4.3.1 实验环境与评价指标 .....	42
4.3.2 融合 SENet 的 CNN-Net 的运动想象 EEG 分类研究 .....	42
4.3.3 融合 ECA 的 CNN-Net 的运动想象 EEG 分类研究 .....	45
4.3.4 融合 CBAM 的 CNN-Net 的运动想象 EEG 分类研究 .....	47
4.4 实验结果与分析 .....	50
4.4.1 对比分析 .....	50
4.4.2 消融实验 .....	51
4.4.3 综合对比分析 .....	52
4.5 本章小结 .....	53
第 5 章 总结与展望 .....	54
5.1 总结 .....	54



5.2 展望 .....	55
参考文献 .....	56
致谢 .....	63
附录 .....	64

## 第 1 章 绪论

### 1.1 研究背景与意义

脑属于人体神经中枢系统的一部分，通过神经系统识别外界的视觉和听觉等刺激，通过神经系统和肌肉之间的协调从而进行正常的肢体运动。人类大脑的皮层含有约一千亿个神经细胞，当人们进行思考时，这些神经细胞会产生一系列的神经电活动。神经元和突触构成神经信息传递网络，能够协调管理人的认知、语言、意识和思维等基本神经活动<sup>[1]</sup>。在科技高速发展的推动下，世界上许多国家和组织意识到脑科学的重要性，学者们开始对大脑进行更加深入的研究，纷纷开展脑探索计划<sup>[2]</sup>。2013 年，美国启动了“创新性神经技术大脑研究”的研究计划，研究方向是大脑功能和行为之间的复杂联系，旨在为老年痴呆症、创伤性脑损伤的患者提供一种新的康复方法。同年，欧盟也推出了“人类脑计划”，研究的重心是神经信息学、大脑模拟、神经形态计算和神经机器人。2014 年，日本启动了名为“脑计划”的研究项目，主要研究方向包括绘制猕猴大脑结构、开发脑图绘制技术以及绘制人类脑图谱。为了在脑科学领域占据战略性地位，中国在 2015 年启动了为期十五年“中国脑”的研究计划，探索认识脑、保护脑和模拟脑三个研究领域，并逐步形成“一体两翼”的研究布局，将脑认知解析平台作为主体，以认知障碍类重大脑疾病的康复技术和类脑计算技术作为辅助。脑科学技术研究是 21 世纪人类所面临的一项重大挑战。脑科学研究的意义在于深入理解人类行为和决策背后的神经机制，这对于认知和行为科学、医学技术等领域都具有重要影响，同时也有助于促进心理学和神经科学之间的融合。

脑机接口(Brain-computer Interface, BCI)是一项新型的人工智能技术，通过计算机接收脑电信号，经处理分析后对外围设备发送对应的指令并执行相应的操作，由此可以建立出一条全新的人机交互通路<sup>[3-5]</sup>。BCI 不依赖神经肌肉的通信方式的大脑意识正常但具有运动障碍的人群提供了一种新的医疗康复手段，具有重大的研究意义<sup>[6-8]</sup>。

运动想象(Motor-Imagery, MI)脑机接口系统实现了一种全新的脑机交互方式，能够将输入的脑电(Electroencephalogram, EEG)信号提取特征，进一步进行模式识别，使得人们可以通过想象肢体运动来控制外围设备。在医疗康复领域以及辅助领域，MI-EEG 技术拥有广泛的应用前景，因此越来越多的科学研究人员加入到 MI-BCI 的研究领域。

随着人类对于 MI-BCI 研究的不断深入，MI-BCI 系统也被广泛的应用于各个领

域。在医疗康复领域，MI-BCI 系统可以通过对具有运动障碍的残障患者外接机械假肢并进行康复训练，帮助患者重新获得肢体运动能力<sup>[9]</sup>。在教育领域，脑机接口创业公司 BrainCo 的目标是实时探测和训练学生上课时注意力的集中程度，以提高学生的学习效率。可以让老师实时了解学生上课时的具体情况，从而更好地指导学生的学习<sup>[10]</sup>。在娱乐领域，基于 MI-BCI 的 VR 也被很好的运用于游戏领域<sup>[11]</sup>，用户可以通过意念来操控游戏里面的角色，使得意念移物变成现实，给用户带来一种全新的游戏体验。在军事领域，脑机接口技术可以远程操控无人设备代替人类在很多高危场合执行任务，协助操作员更准确、高效地操控无人设备<sup>[12]</sup>。

随着互联网及计算机硬件性能的高速发展，深度学习已经被广泛应用于各个领域。传统机器学习方法分为特征提取和分类识别两个部分，但是这两个部分关联性不强。根据脑电信号的时频或者空间特性提取特征，继而使用模式识别算法建立脑电信号特征和目标类别的映射。机器学习是一种线性方法，而自然界的信号大多是非线性信号，所以机器学习具有一定的局限性。深度学习对于复杂的数据能进行逐层抽象，借助激活函数等策略能表示非线性模型，具有强大的学习能力。对于音视频等维度较高的样本，使用传统机器学习方法进行特征提取工作量大，并缺少先验知识；深度学习可以能够直接从原始数据学习和理解数据的特征从而完成分类或者回归等任务，可以看出其对于处理高维度数据具有强大的潜力。近年来，随着 EEG 数据集的日益增加，深度学习已成为处理 EEG 信号的重要工具<sup>[13]</sup>，可见其应用的广泛性和有效性。

综上所述，BCI 系统具有非常广阔的应用前景，基于安全性和价格等方面的考量，目前研究比较热门的是非侵入式的脑机接口，并且朝着可穿戴的方向发展。在脑科学、人工智能飞速发展的同时，脑电信号分析和分类模型是 BCI 系统的关键部分，因此将深度学习应用在脑电信号分类任务中是一个热门的研究方向。

## 1.2 国内外研究现状

### 1.2.1 运动想象脑机接口研究现状

脑机接口从发展至今有着五十年的历史。随着计算机科学、脑科学和医学的高速发展，学者们对于基于运动想象的脑机接口技术的研究也愈发深入，开启了飞速发展的阶段。

1991 年，奥地利格拉兹大学着手于脑机接口技术的研究，主要的研究方向是基于运动想象脑电信号的事件相关同步/事件相关去同步<sup>[14]</sup>。设计了一款能够实现光标控制和机械臂控制的运动想象脑机接口系统，识别准确率能够达到 70% 以上<sup>[15]</sup>。

2001 年，布朗大学 John Donoghue 的研究团队推出了第一款商业化 BCI 产品 NeuroPort<sup>TM</sup>，该脑机接口能够监测和记录脑电活动，并标志着脑机接口商业化的开始。

2004 年, Jonathan Wolpaw 等人在一项实验中取得了重大进展, 证实人们可以通过佩戴非侵入式的电极帽, 仅通过意念就可以实现光标在屏幕上进行二维的上下左右运动, 而不仅仅是以前的单一维度运动<sup>[16]</sup>。这一发现在无创脑机接口领域具有重要意义。

2011 年, 德国马普研究所实现了一款用于手臂康复脑机接口系统, 该系统能够解析从受试者采集的脑电信号, 实现了具有触觉反馈的机械臂控制系统<sup>[17]</sup>。该研究表明, BCI 康复系统对于脑卒中患者具有积极的康复效果。

2018 年, 美国国防部高级研究计划局实现了一款能够赋予飞行员同时操控多架飞机和无人机能力的脑机接口系统, 将脑机接口成功的应用于军事化中。

2020 年 8 月, Neuralink 公司成功在猪的大脑中植入了侵入式脑机接口系统, 该脑机接口系统能够清晰的观察猪大脑的神经活动, 当演示人员触碰它的鼻子时, 可以通过脑电图看出猪的神经开始兴奋。2021 年 4 月, Neuralink 成功将侵入性脑机接口植入猴子脑内, 植入电极的猴子只需要在大脑想象如何移动操作杆就能玩游戏。Neuralink 对未来做出更宏观的预测: 瘫痪患者可以通过脑机接口操作智能手机, 并且速度会比手指还要快。

国内对于运动想象脑机接口系统的研究起步晚, 但也不断在缩小同发达国家技术间的差距, 也取得了不错的进步。2007 年, 清华大学高上凯教授研究团队实现了控制机器狗踢足球的运动想象脑机接口系统。该系统通过监测人类大脑皮层的活动来识别特定的意图, 然后将这些意图转化为命令, 控制机器狗进行相应的动作。

2008 年, 上海交通大学张丽清教授研究团队实现了一款运动想象脑机接口系统, 该系统能够解析并识别运动想象脑电发出对应的控制指令, 从而实现对虚拟汽车的左转、右转、加速和减速控制<sup>[18]</sup>。

2010 年, 华南理工大学李远清教授研究团队通过对 Mu、Beta 节律和 P300 两种脑电范式结合的研究, 实现了一款控制二维光标的脑机接口系统<sup>[19,20]</sup>。2012 年, 以该系统为基础进行改进, 又实现了对轮椅的控制<sup>[21]</sup>。

2011 年, 东南大学徐宝国教授的研究团队将虚拟现实应用于脑机接口系统, 该系统主要应用于脑卒中患者的上肢康复, 对患者进行康复训练的同时给予患者视觉上的反馈<sup>[22]</sup>。

2020 年, 浙江大学求是高等研究院脑机接口团队与浙江大学附属第二医院神经外科合作完成了国内首例侵入式脑机接口临床研究。在一位高位截肢瘫痪患者脑内植入电极, 通过大量的康复训练, 最终实现了通过解析患者脑电信号控制外部机设备的功能, 包括进食、饮水和握手等重要运动功能。

2022 年, 天津大学作为主导单位, 推出一款开源软件平台 MetaBCI 用于脑机接口系统的研究, 该平台能够简化脑电信号处理的流程, 并实现脑电信号自动读取和处理的一体化流程。

## 1.2.2 运动想象脑电信号分类研究现状

准确地理解脑电信号的工作机制是实现脑机接口系统的关键。脑电信号的研究主要包括预处理、特征提取、分类三个部分，其中特征提取和分类最为重要。近年来，运动想象脑电信号的识别分类方法主要有两种：机器学习以及深度学习。下面对这两种方法的研究现状进行介绍。

### (1) 基于机器学习的运动想象脑电信号分类方法

传统的机器学习方法已被广泛应用于识别运动想象脑电信号的研究。首先通过特征提取算法获取脑电信号的特征，然后使用分类算法构建获取的脑电信号特征和实际类别的映射关系，从而达到分类的效果。根据运动想象脑电信号在时域、频域和空域的特征，研究者们也从这三个方面的特征对脑电信号进行研究。

在特征提取方面，运动想象脑电信号的时域特征可以通过使用均值、方差和偏度等特征在不同时间点或不同时间段的时域中提取<sup>[23]</sup>。常见的时域分析方法有短时傅里叶变换(Short-Time Fourier transform, STFT)和小波变换(Wavelet Transform, WT)等<sup>[24]</sup>。因为运动想象脑电信号的频段组成包括  $\alpha$  波中的  $\mu$  节律和  $\beta$  波，所以通过频域分析法能够获得脑电信号频域中的有效信息。常见的频域分析方法有自回归参数模型(Auto Regression, AR)、功率谱密度(Power Spectral Density, PSD)、快速傅里叶变换(Fast Fourier transform, FFT)等<sup>[25-27]</sup>。空域分析法中最具代表性的算法是共空间模式(Common Spatial Pattern, CSP)<sup>[28,29]</sup>，CSP 算法的原理是通过对脑电信号进行空域滤波提取脑电信号多个通道中每一类的空间特征，适用于二分类任务。Pfurtscheller 等人<sup>[30]</sup>在二分类的运动想象脑电信号分类中使用了 CSP 算法，分类准确率都达到了 90%以上。受到 CSP 算法的启发，研究者们对该算法做了系列的改进，并取得了较好的分类效果。

在分类方面，通过对分类器的不断调优并在训练集上训练分类器，以获得最佳的分类器模型，再用测试数据测试模型的性能。常见的分类方法有：K 近邻(K-Nearest Neighbor, KNN)、线性判别分析(Linear Discriminant Analysis, LDA)、支持向量机(Support Vector Machine, SVM)<sup>[31,32]</sup>。2013 年，Kim 等人<sup>[33]</sup>将 CSP 特征提取算法与 LDA 分类算法结合，最终在脑电信号的分类任务中取得了 66.65%的平均分类准确率。2014 年，Gupta 等人<sup>[34]</sup>基于脑电信号类之间和类内的差异性，提出了一种新的基于 L1 范数的主成分分析和 LDA 方法来替代 CSP，取得了良好的效果。2016 年，Tan 等人<sup>[35]</sup>以互信息和分类精度作为评价标准，将极限学习机应用于运动想象脑电信号识别任务中，通过对比实验结果发现。极限学习机相比 LDA 和 SVM 具备更好的性能。2017 年，Isa 等人<sup>[36]</sup>深入研究了 K 近邻法分类器对 EEG 数据的性能分析，实验结果表明，距离度量对 K 近邻精度的显著影响，其中闵氏距离与欧几里德距离相比具有更高的精度。2018 年，Pinheiro 等人<sup>[37]</sup>通过使用快速傅里叶变换(Fast Fourier

Transform, FFT)提取经过带通滤波处理后脑电信号的特征,最后使用人工神经网络(Artificial Neural Network, ANN)进行分类识别,在四类脑电信号识别任务中取得了74.96%的准确率。2019年, Fu 等人<sup>[38]</sup>在 LDA 的基础上改进了一种正则化线性判别(Regularized Linear Discriminant Analysis, RLDA)分类算法,通过与 CSP 算法结合,获得更高的分类精度。2020年, Shi 等人<sup>[39]</sup>通过重定向提取脑电信号的时域特征,以支持向量机作为分类识别算法,取得85.9%的分类准确率。在此基础上,又有许多专家和学者对 SVM 展开研究并分别取得较好的效果。

传统的机器学习方法已经对运动想象脑电信号分类研究做出了很大的改进,但 these 方法依然存在一定的缺陷。首先,脑电信号是非常微弱的电信号,幅值范围为5-300 微伏。所以在采集的过程容易混入其他噪声,比如环境噪声、肌电噪声、眼电噪声等。其次,脑电信号的低信噪比(Signal-to-Noise Ratio, SNR)以及非平稳的特点会导致训练集和测试集中的数据具有差异性。此外,机器学习算法是线性方法,而脑电信号是非线性的,因此机器学习无法很好的解释脑电信号。因此准确理解运动想象 EEG 信号进行分类是极具挑战性的。特征提取很大程度上依赖于先验知识,如果能有一种自动提取特征的方法将会极大的提高运动想象脑电信号的分类研究。

## (2) 基于深度学习的运动想象脑电信号分类方法

随着近年来深度学习(Deep Learning, DL)的发展,为了能自动学习到脑电信号的高维特征,许多学者将深度学习方法应用到运动想象脑电信号的分类研究中。深度学习所有的模块都包含在神经网络内部,是一种端到端的网络结构。深度学习网络模型有效地融合了特征提取模块和分类识别模块,通过在内部不断优化模型参数,从而显著的提高了性能。常用于脑电信号分类深度学习模型包括卷积神经网络(Convolution Neural Network, CNN)和循环神经网络(Recurrent Neural Network, RNN)。

CNN 是深度学习中一种常用的模型,目前已经有大量的研究人员将卷积神经网络用到 EEG 的分类任务中。2018年, Dose 等人<sup>[40]</sup>构建了一种融合脑电信号的时域特征和空域特征的模型,以原始脑电信号作为输入数据,在测试数据上取得了不错的分类效果。2018年, Lawhern 等人<sup>[41]</sup>设计了一种名为 EEGNet 的脑电信号分类模型,解决了传统 EEG 处理方法中需要人工提取特征以及数据处理慢等问题,EEGNet 已经被广泛用于 EEG 数据的分类和预测任务中。2019年, 胡章芳等人<sup>[42]</sup>通过使用短时傅里叶(Short-time Fourier Transform, STFT)获取脑电信号的时频特征,将该特征作为卷积神经网络的输入,并且在 BCI IV 竞赛数据集上取得了不错的效果,达到了86.4%的平均识别率。2019年, Amin 等人<sup>[43]</sup>设计了一种 CNN-MLP/AE 混合模型,脑电信号以二维数组的格式作为网络的输入,并在脑电信号分类任务中取得了不错的识别准确率。2020年, Ingolfsson 等人<sup>[44]</sup>以时间卷积神经网络(Temporal Convolutional Neural Networks, TCN)为基础设计了一种名为 EEG-TCNet 的网络,取得了较好的分

类准确率。2020 年, Santamaria-Vazquez 等人<sup>[45]</sup>设计了一种名为 EEG-Inception 的网络模型, EEG-Inception 是第一个整合 Inception 模型进行脑电信号分类的模型, 并在脑电信号处理任务中取得了较好的效果。2021 年, Musallam 等人<sup>[46]</sup>在 EEG-TCNet 的基础上通过增加线性参数数量设计了一种名为 TCNet-Fusion 的网络, 相比于 EEG-TCNet 网络的分类性能得到了提升。

RNN 擅长从时间序列中提取特征, EEG 是一种一维时间信号, 循环神经网络也被应用于 EEG 的分类任务中。2018 年, Luo 等人<sup>[47]</sup>利用滤波器组共空间模式(Filter Bank Common Spatial Pattern, FBCSP)从 MI-EEG 信号中提取空间频率序列特征作为网络的输入数据, 并使用长短时记忆(Long Short Term Memory Network, LSTM)和门控循环单元(Gated Recurrent Neural Network, GRU)模型对其进行分类, 并证明在运动想象脑电信号分类任务中取得良好的效果。2019 年, Zhang 等人<sup>[48]</sup>通过对 LSTM 和注意力机制的融合, 在运动想象脑电信号分类任务中取得较高的识别效果。2020 年, 王薇<sup>[49]</sup>提出了基于 LSTM 和 GRU 的集成网络使得模型具有良好的鲁棒性。

目前存在大量研究致力于理解运动想象脑电信号, 由于脑电信号的生理机制的复杂性, 如何有效地进行分类研究仍是一项极具挑战性的工作。综上分析, 在脑电信号分类任务中, 机器学习方法需要进行复杂的特征提取过程, 并且在特征提取过程中会造成脑电信号中关键特征的丢失。而深度学习方法具有强大的自学习能力, 避免了复杂的特征提取过程, 可以有效避免机器学习方法中特征提取的工作量。为了避免复杂的特征提取过程, 所以本文将开展基于深度学习的运动想象脑电信号分类研究, 旨在获取一种具有良好分类性能的深度学习模型。

### 1.3 本文主要研究内容

近些年, 对于运动想象脑电信号的分类研究取得了重要进展, 尤其是深度学习方法的引入, 推动了脑机接口性能的飞跃。本文主要应用了基于深度学习的方法对运动想象脑电信号进行分类研究, 主要工作内容概括如下:

(1) 根据运动想象脑电的频率特性, 采用 8Hz-30Hz 的带通滤波器去除与运动想象脑电信号无关的频带; 为了进一步去除噪声和伪迹的干扰, 分别使用了重参考和独立成分分析。并对实验数据进行了时间切分、降采样等处理, 构建了两类手运动想象脑电信号数据集, 用于后续的分类研究。

(2) 研究基于深度学习在运动想象脑电信号分类方法中的应用。分别采用 EEGNet、EEG-Inception 网络模型, 对两类手运动想象脑电信号进行分类。针对 EEGNet、EEG-Inception 模型分类性能不佳的问题, 设计了一种基于卷积神经网络的脑电信号分类模型(CNN-Net), 并对这三种网络模型的实验结果以及现有分类方法进行了对比分析。

(3) 研究注意力机制对 CNN-Net 模型分类性能的影响。主要基于注意力机制能够

强化有用特征并弱化无用特征的特性，在 CNN-Net 分类模型的基础上分别引入了 SENet、ECA、CBAM 注意力机制，旨在使模型得到更理想的分类性能。对比分析了不同注意力机制引入方式对 CNN-Net 分类性能的影响，并对三种注意力机制不同引入方式的实验结果以及现有分类方法进行了对比分析。

## 1.4 本文组织结构

本论文共有五个章节，主要框架如图 1.1 所示，各章节的具体内容概括如下：

第 1 章：首先介绍了运动想象脑电信号的研究背景和研究意义，再介绍了国内外脑机接口技术和运动想象脑电信号的研究现状，最后对本文的主要研究内容以及本文的组织结构做出了说明。

第 2 章：主要介绍了运动想象脑电信号分析的基础理论。包括脑机接口系统的组成部分以及、脑电信号的研究基础、卷积神经网络的组件以及特点。

第 3 章：首先对本文使用的数据集进行了介绍，并对数据的预处理做出了详细说明。通过使用 EEGNet 和 EEG-Inception 两种常用于脑电信号分类的模型与本文提出的 CNN-Net 模型对运动想象脑电信号进行了分类研究。通过对比实验结果以及现有的分类方法，验证了 CNN-Net 模型的有效性。

第 4 章：研究了注意力机制对 CNN-Net 模型分类性能的影响，将不同注意力机制和 CNN-Net 模型融合。研究了不同注意力机制引入方式对模型分类性能的影响，并对结果进行分析。证明了融合注意力机制的 CNN-Net 模型相比于 CNN-Net 模型的分性能得到了进一步的提升。

第 5 章：总结与展望。总结了全文的研究，并对未来的工作进行了展望。

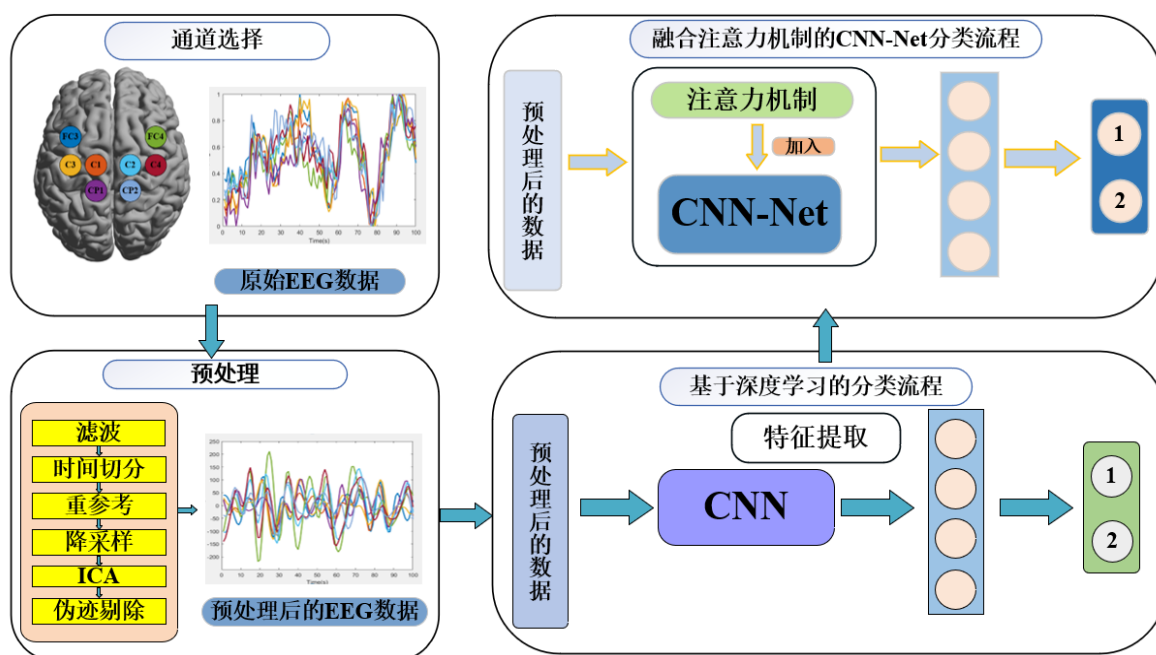


图 1.1 本文整体框架图



## 第 2 章 运动想象脑电信号分析的基础理论

### 2.1 脑机接口系统

#### 2.1.1 脑机接口系统组成

脑机接口系统在大脑和外部设备之间搭建一条不需要真实肢体运动参与的通信渠道，从而实现直接控制外部设备的功能<sup>[50,51]</sup>。这种系统有助于推进大脑生理信息研究，提供设备辅助人们的生活。一个完整的 BCI 系统包含以下 5 个部分：信号采集、信号预处理、特征提取、信号识别和控制指令输出与执行，完整的 BCI 框架如图 2.1 所示。

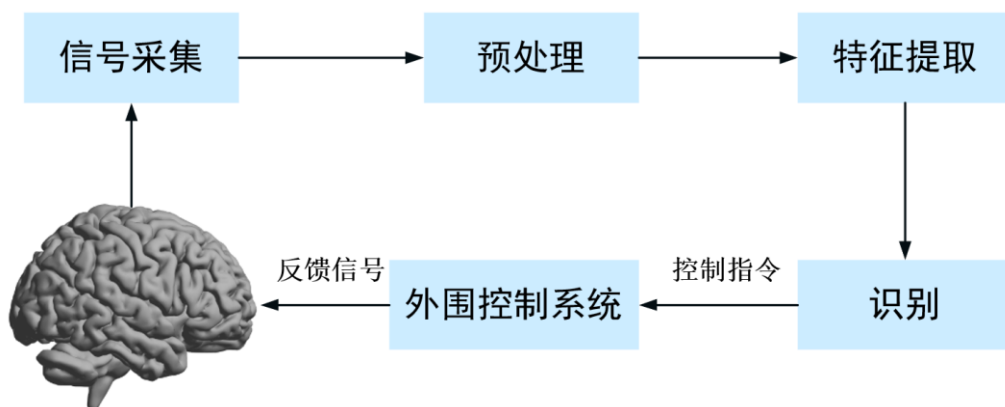


图 2.1 BCI 系统

##### (1) 信号采集和预处理

根据脑电信号采集方式可以将脑电信号分为侵入性信号和非侵入性信号：脑电(Electroencephalogram, EEG)是非侵入性脑电信号，只需将电极放置在大脑皮层采集，具有随机非平稳、信噪比低等特征<sup>[52]</sup>；皮层脑电图(Electrocorticography, ECoG)是通过侵入性脑机接口采集的脑电信号，采集信号的过程中需要将电极植入到大脑皮层。ECoG 具有高空间分辨率和较低噪声水平的优点，并且受到伪迹信号影响的可能性较小，但其侵入性采集方式可能会对人体造成损伤；EEG 容易受到伪迹信号和噪声的干扰，并且空间分辨率较低，但 EEG 采用非侵入性的电极帽进行信号采集，不会对人体产生损伤而且具有良好的时间分辨率。EEG 信号不会对脑部造成损伤，具有采集简便、安全、时间分辨率高、设备要求低廉等优点，因此目前常见的 BCI 系统使用的是 EEG 信号。

由于脑电信号具有随机非平稳的特性，所以在采集的过程中，容易受到周围环境以及受试者自身的影响，原始脑电信号会存在各种生理伪迹，对于采集到原始信号要进行响应的预处理，得到相对平滑的、无噪声的脑电信号。目前比较常见的预

处理方法有以下几种：数字滤波，可以根据脑电信号的频率范围来滤除频率范围以外的无关信号；重参考，改变参考电极的选择或者重新计算参考电极的值，以消除参考电极选择带来的影响或者改变信号的特征。常用的伪迹去除方法有独立成分分析(Independent Components Analysis, ICA)<sup>[53]</sup>、主成分分析(Principal Component Analysis, PCA)<sup>[54]</sup>等。

## (2) 特征提取

通过电极等外部设备采集到的脑电信号通常包含各种伪迹，因此对信号进行预处理是必要的，以使信号更加逼近所要采集的节律信号。然而，直接使用预处理后的信号进行分类控制外部设备通常不能达到所要求的准确度。因此，通常会根据脑电信号的不同节律特性，抽取有用的特征，并将最能体现出该节律信号与其他信号的差异性特征送入分类器。对脑电信号进行特征提取的过程，通常会从时域、频域和空域等三个方面进行考虑。

## (3) 分类识别

经过特征提取之后，需要继续对脑电信号进行分类。脑机接口性能的关键在于分类的准确率，因此需要选用有效的分类方法对脑电信号进行分类。常用机器学习分类方法包括支持向量机和线性判别分析。近年来，得益于深度学习技术的飞速发展，深度学习在脑电信号分类任务的应用也愈发广泛，并取得了较高的分类准确率。

支持向量机是一种典型的监督分类算法，其原理是寻找一个使样本间隔最大化的超平面，最终转化为一个凸二次规划问题来求解，主要用于二分类任务。支持向量机可以解决非线性问题、可以避免神经网络结构选择和局部极小值点问题、可以提高泛化能力、可以解决高维问题。当数据集的样本较少时，支持向量机容易得到样本与特征之间的非线性关系，因此可以处理少量样本的非线性分类问题。然而，在实际应用中，如果遇到数量庞大的复杂计算，支持向量机可能对大规模训练样本难以实施。此外，支持向量机只适用于二分类问题，对于多分类问题需要进行扩展。

线性判别分析是一种典型的有监督机器学习方法，并且它是一种线性方法，它的主要思想是以一种基于降维的方式将数据集中的样本映射到一维坐标轴上，通过设定一个合理的阈值，让同类样本的投影点尽可能接近，异类样本的投影点尽可能远离。线性判别分析的计算效率高、算法容易理解，能对高维度数据进行有效地处理，因此非常适用于 BCI 系统。但是该算法也存在依赖数据、泛化能力弱的问题。

近些年，深度学习领域得到了快速的发展和广泛的应用，尤其是在计算机视觉、自然语言处理等领域。深度学习具有非线性、识别高维度数据特征以及自动提取数据特征的特点，因此也被逐渐应用于 BCI 系统的研究中。卷积神经网络和循环神经网络是目前应用最广泛的深度学习模型，同时，许多研究人员也在这两种模型

的基础上不断探索和改进,提出了基于卷积神经网络和循环神经网络的新模型,并在特定领域中取得了良好的效果。

#### (4) 外部控制设备

脑电信号被送入分类器进行识别,然后将分类结果传送给外部控制系统,控制系统根据识别结果执行相应的动作,比如智能轮椅控制、光标控制以及机械臂操作等<sup>[55]</sup>。通过这种方式,脑机接口可以实现对外部设备的控制,让使用者能够通过意念控制设备,实现更加自然、高效的交互。

### 2.1.2 脑电信号范式种类

脑电信号是由大脑的节律性电活动产生的,这些电活动可以反映出个体的意识和行为状态。根据这些节律的特点,常用的脑电信号分类可以分为以下三种:

#### (1) 稳态视觉诱发电位

诱发电位(Visual Evoked Potential, VEP)是当大脑受到脉冲电流、闪光或者变化的图像、连续的声音刺激时产生的电活动信号。稳态视觉诱发电位(Steady-State Visual Evoked Potentials, SSVEP)是 VEP 的一种,它的原理是:在正常情况下,由于各种神经网络在大脑中分布时具有固有的谐振频率,因此这些神经网络通常是不同步的<sup>[56]</sup>。当在大脑施加一个固定频率的外部视觉刺激时,与刺激频率或谐波频率相匹配的神经网络就会谐振,从而导致大脑的电位活动在刺激频率或谐波频率处出现明显变化,由此产生 SSVEP 信号。SSVEP 具有操作简单、训练时间短、信息传输速率高的特点。

#### (2) P300 信号

事件相关电位(Event Related Potential, ERP)是大脑对来自外界环境的特定的感觉、认知或运动事件等产生的心理反应的测量<sup>[57]</sup>。P300 信号是事件相关电位的一种,产生与大脑进行认知的过程,主要与期待、意动、觉醒、注意等心理因素有关。当大脑受到小概率相关事件的刺激时,脑电信号中会出现一个正向波峰,其潜伏期约为 300 毫秒,因此被称为 P300。通常情况下,认知障碍与 P300 的变化具有较强的相关性,所以该波形可用作评估各种治疗对认知功能效果的指标。因此, P300 在临床研究中有广泛的用途。

#### (3) 运动想象脑电信号

运动想象脑电信号是一种在肢体没有实际运动的情况下,大脑想象着身体部位在运动,在大脑皮层产生对应类别的 EEG 信号<sup>[58]</sup>。当大脑在进行运动想象时,相应的脑区会被激活,导致被激活脑区的血液流量增加并且新陈代谢速度加快。此时大脑皮层通常产生两种不同节律的信号,分别是 8-15Hz 的  $\mu$  节律和 18-24Hz 的  $\beta$  节律。此外,运动想象还会导致大脑对侧运动感觉区的能量下降,而同侧能量上升。

## 2.2 脑电信号基础

### 2.2.1 脑电信号生理基础

大脑是人体最重要的器官，主要由左、右两个大脑半球组成，包含有大量功能复杂的神经元，控制着人的语言、认知、情感和运动等各项神经活动<sup>[59]</sup>。每个半球的大脑皮质分为四种不同的叶区，分别为额叶、顶叶、颞叶和枕叶，如图 2.2 所示。额叶，位于中央沟前，具有推理和决策等复杂的心理功能，还负责计划与执行运动的任务。顶叶，位于中央沟后，负责处理身体的触觉信息以及整合不同类型的感觉信息，以产生空间意识。颞叶，在脑的两侧，负责听觉和短时记忆。枕叶，位于脑的后端，负责处理和解读视觉信息。




图 2.2 大脑结构<sup>[59]</sup>

德国科学家 Hans Berger 在 1924 年首先检测脑电信号的存在，并命名为脑电图。自此以后，脑电波才被人们所认识，有关研究也越来越深入。脑电信号是指大脑神经元的电活动产生的电信号。当神经元被激活时，会产生电信号，这些信号可以相互影响并产生复杂的脑电信号。通过测量脑电信号，可以研究大脑的结构和功能，并帮助诊断和治疗神经系统疾病。

脑电信号不同于其他生物电信号，具有以下特点：

1、脑电信号幅值微弱且信噪比较低。因为脑电信号的幅值是微伏数量级，所以在采集过程中容易受到外部噪声和内部噪声的干扰。外部噪声主要是脑电采集设备使用过程中产生的 50Hz 的干扰信号以及环境噪声，内部噪声主要是采集过程中受试者的肌电、眼电、心电等生理信号。加上噪声信号的幅值往往大于真实脑电信号的幅值，使得原始信号可能会被噪声信号覆盖。

2、脑电信号随机且非平稳。脑电信号具有时变信号的特点，能时刻反映大脑对当前状态的感知，呈现出显著的随机性特征。脑电信号会随着被试者的心理状态以及情绪状态的变化，表现出突发性的瞬时状态。当脑电信号中存在外界环境干扰时，脑电信号表现出非平稳性以及随机性。

3、脑电信号是非线性信号。人脑包含了大量的神经元，一次生理动作需要大量的神经元协调工作，同一时间，位于不同脑区的神经元还需要相对独立的完成相应的任务。生物组织电生理信号的调节会受到其自调节和自适应的影响，因此脑电信号呈现出非线性的特性。

4、脑电信号具有个体差异性。容易受到个体精神状态、健康状况、所处的环境、个人情绪等因素的影响，相同的个体在不同的环境下，脑电信号也会呈现不同状态。考虑个体间脑电信号的差异性，脑电信号分类算法应当具备良好的泛化性和自适应性。

## 2.2.2 事件相关同步/去同步现象

运动想象脑电信号是指人们想象肢体(或肌肉)的运动，却没有真实的运动输出，激活了脑区中的特定区域，从而产生与其他活动不同的特有的脑电信号。运动想象脑电信号具有时间相关同步和事件相关去同步两个重要的特征。事件相关同步的具体表现为：当身体的一侧在准备和执行运动时，身体运动的同侧感觉运动皮质脑电信号中的  $\alpha$  频段(8-12Hz)和  $\beta$  频段(13-30Hz)出现振幅增加的变化，这种变化被称为事件相关同步(Event-Related Synchronization, ERS)。与此同时，对侧感觉运动皮质脑电信号中的  $\alpha$  频段(8-12Hz)和  $\beta$  频段(13-30Hz)出现振幅降低的变化，这种变化被称为事件相关去同步(Event-Related Desynchronization, ERD)<sup>[60]</sup>。由于个体之间具有差异性，所以不同受试者产生的运动想象脑电相关 ERS 和 ERD 现象也不同。ERS 和 ERD 现象的计算公式，如式(2.1)所示。

$$\frac{ERD}{ERS} = \frac{E - R}{R} \times 100\% \quad (2.1)$$

E 表示运动想象后特定频率范围内脑电信号的能量值，R 表示运动想象前特定频率范围内脑电信号的能量值。通过分析公式，可以看出当结果为正值时，表明运动想象后特定频率范围内脑电信号的能量值增加了，发生了 ERS 现象；当结果为负值时，则发生的是 ERD 现象；当结果为 0 时，表明前后能量值不变，则 ERS 现象和 ERD 现象都没有发生。

因为不同的动作之间在脑区的神经信号具有差异性，不同情况的运动想象任务在大脑不同区域会出现频段的变化，正是基于这一特性，才能对运动想象脑电信号进行了分析和识别，进而获得了想象中运动类别信息。

## 2.3 卷积神经网络基本原理

卷积神经网络(Convolutional Neural Network, CNN)是深度学习中一种常见的深层前馈神经网络<sup>[61]</sup>，具有局部连接、权值共享等特点。近年来，CNN 被广泛应用到自然语言处理、神经信号处理、图像处理等领域中，并且效果有了显著的提升，是目前应用最广泛的模型之一。CNN 的结构使得其具有良好的空间特征学习能力。一

个典型的卷积神经网络通常由 5 部分组成，包括输入层(Input Layer)、卷积层(Convolutional Layer)、池化层(Pooling Layer)、全连接层(Fully Connected Layer)和输出层(Output Layer)<sup>[62]</sup>，CNN 结构如图 2.3 所示。

CNN 通过卷积层、池化层和全连接层等组件构建出完整的模型，实现从输入数据中提取出高级特征，并将提取的抽象特征映射到分类任务。CNN 模型使用前向传播(Forward Propagation, FP)进行数据处理，通过损失函数(Loss Function)计算出预测值与真实值之间的偏差。通过反向传播(Back Propagation, BP)算法更新网络每层的参数<sup>[63]</sup>。FP 和 BP 反复交替进行，直到损失趋于稳定，即网络收敛。

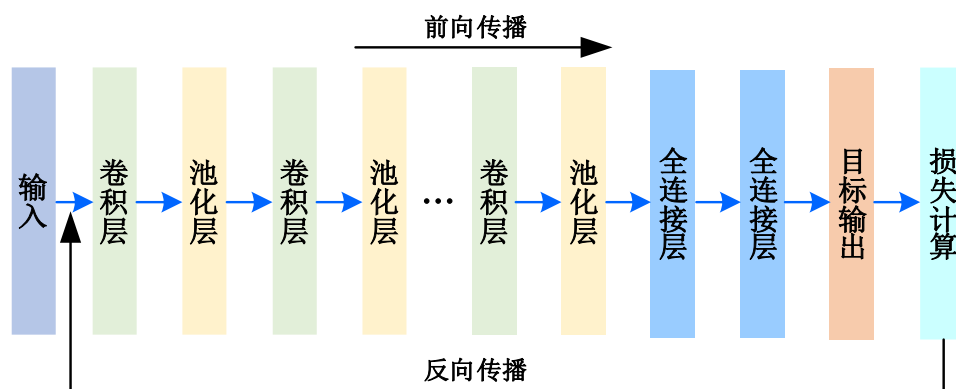


图 2.3 卷积神经网络基本构成

### 2.3.1 卷积神经网络构成

#### (1) 输入层

输入层作为整个网络模型第一层，负责接收数据并将其转化为网络可以处理的形式。通常会将预处理(归一化、正则化等)之后的数据作为网络的输入数据，来提高模型的训练效率。输入数据格式为图像时，可以使用二维数组表示图像的长度和宽度，也可以使用三维数组表示图像，其中第三维表示图像的 RGB 通道。对于脑电信号的输入，通常使用一维数组或者二维数组表示，一维数组是将单个通道信号作为输入，二维数组是将脑电信号作为二维图像的形式输入，长度代表通道信号采样点的数量，宽度代表通道数量。

#### (2) 卷积层

卷积层是神经网络的关键部分，主要功能用来提取特征，原理是在输入数据上滑动一个固定大小的卷积核，对输入数据进行特征提取和转换。卷积运算可以有效地提取输入数据的局部特征，并保留特征的空间关系。卷积层通常会设置多个卷积核，可以从同一数据中提取多个不同的特征图，从而更好地学习到数据的特征。卷积核尺寸决定了卷积层从输入数据中提取的特征的大小和形状。在实际应用中，卷积核的大小通常需要根据具体任务的需求和数据的特点来确定。二维卷积的过程就是卷积核在特征图上以设置好的固定步长进行滑动，同时在特征图上与卷积核对应

的位置上进行内积运算，就得到输出特征图。其过程如图 2.4 所示。




图 2.4 卷积计算过程

### (3) 池化层

池化层是深度学习中常用的一种层次结构，用于降低卷积神经网络中卷积层输出特征的维度。池化相当于对图像的压缩，减小特征图尺寸的同时也提取了主要特征，有助于减小特征图中的噪声和冗余信息，同时也可以提高模型的鲁棒性和泛化能力。池化能减小神经元的感受野，让模型捕捉更加局部的特征，从而让网络学习到更抽象的、高层次的特征。池化能保证图像的平移和旋转不变性，从而对二维图像进行有效地处理。常见的池化方式有两种，平均池化和最大池化。平均池化输出池化窗口中特征图的均值。最大池化输出池化窗口中特征图的最大值。其过程如图 2.5 所示。

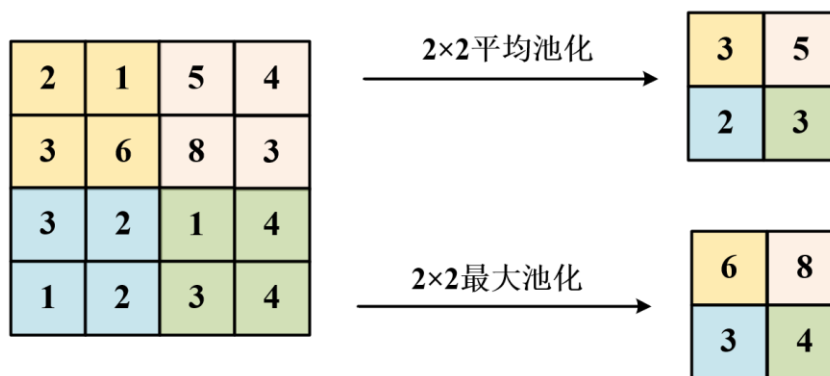


图 2.5 平均池化与最大池化过程

### (4) 全连接层

全连接层通常会在卷积层或池化层之后使用，将卷积层或池化层输出的特征图展平成一个一维向量，并将其映射到更高层次的特征表示空间，从而进行分类或回归等任务。在全连接层中，每一个神经元都与上一层的所有神经元都有连接，每个连接都有一个权重，这些权重构成了全连接层的参数。全连接层结构如图 2.6 所示。






图 2.6 全连接层模型

### (5) 输出层

输出层是神经网络的最后一层，它的作用是将前面层的计算结果转化为模型输出。输出层通常使用 **Softmax** 函数来将模型的输出转换为概率分布，每个输出节点对应一个类别，输出节点的值表示样本属于该类别的概率。

## 2.3.2 激活函数和优化算法

激活函数和优化算法是神经网络中的重要组成部分，激活函数赋予网络表达非线性问题的能力，优化算法可以提高网络的训练效率，下面分别对激活函数和优化算法进行说明。

### (1) 激活函数

激活函数是神经网络能够解释非线性关系的原因，激活函数的主要作用是对卷积层的输出特征图进行一次非线性映射，从而赋予了神经网络解释非线性关系的能力。卷积层的卷积操作线性的，因而每次卷积的输出都是一个线性的结果，无法很好的解释非线性关系。激活函数通常应用于卷积层当中，对卷积层提取的特征进行非线性映射，这种非线性映射可以使神经网络更好地学习和表示复杂的特征，从而提高模型的性能。常见的激活函数有 **Sigmoid** 函数、**Tanh** 函数和 **Relu** 函数，函数表示式如式(2.2)到式(2.4)所示，函数示意图如图 2.7 所示。

$$\text{Sigmoid: } f(x) = \frac{1}{1 + e^{-x}} \quad (2.2)$$

$$\text{Tanh: } f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.3)$$

$$\text{Relu: } f(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (2.4)$$




图 2.7 Sigmoid 函数、Tanh 函数、Relu 函数



## (2) 优化算法

优化算法是深度学习中一个重要参数，一个好的优化算法在训练模型的过程中极其重要。在训练过程中，如果没有选择好优化算法，可能会出现网络收敛速度过慢、损失函数值偏大、甚至网络不收敛等情况，而导致网络没有提取到数据的有效特征，因此选择一个好的优化算法是获取到理想模型的关键。

常见的优化算法有 SGD、AdaGrad、RMSProp 和 Adam 等。AdaGrad 算法擅长处理稀疏梯度，而 RMSProp 算法擅长处理非平稳目标。Adam 优化算法是最常用的优化算法，Adam 兼顾了 AdaGrad 和 RMSProp 两种算法的优点。实现起来较为简单，对内存的需求较少，计算速度较快。Adam 算法还有一个更重要的优点，可以自适应地调整每个参数的学习率，从而有区分度地学习不同参数。传统的随机梯度下降算法在训练模型的过程中学习率不会改变，Adam 算法很好的解决了这个问题，在训练过程中使用 Adam 算法作为优化算法，学习率会随参数的更新而更新，自适应地学习好训练参数，从而训练出更好的模型。Adam 为不同的参数调整最佳的自适应性学习率主要通过计算梯度的一阶矩估计和二阶矩估计。

具体来说，Adam 算法在每个迭代步骤中执行以下步骤：

- 1、计算梯度：计算当前参数向量的梯度。
- 2、更新动量项：根据上一个时间步骤的动量项和当前梯度来更新当前动量项。
- 3、计算一阶矩估计：计算当前参数向量梯度的一阶矩估计，即平均梯度。
- 4、计算二阶矩估计：计算当前参数向量梯度的二阶矩估计，即平均梯度的平方。
- 5、根据一阶和二阶矩估计更新参数：根据一阶和二阶矩估计来更新当前参数向量的值。

Adam 算法的公式如式(2.5)到式(2.9)所示：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (2.5)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (2.6)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (2.7)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (2.8)$$

$$\theta_t = \theta_{t-1} - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (2.9)$$

其中， $g_t$ 是当前参数向量的梯度， $\beta_1$ 和 $\beta_2$ 是超参数，通常取 0.9 和 0.999，分别用于计算动量项和二阶矩估计。 $m_t$ 和 $v_t$ 分别是动量项和二阶矩估计的历史累加量， $\hat{m}_t$ 和 $\hat{v}_t$ 是对 $m_t$ 和 $v_t$ 做偏差校正的估计量， $\theta_t$ 是当前迭代的时间步骤， $\eta$ 是学习率， $\epsilon$ 是为了数值稳定性而添加的小常数。

### 2.3.3 卷积神经网络的特点

CNN 能实现端到端的学习，避免了复杂的特征提取过程，并且具有局部连接、权值共享和 Dropout 等特点，使得 CNN 在处理图像等大规模数据时具有出色的表现，下面分别阐述这些特点。

#### (1) 局部连接

局部连接的原理是每一层卷积层中的神经元只和上一层网络的部分神经元是连接的，这种连接方式可以让神经网络只学习到局部特征。局部连接如图 2.8 所示。局部连接通常用于处理图像和视频等高维输入数据，因为这些数据通常具有局部相关性和空间结构，这意味着每个像素或像素组的值可能受到其周围像素或像素组的影响。通过使用局部连接，神经网络可以更好地利用这种结构，并在处理高维数据时具有更高的效率和准确性。局部连接神经网络的参数数量更少，因此更容易训练，并且可以处理更大的输入数据。因此，局部连接在深度学习中被广泛应用，并成为了许多先进神经网络的基础。




图 2.8 局部连接

#### (2) 权值共享

权值共享是一种神经网络的设计技术，通过共享一组特征(例如相邻的像素)的权重参数，来减少模型的复杂度和参数数量。权值共享如图 2.9 所示。权值共享具有平移不变性的优点，在输入数据中进行平移操作时，共享相同权重的神经元输出不变。平移不变性是神经网络应用于图像处理任务中的一个重要优点，可以提高网络的泛化能力，使其对于不同位置的图像输入具有更好的鲁棒性。




图 2.9 权值共享

### (3) Dropout

**Dropout** 是一种正则化技术，通过在训练过程中，随机将一些神经元的输出置为 0，从而强制网络去学习多个互相独立的子模型，而不是依赖于某些神经元的特定权重，从而避免神经网络过拟合。图 2.10 展示了普通神经网络和使用 **Dropout** 的神经网络。**Dropout** 可以有效地减少神经网络的过拟合，同时还可以使得网络具有更好的泛化性能。因为它可以使得网络的每个神经元都变得更加独立，从而避免了某些神经元在某些输入上过度适应，导致网络的过拟合。此外，**Dropout** 还可以防止梯度消失问题，增加网络的鲁棒性。




图 2.10 普通神经网络和使用 Dropout 的神经网络对比

## 2.4 本章小结

本章首先介绍了脑机接口系统的组成部分以及不同的采集范式的脑电信号，随后介绍了大脑的组成和脑电信号的特点，包括相关的运动想象脑电信号 ERS/ERD 想象。并介绍了卷积神经网络的构成组件以及特点。

## 第3章 基于深度学习的运动想象 EEG 分类研究

### 3.1 引言

第二章主要介绍了本文研究的理论基础。以第二章的理论为基础，本章将对两类手运动想象脑电信号进行分类研究。本章首先介绍了本文使用的数据集并对数据预处理进行了详细介绍，设计使用了 EEGNet 和 EEG-Inception 两种常见的脑电分类模型对本文使用的数据集进行了分类研究，针对 EEGNet 和 EEG-Inception 分类性能的不足，提出了一种基于卷积神经网络的分类模型(CNN-Net)进行分类研究，并对对比分析了实验结果，实验流程如图 3.1 所示。

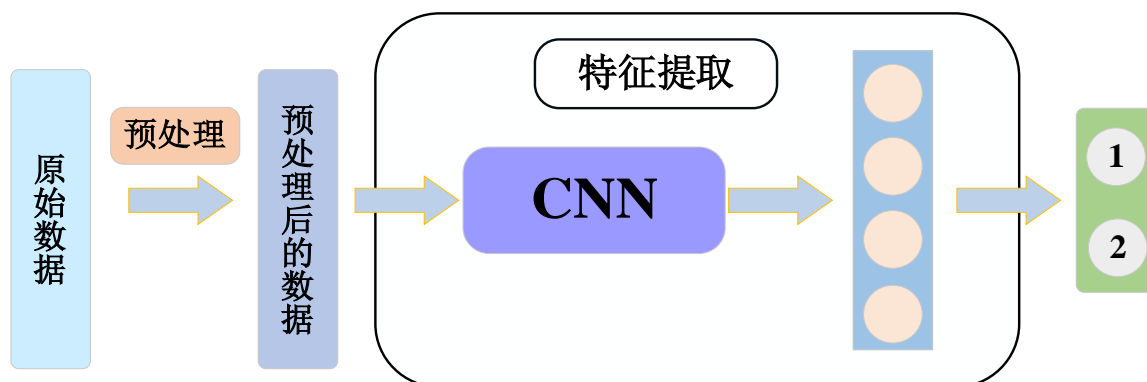


图 3.1 EEG 信号分类流程

### 3.2 实验数据介绍与预处理

#### 3.2.1 实验数据介绍

本文使用的数据集是由韩国韩东国际大学和美国北卡罗来纳大学教堂山分校联合采集的公开数据集，命名为 GIGA<sup>[64]</sup>。GIGA 数据集共包括 52 名(33 名男性、19 名女性，平均年龄 $\pm$ 标准差年龄=24.8 $\pm$ 3.86 岁)健康受试者的左手和右手运动想象任务的脑电图记录。除了受试者 S20 和 S33 是左利手以外，其他受试者都是右利手。在采样频率为 512Hz 的情况下使用 64 个 Ag/AgCl 活性电极采集 EEG 数据。以国际 10-10 系统为标准放置电极，如图 3.2(a)所示。记录每名受试者的 100 次或者 120 次与任务相关(左手和右手)运动想象脑电信号的试验。在开始运动想象实验之前，受试者坐在一张有扶手的椅子上，观看监视器。每次试验开始时，监护仪都会显示一个带有固定十字架的黑屏，持续 2 秒；然后，受试者准备好进行想象手部动作(一旦黑屏向受试者发出准备就绪的信号)。想象左手运动和想象右手运动指令在屏幕上随机显示，受试者收到指令后做出与指令对应的手运动想象。当运动想象完成后，当空白屏幕再次出现时，受试者被随机休息 4.1 至 4.8 秒。这些过

程对于一类任务重复 100 次或者 120 次。具体实验范式如图 3.2(b)所示。




图 3.2 导联标准示意图与实验范式图<sup>[64]</sup>

### 3.2.2 实验数据预处理

GIGA 数据集提供的运动想象脑电信号是较为原始的数据集，采集过程中会受到外界环境和自身的干扰，可能包含环境噪声、眼电及心电等伪迹，从而影响信号的质量。脑电信号的预处理就是为了尽可能的减轻伪迹对原始信号的影响。通常要经过滤波、重参考、时间切分、伪迹剔除等步骤。脑电信号预处理流程如图 3.3 所示。

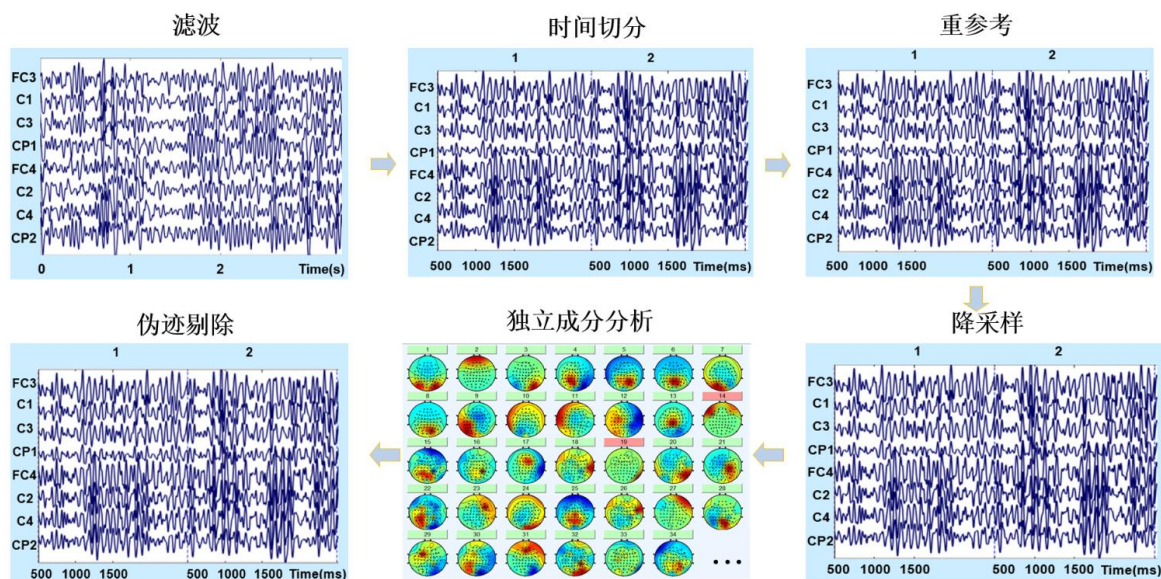


图 3.3 脑电信号预处理流程

#### (1) 带通滤波

运动想象左手和右手的脑电信号有关频段集中在 8-12Hz 和 12-30Hz，必须去除这两个频段以外的全部信号。本文选择 IIR(Infinite Impulse Response)滤波器对原始脑电信号进行 8Hz 到 30Hz 的带通滤波处理，保留与运动想象相关性高的频段<sup>[65]</sup>。

IIR 滤波器是一种数字滤波器，具有无限长的冲激响应。由于它的输出是当前和前面的输入值的线性组合因此又称为递归滤波器，并且具有无限脉冲响应的特征。

IIR 滤波器的差分方程如式(3.1)所示：



$$y(n) = \sum_{i=1}^N b_i x(n-i) - \sum_{i=1}^M a_i y(n-i) \quad n \geq 0 \quad (3.1)$$

$x(n)$ 表示输入序列， $y(n)$ 表示输出序列， $a_i$ 、 $b_i$ 表示滤波器系数， $N$ 表示滤波器的阶数，系统函数如式(3.2)所示：

$$H(z) = \frac{Y(z)}{X(z)} = \frac{\sum_{k=0}^M b_k \cdot z^{-k}}{1 - \sum_{k=1}^N a_k \cdot z^{-k}} \quad (3.2)$$

可以看出 IIR 数字滤波器具有以下特点：

1、IIR 数字滤波器计算复杂度比较低，并且具有记忆性，适合脑电这种时间序列信号；

2、IIR 滤波器相比于 FIR 滤波器可以使用较少的滤波器系数实现更高阶的滤波器特性。




图 3.4 滤波前后的脑电信号

图 3.4 是经过带通滤波前后的脑电信号图，分析对比以上图可以知道，带通滤波处理后脑电信号的质量得到了明显的改善，信号经过带通滤波之后，减少了原始 EEG 信号中与运动想象无关成分的频带，眼电伪迹也得到了改善，有利于后续的特征提取与分类任务的进行。

## (2) 时间切分

采集脑电信号时，开始和结束的脑电信号可能和运动想象的相关性不大。因为受试者收到运动想象的指令时，需要经过一定的思考时间，才开始进行运动想象。在运动想象的过程中，能持续的时间不长，为了保留与运动想象相关性最高的脑电信号，截取每次运动想象的[0.5s, 2.5s]这一区间<sup>[66]</sup>，从受试者收到运动想象指令后的 0.5s 到 2.5s 作为实验数据，如图 3.5 所示。

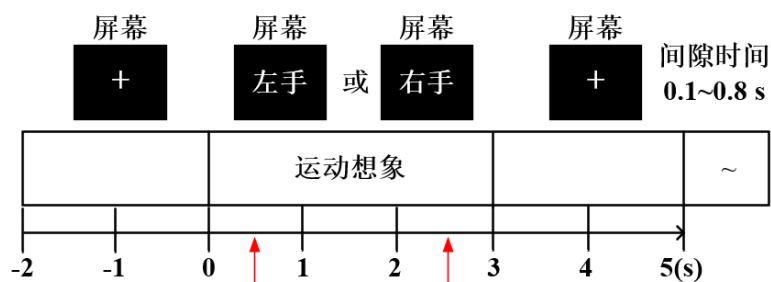


图 3.5 单次试验时间切分

### (3) 重参考

重参考是一个参考通道转换为另一个参考通道的过程。虽然带通滤波可以剔除与运动想象无关的频带，却无法消除频率相近且通道相关性较强的噪声信号，因此常用重参考在空域上对 EEG 进行预处理。本文选择全局平均参考(Common Average Reference, CAR)对脑电信号进行处理。具体而言，全局平均参考首先计算出所有通道信号的平均值再让所有通道信号减去计算出来的平均值，每个通道信号得到更新来消除噪声的影响。

### (4) 降采样

原始脑电信号的采样频率为 512Hz，在截取了每次运动想象的[0.5s, 2.5s]这一区间的脑电信号后，每次运动想象脑电信号共有 1024 个时间采样点，如果直接以 1024 个采样点的数据作为网络的训练数据会造成数据运算量大、训练时间长、模型收敛慢等问题，所以本文对重参考之后的脑电数据进行了降采样处理，频率由 512Hz 降为 256Hz，降采样之后的每次运动想象脑电信号有 512 个采样点。

### (5) 伪迹剔除

原始脑电信号经过带通滤波和重参考后，信号中还包含肌电、眼电以及心电等伪迹，独立成分分析(ICA)在脑电信号伪迹的去除可以取得很好的效果，因此本文选择 ICA 对滤波和重参考后的脑电信号进行伪迹的去除。

ICA 算法能够从多维统计数据中检测出未知的成分，其原理概述如下：假设有  $n$  个混合信号源  $X$  和  $n$  个独立信号  $S$ ，并且每个混合信号都和  $n$  个独立信号线性相关，则有  $X=AS$ ，因此可以推出  $S=WX$ ， $W=A^{-1}$ 。对于每个混合信号，可以取得  $m$  个样本，则有  $n*m$  的样本输出矩阵产生。各个信号源相互独立且不相干，因此得到其概率密度为：

$$P_S(s) = \prod_{i=1}^n P_{S_i}(s_i) \quad (3.3)$$

通过上式  $S=WX$  可以计算出其概率密度为：

$$P_X(x) = F_X(x) = |W| * \prod_{i=1}^n P_{S_i}(W^T x_i) \quad (3.4)$$

假设有  $m$  个样本，则由其概率密度可以得到所有样本的似然函数  $L$  为：

$$L = \prod_{i=1}^m (|W| * \prod_{j=1}^n P_{S_j}(W_i^T x_i)) \quad (3.5)$$

对样本似然函数  $L$  取对数可得：

$$\ln L = \sum_{i=1}^m (\sum_{j=1}^n \ln P_{S_j}(W_j^T x_i) + m \ln |W|) \quad (3.6)$$

得到对数函数之后，通过无监督梯度下降法用似然函数求出对数迭代更新收敛的阈值，能够得到概率最大参数 $W$ ，就可以利用 $W$ 恢复出独立的成分 $s^{(i)}$ ，计算原理如式(3.7)所示。ICA 算法流程如图 3.6 所示。

$$s^{(i)} = Wx^{(i)} \quad (3.7)$$

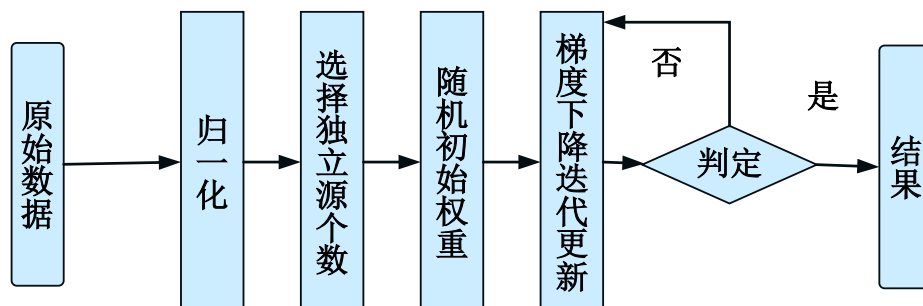


图 3.6 ICA 算法流程

对降采样之后的脑电信号进行 ICA 算法处理并去除了伪迹。图 3.7 是原始脑电信号经过滤波后和伪迹剔除后的脑电信号对比，从图中可以看出经过 ICA 处理后的波形更加光滑，信号质量更好，有利于后续的特征提取与分类任务的进行。

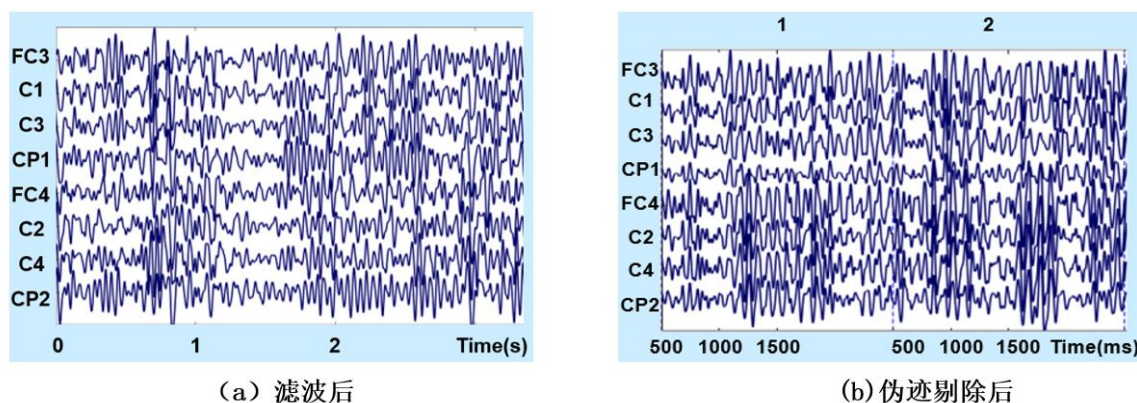


图 3.7 滤波后和伪迹剔除后的脑电信号对比

## (6) 数据集构建

经过上述预处理之后，单次运动想象任务包含 512 个时间采样点。Lun 等人<sup>[67]</sup>研究只使用两个通道信号对分类性能的影响，该研究表明如果只输入两个通道的脑电信号进行分类研究时，通道对信号的准确率由高到低依次为 FC3-FC4、C1-C2、CP1-CP2、C3-C4。考虑到运动想象脑电信号分类识别的算法，目的是部署到脑机接口设备中，如果使用较小的数据规模就能得到较好的效果，那么对于模型落地到实际应用会有很大帮助。所以本文选取 64 个通道中和运动想象相关性最高的 4 个通道对信号 FC3-FC4、C1-C2、CP1-CP2、C3-C4 共 8 个通道的脑电信号进行分类研究，减小数据规模的同时，也提高了数据的相关性，同时对数据进行了归一化处理。并以 FC3-FC4 通道信号为基础，按照分类准确率由高到低的原则，逐次累加 C1-C2、CP1-CP2、C3-C4 通道信号，探究通道数量对于分类性能的影响。2 通道代表 FC3-FC4 通道信号，4 通道代表 FC3-FC4、C1-C2 通道脑电信号，6 通道使用 FC3-FC4、C1-C2、




CP1-CP2, 8 通道代表 FC3-FC4、C1-C2、CP1-CP2、C3-C4 通道脑电信号。

构建一个高效通用的神经网络需要将原始数据集合理的划分为训练集、验证集和测试集。深度学习中数据集的划分,通常还会在训练集中划分出一部分数据集充当验证集,验证集可以有效防止训练过程中模型过拟合。为了减轻模型的训练负担,同时保证数据样本的完整性,随机选取每名受试者 80 次想象左手运动和 80 次想象右手运动的脑电信号数据作为本文的数据集,单个受试者一共 160 个运动想象脑电信号样本,有 52 名受试者,所以数据集总共包含 8320 个样本。将数据集随机划分为训练集和测试集,其中训练集和测试集的比例分别为 80%、20%,并且从训练集中划分出 25% 的数据充当验证集。训练集、验证集和测试集的比例为 60%: 20%: 20%,这样可以保证所有的样本都参与过模型的训练与测试,避免了偶然性,从而可以得到稳定可靠的模型。本文使用独热编码对目标类别进行标注,其中[1, 0]表示想象左手运动, [0, 1]表示想象右手运动。

### 3.3 基于 EEGNet 的运动想象 EEG 分类研究

EEGNet 是一种基于卷积神经网络的脑电分类模型,其设计旨在解决传统的 EEG 处理方法存在的一些缺陷<sup>[41]</sup>,例如需要人工提取特征,对数据的处理速度较慢等问题。它利用了 CNN 在图像处理中的良好性能,将输入的 EEG 数据看作时间序列,通过一系列的卷积层、池化层和批归一化层来提取特征,并通过全连接层进行分类。

EEGNet 已经被广泛应用于 EEG 数据的分类和预测任务中,例如癫痫发作的检测、脑机接口技术等领域。其网络模型结构如图 3.8 所示,主要包含三部分,第一部分包含两个卷积操作,第二部分包含深度可分离卷积操作,最后应用 Softmax 分类层输出分类结果。



在时间卷积模块中,按顺序执行两个卷积步骤。对于输入信号使用了 8 个  $1 \times 64$

的二维卷积核进行卷积，得到了8个不同带通频率大小的特征图，对特征图进行线性激活，之后再连接一个 BatchNorm 层。

在深度分离卷积模块中，首先使用2组16个大小为  $N \times 1$  的卷积核对所有通道信号进行深度卷积，再使用一个 BatchNorm 层对数据进行批归一化处理，并使用 ELU 函数进行非线性激活，之后使用一个大小为  $1 \times 4$  的二维平均池化层，最后连接一个失活率为25%的 Dropout 层。再使用1组16个大小为  $1 \times 16$  的卷积核输出特征在时域上进行分离卷积，并通过16个大小为  $1 \times 1$  的卷积核提取到的通道特征进行融合，同时使用线性激活函数，连接一个 BatchNorm 层，并采取 ELU 函数进行非线性激活，特征图经过一个  $1 \times 8$  的二维平均池化层降低维度，最后连接一个失活率为25%的 Dropout 层。

输出模块中输出脑电信号分类结果，使用 Softmax 进行分类。

### 3.3.1 实验环境与评价指标

#### (1) 实验环境

硬件环境：处理器为英特尔 Core i7-10700，内存为32G，显卡为英伟达 GeForce RTX 3060，显存为16GB，固态硬盘容量为1.5TB。

软件环境：操作系统为 Ubuntu 16.04 64 位，开发环境为 Tensorflow 2.4，编程语言为 Python 3.6，编辑器为 PyCharm 2020。

#### (2) 评价指标

对于本文运动想象脑电信号分类模型分类性能的优劣主要可以使用准确率 (Accuracy) 来衡量，也可以同时参考精确率 (precision)、召回率 (recall) 和 F1-score 等指标来综合判断模型的性能，指标的计算公式分别如式(3.8)到式(3.11)所示：

$$Accuracy = \frac{\sum_{i=1}^N TP_i}{\sum_{i=1}^N (TP_i + FP_i)} = \frac{\sum_{i=1}^N TP_i}{\sum_{i=1}^N (TP_i + FN_i)} \quad (3.8)$$

$$Precision = \frac{1}{N} \sum_{i=1}^N \frac{TP_i}{TP_i + FP_i} \quad (3.9)$$

$$Recall = \frac{1}{N} \sum_{i=1}^N \frac{TP_i}{TP_i + FN_i} \quad (3.10)$$

$$F1 = \frac{1}{N} \sum_{i=1}^N \frac{2TP_i}{2TP_i + FP_i + FN_i} \quad (3.11)$$

其中  $N$  表示分类的类别总数， $TP$  表示真阳性数， $TP_i$  表示实际为  $i$  类的样本被预测为  $i$  类的数； $FP$  表示假阳性数， $FP_i$  表示实际为  $i$  类的样本被误判为除  $i$  类外的类别的样本数； $FN$  表示假阴性数， $FN_i$  表示实际为其它类别的样本被误判为  $i$  类的样本数， $\sum_{i=1}^N (TP_i + FP_i)$  和  $\sum_{i=1}^N (TP_i + FN_i)$  表示数据集中样本的总数。

### 3.3.2 实验结果与分析

本节使用 EEGNet 模型，优化算法为 Adam，学习率设置为 0.0005，Batch Size 设置为 64。输入的数据格式为  $N \times 512$ ，其中  $N$  为通道数量，512 为单次实验脑电信号的时间采样点数量。分别使用数据集中 2 通道、4 通道、6 通道、8 通道信号进行训练，并在测试集中进行了 8 次预测实验，实验结果如表 3.1 所示，图 3.9 可视化展示了该结果。

表 3.1 EEGNet 在不同通道组合下的分类准确率

试验编号	2 通道	4 通道	6 通道	8 通道
1	52.52%	64.18%	51.50%	80.11%
2	55.83%	66.76%	71.81%	80.04%
3	52.16%	63.64%	75.42%	59.25%
4	66.76%	56.49%	69.35%	77.76%
5	55.62%	67.01%	67.18%	77.34%
6	58.16%	63.11%	67.48%	73.19%
7	62.13%	60.99%	65.86%	58.35%
8	59.15%	64.59%	70.51%	76.85%
平均值	57.79%	63.35%	67.39%	72.86%




图 3.9 EEGNet 在不同通道组合下的分类准确率

从图 3.9 中可以看出 EEGNet 模型，随着通道数量的增加，模型的平均分类准确率呈现上升趋势。在 2 通道、4 通道、6 通道、8 通道的情况下，平均的分类准确率分别为 57.79%、63.35%、67.39%、72.86%，其中 8 通道下的分类效果最好。单次试验中，2 通道、4 通道、6 通道、8 通道的最高分类准确率分别为 66.76%、67.01%、75.42%、80.11%。总体上看，EEGNet 模型的分类效果还不够理想，分类性能还有待提升。因为 EEGNet 模型是一种紧凑型的卷积神经网络，卷积层数量较少。由于卷积层的数量较少，EEGNet 无法从输入信号中提取足够丰富、高质量的特征，从而导致

分类性能下降。并且 EEGNet 的参数数量相对较少，会导致模型的容量不足，无法捕捉数据集中的复杂特征以及对数据整体的建模，从而导致分类性能下降。可以通过增加卷积层的数量和深度以及增加模型的参数数量来提高模型的特征提取能力，从而达到更好的分类效果。

### 3.4 基于 EEG-Inception 的运动想象 EEG 分类研究

EEG-Inception 是一种基于深度学习的神经网络模型<sup>[45]</sup>，专门用于处理脑电信号数据。它是从 Inception 网络中借鉴了一些思想，以改进 EEG 信号分类任务而开发的。该模型的目标是在 EEG 数据中自动提取特征，并将其映射到正确的分类标签上。

EEG-Inception 网络结构上包含了 2 个 Inception 模块后接了两个卷积层，最后全连接层进行分类。其结构如图 3.10 所示。

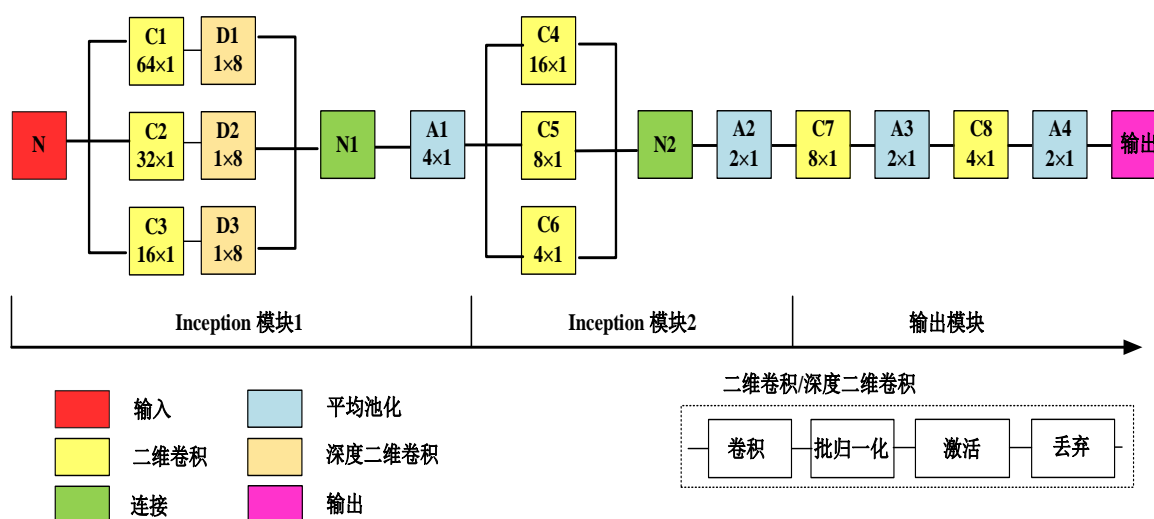


图 3.10 EEG-Inception 网络结构

第一个 Inception 模块通过使用三个卷积核 C1、C2 和 C3 大小分别为  $64 \times 1$ ， $32 \times 1$  和  $16 \times 1$ ，提取出三种脑电信号在时域上的特征。输入脑电信号的采样率为 256Hz，使用 D1、D2 和 D3 卷积层在通道维度上对脑电信号进行深度卷积。再将不同卷积的输出特征图拼接，使用平均池化降低特征图维度，减少训练参数，提高模型训练速度。

第二个 Inception 模块同样使用了三个卷积层，对应的卷积核大小分别为  $16 \times 1$ ， $8 \times 1$  和  $4 \times 1$ 。该模块可提取出所有导联更高抽象层次的时域特征。再将不同卷积的输出拼接，进行平均池化降低维度。

最后的两个卷积层用于提取特征中对于分类有用的模式，同时使用平均池化降低特征维度，最后全连接层加上 Softmax 进行分类输出。

#### 3.4.1 实验环境与评价指标

本节的实验环境和评价指标与 3.3.1 节一致，具体描述可参照 3.3.1 节。

3.4.2 实验结果与分析

使用 EEG-Inception 模型，优化算法为 Adam，学习率设置为 0.004，Batch Size 设置为 64。输入的数据格式为  $N \times 512$ ，其中  $N$  为通道数量，512 为单次实验脑电信号的时间采样点数量。分别使用数据集中 2 通道、4 通道、6 通道、8 通道信号进行训练，并在测试集中进行了 8 次预测实验，实验结果如表 3.2 所示，图 3.11 可视化展示了该结果。

表 3.2 EEG-Inception 在不同通道组合下的分类准确率

试验编号	2 通道	4 通道	6 通道	8 通道
1	57.45%	69.05%	72.66%	71.45%
2	61.47%	71.51%	60.46%	65.56%
3	58.89%	64.30%	65.32%	60.52%
4	63.52%	59.13%	66.53%	68.93%
5	66.58%	73.25%	75.48%	63.04%
6	62.68%	60.15%	65.44%	60.75%
7	61.29%	71.09%	66.71%	73.01%
8	63.16%	65.26%	69.53%	66.64%
平均值	61.88%	66.72%	67.77%	66.24%




图 3.11 EEG-Inception 在不同通道组合下的分类准确率

从图 3.11 中可以看出 EEG-Inception 模型，在 2 通道、4 通道、6 通道、8 通道的情况下，平均的分类准确率分别为 61.88%、66.72%、67.77%、66.24%，都没有超过 70%。其中 6 通道下的分类效果最好。单次试验中，2 通道、4 通道、6 通道、8 通道的最高分类准确率分别为 66.58%、73.25%、75.48%、73.01%。总体上看，EEG-Inception 模型的分类效果也不理想。通过对比 3.3 节中 EEGNet 模型的分类结果，EEGNet 在 8 通道的情况下，分类效果最佳，平均准确率达到 72.86%，单次最高准确率为 80.11%。发现 EEGNet 模型的分类性能比 EEG-Inception 模型更好。EEG-Inception 模型相对 EEGNet 模型更加复杂，采用 Inception 结构，即多个并行的卷积层

和池化层组成的模块，因此模型的参数数量较多。当模型过于复杂时，容易学习到训练数据中噪声的特征，而不是对数据整体进行建模，从而导致分类性能不佳。可以通过减少分支数量或采用更轻量级的网络结构来减少参数数量来提高分类性能。综上分析，想要取得较高的分类准确率，用于脑电信号分类的模型不能过于复杂，也不能过于简单。模型参数数量要适中，才能更好地学习到整体数据的特征，从而达到理想的分类效果。

### 3.5 基于 CNN-Net 的运动想象 EEG 分类研究

根据上文对 EEGNet 和 EEG-Inception 这两种卷积神经网络分类模型的试验结果分析，为了取得更好的分类效果。本文设计了一个基于卷积神经网络的分类模型 (CNN-Net)。网络模型各层参数如表 3.3 所示，结构如图 3.12 所示。此模型共有 9 层 (L1-L9)，以下为各层网络结构：

表 3.3 CNN-Net 网络模型的具体参数

层数	类型	特征尺寸	核尺寸	步长	填充
L1	输入	(512, N, 1)			
L2	卷积	(512, N, 8)	(3, 3)	(1, 1)	Same
L3	卷积	(512, N, 8)	(3, 3)	(1, 1)	Same
L4	卷积	(512, N, 16)	(3, 3)	(1, 1)	Same
	最大池化	(86, N, 16)	(6, 1)	(6, 1)	Same
L5	卷积	(86, N, 16)	(3, 3)	(1, 1)	Same
L6	卷积	(86, N, 32)	(3, 3)	(1, 1)	Same
	最大池化	(15, N, 32)	(6, 1)	(6, 1)	Same
L7	全局平均池化	32			
L8	全连接	2			
L9	输出	2			

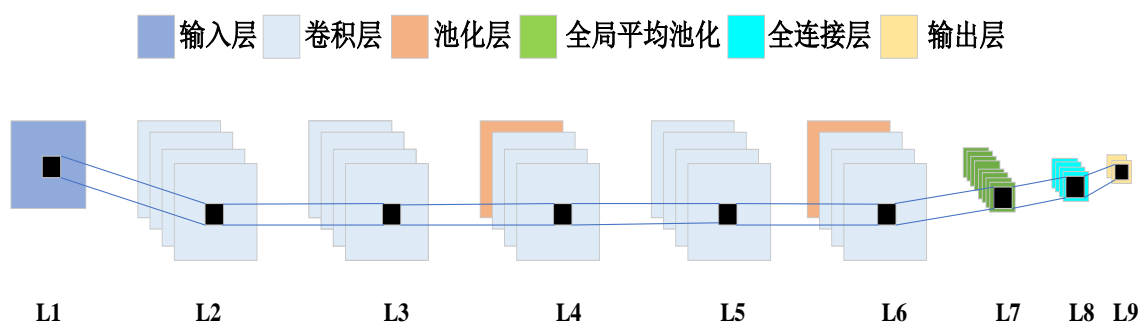


图 3.12 CNN-Net 网络结构

(1) L1: 输入层，将运动想象脑电信号数据输入网络，数据格式为脑电信号的时

间采样点数量×电极通道数量的二维数组，并传递给下层网络。

(2) L2: 卷积层，包含 8 个卷积核，卷积核尺寸为  $3\times 3$ ，用于提取输入层数据的特征，步长为  $1\times 1$ ，激活函数为 Tanh，填充方式为 Same。

(3) L3: 卷积层，包含 8 个卷积核，卷积核尺寸为  $3\times 3$ ，步长设置为  $1\times 1$ ，激活函数为 Tanh，填充方式为 Same。

(4) L4: 卷积层，包含 16 个卷积核，卷积核尺寸为  $3\times 3$ ，步长设置为  $1\times 1$ ，激活函数为 Tanh，填充方式为 Same。并经过一个大小为  $6\times 1$  的最大池化层，步长设置为  $6\times 1$ ，提取脑电信号在时域上的主要特征。最后添加了一个失活率为 50% 的 Dropout 层，防止出现过拟合。

(5) L5: 卷积层，包含 16 个卷积核，卷积核尺寸为  $3\times 3$ ，步长为  $1\times 1$ ，激活函数为 Tanh，填充方式为 Same。

(6) L6: 卷积层，包含 32 个卷积核大小为  $3\times 3$  的卷积滤波器，步长为  $1\times 1$ ，激活函数为 Tanh，填充方式为 Same。并经过一个大小为  $6\times 1$  的最大池化层，步长设置为  $6\times 1$ ，提取脑电信号在时域上的主要特征。最后添加了一个失活率为 50% 的 Dropout 层，避免出现拟合。

(7) L7: 全局平均池化层，减小特征图的空间大小，并且可以减少模型中参数的数量，从而避免过拟合。并且可以对某些不重要的细节进行平均化处理，从而使模型对输入数据更具有鲁棒性。

(8) L8: 全连接层，连接前一层的所有特征，并进行进一步加权计算。

(9) L9: 输出层，使用 Softmax 函数对脑电信号进行分类，输出分类结果。

### 3.5.1 实验环境与评价指标

本节的实验环境和评价指标与 3.3.1 节一致，具体描述可参照 3.3.1 节。

### 3.5.2 网络模型最优参数

模型参数取值不同，模型的分类效果也会相差很大。要选取模型的最优参数，就必须进行大量实验。为了验证 CNN-Net 对脑电信号分类的有效性，本节构建基于卷积神经网络的分类模型，进行了相关实验对模型的参数进行优化。本节使用 2 通道(FC3-FC4)信号作为输入数据，输入的数据格式为  $512\times 2$ ，其中 512 为单次实验脑电信号的时间采样点数量，其中 2 为通道数量。选取最优参数的过程需要固定除变量外的参数，并对变量进行合理的调控。最优参数的选取是通过局部最优的组合，从而选出全局最优，具体实验结果在下文会详细说明。

#### (1) 学习率

学习率是训练模型中一个重要的参数，学习率过高会导致模型在局部极小值附近震荡难以收敛，也容易出现梯度爆炸现象。学习率设置太低会导致权值更新过慢，容易陷入局部最优解，甚至导致梯度消失而无法收敛。因此设置一个合适的学

习率有利于模型收敛。为了找到最优的学习率，本次试验的模型固定 5 层卷积层，且卷积核大小为  $3 \times 3$  的情况下，采用 Adam 优化算法在 5 种不同的学习率的情况下进行测试分析，选择准确率(Accuracy)、精度(Precision)、和召回率(Recall)以及 F1-score 作为评价指标。实验结果如表 3.4 所示。

表 3.4 不同学习率的分类结果

学习率	评价指标			
	Accuracy	Precision	Recall	F1-score
0.01	81.61%	81.71%	81.79%	81.60%
0.001	84.31%	84.41%	84.48%	84.31%
0.004	86.18%	86.06%	86.44%	86.11%
0.008	85.45%	85.51%	85.48%	85.46%
0.0001	64.01%	64.15%	64.28%	63.95%

从表 3.4 中可以看出，学习率设置为 0.0001 时，分类准确率偏低，因为模型梯度更新过慢，陷入了局部最优。随着学习率的增加，分类的准确率呈现出先上升再下降的趋势。当学习率设置为 0.004 时，各项评价指标都是最佳的，因此设置学习率初始值为 0.004。

## (2) Batch Size

Batch Size 在神经网络的训练过程中是一个很重要的参数。当 Batch Size 过小时，所需的训练时间长，还可能导致梯度震荡，不利于模型收敛；当 Batch Size 过大时，梯度下降的方向可能会变得更加不稳定，导致训练过程变得不稳定，同时较大的 Batch Size 需要更长的时间来处理，因此训练速度也会变慢。因此选取一个合适的 Batch Size 有助于模型取得较好的泛化能力。为了找到最优的 Batch Size，所以对本节的模型在固定参数的情况下，采用 5 种不同的 Batch Size 进行试验分析，分别比较各项评价指标，实验结果如表 3.5 所示。

表 3.5 不同 Batch Size 的分类结果

Batch Size	评价指标			
	Accuracy	Precision	Recall	F1-score
16	85.09%	85.03%	85.10%	85.06%
32	85.16%	85.19%	85.22%	85.15%
64	86.12%	86.21%	86.23%	86.12%
128	84.85%	84.83%	84.88%	84.84%
256	85.45%	85.51%	85.61%	85.45%

表 3.5 显示了不同 Batch Size 情况下模型的评价指标。将 Batch Size 都设置为 2 的指数次幂，范围为[16, 256]。可以看出，当 Batch Size 设为 64 时，模型的各项评价指标最高，因此，本文选择 Batch Size 的大小为 64。



### (3) 卷积层数量

深度学习的过程中，主要通过卷积层对输入数据提取特征，卷积层的计算原理：根据卷积核的尺寸，在输入数据上使用与卷积核尺寸相同的矩阵逐块进行计算，提取数据的特征。卷积层的数量需要合适的设置，过多或者过少都会造成相应的问题。卷积层过多会增加模型的计算参数，使模型变得更复杂，降低模型的训练效率，容易出现梯度消失、梯度爆炸、陷入局部最优等问题，卷积层过少可能会导致，模型根本没有学习到数据特征或者特征学习不全面等问题。在本文设计的 CNN-Net 模型的基础上，通过添加和减少卷积层数量，采用 3 到 7 层卷积层进行试验分析，分别比较各项评价指标，实验结果如表 3.6 所示。

表 3.6 不同卷积层数量的分类结果

卷积层数量	评价指标			
	Accuracy	Precision	Recall	F1-score
3	80.94%	80.99%	81.03%	80.94%
4	84.31%	84.35%	84.38%	84.31%
5	86.22%	86.26%	86.31%	86.22%
6	86.59%	86.64%	86.68%	86.59%
7	84.13%	84.02%	84.75%	84.03%

从表 3.6 中可以看出，当卷积层数从 3 层上升到 6 层的时候，对于分类精度效果提升，当卷积层数量上升到 7 层时，分类效果反而下降了，卷积层越多意味模型更复杂，计算量的增加，因此在准确率相差不大的情况下，网络模型尽可能的简单，所以本文选择卷积层数为 5 层。

### (4) 卷积核尺寸

卷积核的尺寸和感受野成正相关，感受野越大，卷积后可以获取数据更多特征，可以提升模型的分类效果，但是增加卷积核尺寸的同时，计算量也在提升，所以针对本文设计的 CNN-Net，分别比较各项评价指标，确定最佳的卷积核尺寸，实验结果如表 3.7 所示。

表 3.7 不同卷积核尺寸的分类结果

卷积核尺寸	评价指标			
	Accuracy	Precision	Recall	F1-score
2×2	75.06%	75.08%	75.09%	75.05%
3×3	87.54%	87.62%	87.92%	87.51%
4×4	87.74%	87.87%	88.63%	87.69%
5×5	87.92%	87.77%	87.79%	87.73%

从表 3.7 可以看出，当卷积核尺寸超过 3×3 时，继续增加卷积核的尺寸，模型的分类准确率提升程度很小。卷积核的作用是提取数据的特征，增加卷积核尺寸的同

时感受野也得到提升，也意味着计算量的增加，会降低模型的计算效率。因此在准确率相差不大的情况下，为了提升网络效率，网络模型尽可能简单，降低训练参数量，所以本文选择卷积核的尺寸为  $3 \times 3$ 。

### 3.5.3 对比实验

#### (1) 最佳参数验证

在 3.5.2 节选择最佳参数的情况下构建模型，为了验证本文构建 CNN-Net 模型的有效性，并研究通道数量对分类准确率的影响。使用了确定的最优网络模型参数，分别使用数据集中 2 通道、4 通道、6 通道、8 通道信号进行训练，并在测试集中进行了 8 次预测实验，实验结果如表 3.8 所示，图 3.13 可视化展示了该结果。

表 3.8 CNN-Net 在不同通道组合下的分类准确率

试验编号	2 通道	4 通道	6 通道	8 通道
1	<b>87.59%</b>	95.22%	94.92%	94.22%
2	84.10%	93.77%	90.18%	94.02%
3	86.80%	95.52%	95.12%	94.19%
4	86.06%	93.90%	94.21%	90.46%
5	86.48%	94.90%	<b>96.49%</b>	92.08%
6	86.51%	95.81%	93.72%	91.41%
7	85.14%	<b>95.85%</b>	95.91%	92.05%
8	85.66%	94.29%	94.67%	<b>94.35%</b>
平均值	86.04%	94.90%	94.40%	92.85%




图 3.13 CNN-Net 在不同通道组合下的分类准确率

从图 3.13 中可以看出 CNN-Net 模型在 3.5.2 节中确定的最优参数下，取得的较好的效果。在 2 通道、4 通道、6 通道、8 通道的情况下，平均的分类准确率分别为 86.04%、94.90%、94.40%、92.85%，单次最高准确率分别为 87.59%、95.85%、

96.49%、94.35%。其中 2 通道下的平均分类准确率最低，在 2 通道的基础上增加到 4 通道、6 通道、8 通道，分类准确率都得到了一定的提升，整体呈现出先上升后下降的趋势，其中 4 通道下的平均准确率最高，达到 94.90%，6 通道分类的平均准确率其次，达到 94.40%。因为当分类性能较低时，通道信号增加意味着更多的学习数据，能让模型学习到更多脑电信号的特征，所以分类准确率得到了提升。但是随着通道数量的持续增加，脑电数据包含的噪声信号也更多，模型难以分辨出有效特征，从而降低了模型的分类性能。

## (2) 通道有效性验证

当前大多数研究运动想象脑电信号的分类研究都是选择 C3 和 C4 通道的脑电信号进行研究<sup>[68]</sup>，为了验证本文通道选择的有效性和合理性。使用了 3.5.2 节中确定的最优网络模型参数，在数据集中使用 C3-C4 通道信号进行训练，并在测试集中进行了 8 次预测实验。得到的分类结果与 3.5.3 节(1)的实验结果对比，得到的对比结果如表 3.9 所示，图 3.14 可视化的展示了该结果。

表 3.9 CNN-Net 在 C3-C4 通道信号下的分类准确率

试验编号	1	2	3	4	5	6	7	8
准确率	83.17%	84.79%	81.43%	87.09%	85.28%	82.99%	85.61%	83.75%




图 3.14 CNN-Net 在不同通道组合下的分类准确率

从表3.9可以计算出在使用数据集中 C3、C4两个通道信号训练的情况下，8次测试的平均分类准确率为84.26%。从图3.14可以看出本文的四种通道组合分类的平均准确率均高于 C3-C4通道分类的平均准确率，结果表明本文选择的通道组合对运动想象脑电信号分类是有效的。

## 3.6 实验结果与分析

### 3.6.1 对比分析

本节将对本章使用的三种模型 EEGNet、EEG-Inception 和 CNN-Net 的分类性能

进行讨论,表 3.10 列举了 EEGNet、EEG-Inception 和 CNN-Net 模型,在四种不同通道组合下的平均分类准确率,图 3.15 可视化展示了该结果。

表 3.10 不同模型的分类准确率

网络模型	2 通道	4 通道	6 通道	8 通道
EEGNet	57.79%	63.35%	67.39%	72.86%
EEG-Inception	61.88%	66.72%	67.77%	66.24%
CNN-Net	86.04%	94.90%	94.40%	92.85%




图 3.15 不同模型分类结果的对比

图 3.15 表示 EEGNet、EEG-Inception 和 CNN-Net 在 4 种通道组合情况下分类的平均准确率,可以看出本章设计的 CNN-Net 模型的分类准确率在 2 通道、4 通道、6 通道和 8 通道四种通道组合下的均优于 EEG-Inception 和 EEGNet,效果最好。EEGNet 和 EEG-Inception 取得的最佳平均分类准确率分别为 72.86%、67.77%。CNN-Net 模型最佳的平均分类准确率为 94.90%,相比于 EEGNet 和 EEG-Inception 的准确率分别提升了 22.04%、27.13%,取得了较为理想的分类效果。虽然 EEGNet 在 2 通道、4 通道和 6 通道的分类性能都低于 EEG-Inception,但是 EEGNet 在 8 通道下的分类准确率相比于 EEG-Inception 高 6.62%,EEGNet 网络模型是一种紧凑型网络,模型比较简单,包含的参数数量较少,但是 EEG-Inception 网络模型相对来说较为复杂,包含的参数也较多,EEG-Inception 的参数数量比 EEGNet 高出一个数量级。考虑到实际的应用情况,在准确率相差不大的情况下,应当优先选用 EEGNet。CNN-Net 在 4 种通道组合情况下都取得了良好的效果。其中 CNN-Net 在 4 通道的情况下,分类平均准确率最高为 94.90%,6 通道的情况下,分类的平均准确率也达到 94.40%,2 通道的情况下平均分类准确率也比 EEGNet 和 EEG-Inception 的最佳情况下的平均分类准确率高。综上分析,相比 EEGNet、EEG-Inception 模型 CNN-Net 模型的分类性能得到了提升,证明了 CNN-Net 模型的有效性。

### 3.6.2 综合对比分析

为了进一步验证 CNN-Net 模型的有效性, 选取 CNN-Net 四种通道组合中最佳组合的平均分类准确率和使用同一数据集进行分类研究的参考文献进行对比。Kumar 等人<sup>[69]</sup>提出了一种基于优化 CSP 和 LSTM 的分类预测器, 取得了 68.19% 的分类准确率。Yu 等人<sup>[70]</sup>通过 welch-PSD 特征和多层感知器(Multilayer Perceptron, MLP)分类器相结合, 表明改进的经验傅立叶分解(Improved Empirical Fourier Decomposition, IEFD)机制产生了稳健的分类结果。Sadiq 等人<sup>[71]</sup>通过使用变分模态分解(Variational Mode Decomposition, VMD)、线性回归(Linear Regression, LR)获得的多域特征和级联前向神经网络(Cascade Feedforward Neural Network, CFNN)组合进行分类研究。Greear 等人<sup>[72]</sup>采用数据降维(Dimension Reduction, DR)构建特征, 再使用 SVM 进行分类, 相比于 Sadiq 等人取得了更好的分类性能。通过对比不同方法的分类结果, 得到了表 3.11, 图 3.16 可视化了该结果。

表 3.11 不同算法的平均准确率对比

文献	分类方法	准确率
Kumar <sup>[69]</sup> (2019)	CSP + LSTM	68.19%
Yu <sup>[70]</sup> (2021)	welch-PSD + MLP + IEFD	83.84%
Sadiq <sup>[71]</sup> (2021)	VMD + LR + CFNN	85.02%
Greear <sup>[72]</sup> (2021)	DR + SVM	92.60%
本文	CNN-Net	94.90%




图 3.16 不同算法的平均准确率对比

从图 3.16 中看出, 相比于参考文献的分类方法, 本章设计的基于 CNN-Net 模型的分类方法取得了更好的分类效果, 进一步证明了基于 CNN-Net 模型分类方法的有效性。基于 CNN-Net 模型的分类方法相比于使用 CSP+LSTM、welch-PSD+MLP+IEFD、VMD+LR+CFNN、DR+SVM 的分类方法, 准确率分别提升了 26.71%、11.06%、9.88%、2.30%。因为这四种方法在对脑电信号分类之前, 都对脑

电信号进行了特征提取，再对提取的特征进行分类，可能会造成脑电信号中关键特征的丢失，从而导致分类性能下降。而 CNN-Net 融合了特征提取和分类功能，实现了端到端的学习，所以分类效果更好。综上所述，CNN-Net 相比于上述的四种分类方法，避免了复杂的特征提取过程，简化了分类识别的流程，并有效地提升了分类精度。

### 3.7 本章小结

本章首先介绍了本文使用的数据集以及数据预处理的步骤。使用 EEGNet、EEG-Inception 两种常用于脑电信号分类的模型和本文提出的 CNN-Net 模型，在四种通道组合的情况下，进行了两类手运动想象的分类研究。通过对比实验结果，以及查阅使用同一数据集进行分类研究的有关文献，发现 CNN-Net 取得了更好的分类效果，并验证了 CNN-Net 模型的有效性。

## 第4章 融合注意力机制的 CNN-Net 的运动想象 EEG 分类研究

### 4.1 引言

由于 EEG 信号的复杂性，加大了提取有效特征的难度，存在识别准确率低和网络泛化能力差的问题。深度学习中的注意力机制是受到人类视觉系统的视觉注意力机制启发而诞生的，让神经网络可以专注于感受野的某个特定部分，被广泛应用于图像处理、自然语言处理以及语音识别等领域<sup>[73-75]</sup>。注意力机制的原理就是在网络的学习过程中挑选更有效的信息进行重点处理，并把不重要的或者无效的信息忽略，从而解决训练过程中训练参数超载的情况<sup>[76,77]</sup>。本章将针对第三章构建的 CNN-Net 模型分别与 SENet、ECA、CBAM 注意力机制相结合，用于运动想象脑电信号的分类研究中，探索注意力机制对 CNN-Net 模型分类性能的影响，旨在得到更好的分类效果。实验流程如图 4.1 所示。

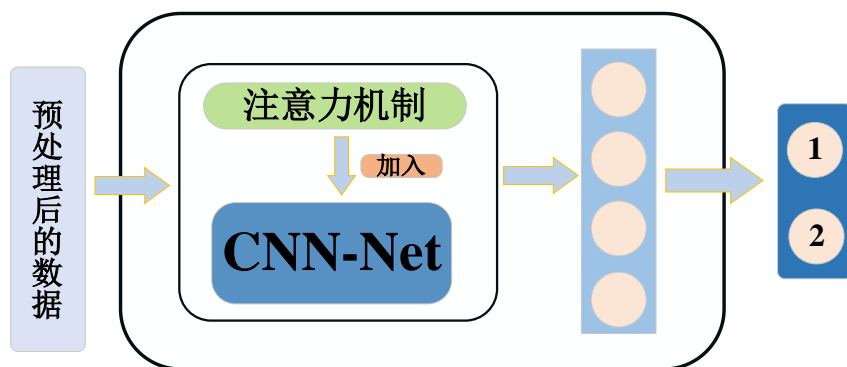


图 4.1 融合注意力机制的 CNN-Net 模型分类流程

### 4.2 注意力机制种类

#### 4.2.1 SENet 注意力机制

SENet(Squeeze-and-Excitation Network)注意力机制主要关注信号的通道特征。其实现原理为：通过自学习捕获每个通道特征对于原始信号的贡献，再根据每个通道对于原始信号的贡献程度来提升重要特征并抑制不重要甚至没用的特征，也被称为“特征重标定”原理。SENet 模块的具体组成如图 4.2 所示。




图 4.2 SENet 模型结构

假设输入的特征图  $X$ ，其特征通道数为  $C_1$ ，通过一系列卷积等一般变换  $F_{tr}$  后得到一个特征通道数为  $C_2$  的特征。与传统的卷积神经网络不同，需要通过下面三个操作来重标定前面得到的特征。

1、首先对输入的特征图进行 Squeeze 操作，在空间维度上对特征图进行压缩，通道中的所有空间特征被整合为一个具有全局的感受野的特征，并且输入特征图和输出特征图的通道数量是一致的，通常采用全局平均池化来达到这种效果。

2、在得到全局特征之后，通过 Excitation 操作来获取通道之间的相关性，和循环神经网络中门机制相似。主要通过两个全连接层：通过第一个全连接层降低特征图的维度，通过第二个全连接层让输入特征图和原始特征图的维度保持一致。进行 Excitation 操作之后就可以为每个特征通道生成相应的权重，即各个通道学习到的激活值。

3、Excitation 操作之后输出的权重的大小代表每个特征通道重要程度，再进行 Scale 操作，顺着输入特征图通道使用乘法依次加权到之前的特征，在通道维度上实现了原始特征的重定位，从而使得模型能够对各个通道的特征有区分度。

#### 4.2.2 ECA 注意力机制

ECA(Efficient Channel Attention)注意力机制是在 SENet 的基础上改进的，由于 SENet 在学习过程中会获取所有通道的相关性，所以 SENet 可能对网络的预测带来副作用。考虑到卷积操作在获取跨通道信息的过程中具有良好的效果。ECA 模块应用了卷积操作，ECA 模块的原理是：首先去除了 SENet 模块中的全连接层，对于在全局平均池化(Global Average Pooling, GAP)之后生成的特征图通过一维卷积核学习。ECA 模块的具体组成如图 4.3 所示。ECA 模型的流程如下：

1、假设输入的原始特征图  $X$  的维度为  $H \times W \times C$ ；通过使用全局平均池化对原始特征图  $X$  进行空间特征压缩，得到  $1 \times 1 \times C$  的特征图；

2、压缩后的空间特征在尺寸大小为  $1 \times 1$  的卷积核学习之后，得到的  $1 \times 1 \times C$  的通道注意力特征图；

3、最后使用通道注意力特征图和原始特征图，沿着通道依次相乘，输出具有通道注意力的特征图。




图 4.3 ECA 模型结构



### 4.2.3 CBAM 注意力机制

卷积注意力模块(Convolution Block Attention Module, CBAM)将通道注意力模块(Channel Attention Module, CAM)和空间注意力模块(Spatial Attention Module, SAM)归于同一模型下, 兼顾了信号在通道和空间的特征, 能更好地学习到信号的特征。其模型结构如图 4.4 所示, 对于输入进来的特征图, CBAM 会对特征图同时施加通道注意力和空间注意力的权重。假设输入的特征图  $F \in \mathbb{R}^{C \times H \times W}$ , CBAM 处理的过程中, 会产生通道注意力特征图  $M_C \in \mathbb{R}^{C \times 1 \times 1}$  和空间特征图  $M_S \in \mathbb{R}^{1 \times H \times W}$ , 特征图  $F$  与通道注意力特征图  $M_C$  按位相乘输出特征图  $F'$ ,  $F'$  与空间特征图  $M_S$  按位相乘输出特征图  $F''$  作为最后的输出。注意力学习的流程可以总结为式(4.1)和式(4.2)。

$$F' = M_C(F) \otimes F \quad (4.1)$$

$$F'' = M_S(F') \otimes F' \quad (4.2)$$

其中,  $\otimes$  表示按位相乘。

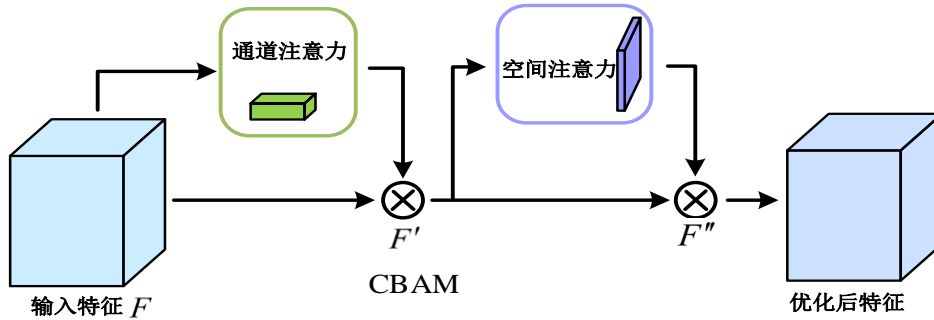


图 4.4 CBAM 模型结构

通道注意力机制在学习的过程中主要关注数据集的通道特征。为了得到空间上下文的两种不同描述:  $F_{avg}^c$  和  $F_{max}^c$ 。对输入的特征图  $F$  分别使用最大池化和平均池化。对于在空间维度上进行压缩获取的特征图  $F_{max}^c$  和特征图  $F_{avg}^c$ , 再通过一个带有隐藏层的多层感知器组成的共享网络对两种特征图计算, 最后计算出通道注意力特征图:  $M_C \in \mathbb{R}^{C \times 1 \times 1}$ 。通道注意力的完整过程如图 4.5 所示。




图 4.5 通道注意力模型结构

通道注意力的计算原理如式(4.3)和式(4.4)所示:

$$M_C(F) = \sigma(\text{MLP}(\text{AvgPool}(F)) + \text{MLP}(\text{MaxPool}(F))) \quad (4.3)$$

$$M_C(F) = \sigma(W_1(W_0(F_{avg}^c)) + W_1(W_0(F_{max}^c))) \quad (4.4)$$

其中,  $W_0$  和  $W_1$  是 MLP 的权重。

空间注意力机制在学习过程中主要关注数据集的空间特征。对通道维度的特征图进行最大池化，得到特征图 $(F')_{max}^s$ ，对通道维度的特征图进行平均池化，得到特征图 $(F')_{avg}^s$ ，将 $(F')_{max}^s$ 和 $(F')_{avg}^s$ 两个特征图进行叠加，再通过卷积调整通道数量并生成空间注意力特征图 $M_s(F')$ 。空间注意力模型结构如图 4.6 所示。




图 4.6 空间注意力模型结构

空间注意力模块的计算原理如式(4.5)和式(4.6)所示：

$$M_s(F') = \sigma(f^{7 \times 7}([\text{AvgPool}(F'); \text{MaxPool}(F')])) \quad (4.5)$$

$$M_s(F') = \sigma(f^{7 \times 7}([(F')_{avg}^s; (F')_{max}^s])) \quad (4.6)$$

其中， $f^{7 \times 7}$ 表示卷积操作的滤波器大小为  $7 \times 7$ 。

### 4.3 融合注意力机制的 CNN-Net 的运动想象 EEG 分类对比实验

传统的 EEG 信号分类效果往往受制于通道信号的选择，传统方法包括选择部分通道信号和全部通道信号。可能将与运动想象相关性不强甚至无关的通道信号输入到网络中，由于通道信号之间对运动想象的贡献没有侧重性，可能会造成与运动想象相关特征的丢失和与运动想象无关特征的冗余，从而降低了运动想象脑电信号的分类效果。注意力机制的本质是在网络的学习过程中对特征施加一组权重，实现网络对特征的关注具有差异性，强化重要特征的同时弱化无用特征，让网络专注于学习更重要的特征，理论上可以放在网络中任一特征层后<sup>[78,79]</sup>。

根据第三章的研究结果显示，CNN-Net 模型在使用 2 通道(FC3-FC4)信号情况下的分类准确率为 86.04%，4 通道(FC3-FC4、C1-C2)信号情况下的分类准确率为 94.90%，6 通道(FC3-FC4、C1-C2、CP1-CP2)信号情况下的分类准确率为 94.40%，8 通道(FC3-FC4、C1-C2、CP1-CP2、C3-C4)信号情况下的分类准确率为 92.85%。其中使用 4 通道信号分类的准确率最高，为 94.90%；6 通道信号的分类准确率其次，为 94.40%，二者准确率相差不大。为了探索注意力机制对 CNN-Net 模型分类性能的影响，本章选取使用 4 通道信号和 6 通道信号这两种最好的情况，探究注意力机制对 CNN-Net 模型分类准确率的影响，以获得更好的分类效果。本章实验中将 CNN-Net 模型分别 SENet、ECA、CBAM 注意力机制相融合，针对 CNN-Net 模型相同位置添加不同注意力机制以及同一注意力机制添加到 CNN-Net 模型的不同位置，测试融合

注意力机制的 CNN-Net 模型的性能,使用分类准确率作为评价指标,旨在获得更好的分类效果。将不同的注意力机制加入到 CNN-Net 的主干网络(L2 到 L6 之间),加入情况为  $L_m$ 、 $L_n$  时,表示注意力机制加入在 CNN-Net 模型的第  $L_m$  和  $L_n$  层之间;加入情况为  $L_m$  时,表示注意力机制加入在 CNN-Net 模型的第  $L_m$  层的卷积层和池化层之间。

#### 4.3.1 实验环境与评价指标

##### (1) 实验环境

硬件环境:处理器为英特尔 Core i7-10700,内存为 32GB,显卡为英伟达 GeForce RTX 3060,显存为 16GB,固态硬盘容量为 1.5TB。

软件环境:操作系统为 Ubuntu 16.04 64 位,开发环境为 Tensorflow 2.4,编程语言为 Python 3.6,编辑器为 PyCharm 2020。

训练策略:使用 Adam 优化算法,学习率设置为 0.004, Batch Size 设置为 64。

##### (2) 评价指标

对于本章中的分类模型而言,使用准确率(Accuracy)来衡量模型的性能,描述如式(4.7)所示:

$$Accuracy = \frac{\sum_{i=1}^N TP_i}{\sum_{i=1}^N (TP_i + FP_i)} = \frac{\sum_{i=1}^N TP_i}{\sum_{i=1}^N (TP_i + FN_i)} \quad (4.7)$$

其中  $N$  表示分类的类别总数,  $TP$  表示真阳性数,  $TP_i$  表示实际为  $i$  类的样本被预测为  $i$  类的数;  $FP$  表示假阳性数,  $FP_i$  表示实际为  $i$  类的样本被误判为除  $i$  类外的类别的样本数;  $FN$  表示假阴性数,  $FN_i$  表示实际为其它类别的样本被误判为  $i$  类的样本数,  $\sum_{i=1}^N (TP_i + FP_i)$  和  $\sum_{i=1}^N (TP_i + FN_i)$  表示数据集中样本的总数。

#### 4.3.2 融合 SENet 的 CNN-Net 的运动想象 EEG 分类研究

本节研究在使用 4 通道(FC3-FC4、C1-C2)信号和 6 通道(FC3-FC4、C1-C2、CP1-CP2)信号的情况下,将 SENet 加入到 CNN-Net 模型中不同位置,探索 SENet 对 CNN-Net 模型分类性能的影响,模型结构如图 4.7 所示。

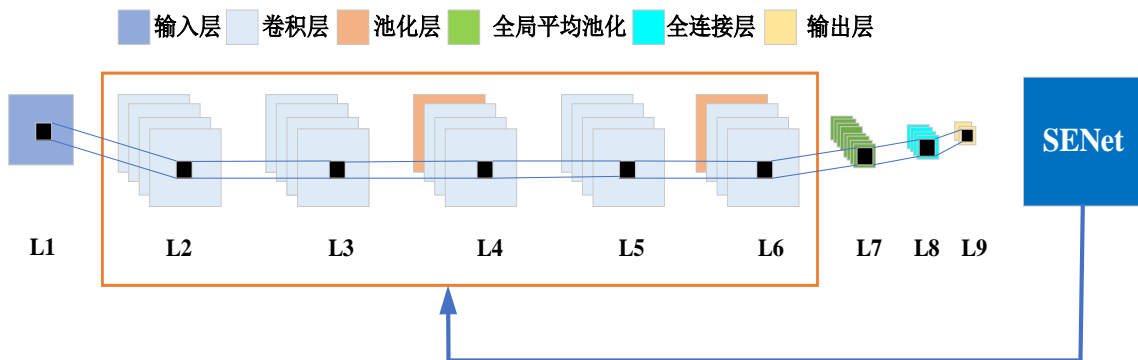


图 4.7 融合 SENet 的 CNN-Net 模型结构

## (1) 4 通道下 SENet 的融合研究

将 SENet 加入到 CNN-Net 模型中不同位置, 使用数据集中 4 通道信号进行训练, 并分别在测试集中进行了 8 次预测试验, 得到了表 4.1 所示的实验结果。表中变化值表示平均值减去 94.90%(3.5.3 节中 CNN-Net 使用 4 通道信号分类的平均准确率)的差值, 图 4.8 可视化展示了表 4.1。

表 4.1 4 通道下 SENet 加入 CNN-Net 模型不同位置的分类准确率

试验编号	加入位置					
	L2、L3	L3、L4	L4	L4、L5	L5、L6	L6
1	94.83%	95.85%	95.49 %	97.29%	95.13%	89.60%
2	96.33%	94.29%	95.97 %	95.85%	95.16%	95.37%
3	94.83%	92.91%	95.13%	94.95%	95.61%	47.84%
4	93.88%	94.95%	93.99%	95.37%	96.27%	89.32%
5	90.86%	95.67%	95.97%	95.73%	95.13%	93.87%
6	94.23%	92.84 %	96.51%	95.61%	94.17%	92.66%
7	95.26%	94.95%	95.37%	95.37%	94.77%	48.92%
8	93.78%	95.62%	95.78%	96.15%	95.68%	92.42%
平均值	94.25%	94.64%	95.53%	95.79%	95.24%	81.25%
变化值	-0.65%	-0.26%	0.63%	0.89%	0.34%	-13.65%




图 4.8 4 通道下 SENet 加入 CNN-Net 模型不同位置的平均准确率和准确率变化

图 4.8 显示 SENet 加入到网络 L4 的卷积层和池化层之间、L4 与 L5 之间和 L5 与 L6 之间, 分类的平均准确率都得到了提升。其中 SENet 加入到网络 L4 和 L5 之间, 分类的平均准确率提升 0.89%, 达到 95.79%, 分类效果最好。当 SENet 加入到网络的 L2 与 L3 之间、L3 与 L4 之间、L6 的卷积层和池化层之间, 分类的平均准确率都出现了下降的情况。当 SENet 添加到网络的 L6 的卷积层和池化层之间时, 有两次分类准确率都没有超过 50%, 平均分类准确率下降了 13.65%, 分类效果最差。综合分析, 发现 SENet 加入到网络的中间层能提升 CNN-Net 模型的分类性能, SENet 加

入到网络的浅层和深层会降低 CNN-Net 模型的分类性能。

## (2) 6 通道下 SENet 的融合研究

将 SENet 加入到 CNN-Net 模型中不同位置, 使用数据集中 6 通道信号进行训练, 并分别在测试集中进行了 8 次预测试验, 得到了表 4.2 所示的实验结果。表中变化值表示平均值减去 94.40%(3.5.3 节中 CNN-Net 使用 6 通道信号分类的平均准确率)的差值, 图 4.9 可视化展示了表 4.2。

表 4.2 6 通道下 SENet 加入 CNN-Net 模型不同位置的分类准确率

试验编号	加入位置					
	L2、L3	L3、L4	L4	L4、L5	L5、L6	L6
1	94.83%	94.15%	93.99%	95.36%	92.62%	94.65%
2	90.62%	94.97%	95.49%	94.67%	94.53%	94.53%
3	94.95%	95.67%	94.71%	95.52%	91.26%	50.13%
4	92.31%	95.19%	95.43%	94.56%	95.34%	95.25%
5	95.55%	94.54%	95.19%	93.75%	94.35%	49.87%
6	93.93%	94.53%	95.25%	95.58%	93.76%	95.26%
7	92.56%	93.65%	93.39%	94.16%	95.62%	92.14%
8	94.18%	95.16%	94.17%	94.97%	94.56%	90.15%
平均值	93.62%	94.73%	94.70%	94.82%	94.01%	82.75%
变化值	-0.78%	0.33%	0.30%	0.42%	-0.39%	-11.65%




图 4.9 6 通道下 SENet 加入 CNN-Net 模型不同位置的平均准确率和准确率变化

图 4.9 显示 SENet 加入到网络的 L3 与 L4 之间、L4 的卷积层和池化层之间、L4 与 L5 之间, 分类的平均准确率都得到了提升。其中 SENet 加入到网络的 L4 和 L5 之间, 分类的平均准确率提升 0.42%, 达到 94.82%, 分类效果最好。当 SENet 加入到网络的 L2 与 L3 之间和 L5 与 L6 之间和 L6 的卷积层和池化层之间, 分类的平均准确率都出现了下降的情况, 当 SENet 添加到网络的 L6 的卷积层和池化层之间时, 有两

次试验的准确率都是 50%左右, 平均分类准确率下降了 11.65%, 分类效果最差。综上分析, 发现 SENet 加入到网络的中间层能提升 CNN-Net 模型的性能, SENet 加入到网络的浅层和深层会降低 CNN-Net 模型的性能。

### 4.3.3 融合 ECA 的 CNN-Net 的运动想象 EEG 分类研究

本节研究在使用 4 通道(FC3-FC4、C1-C2)信号和 6 通道(FC3-FC4、C1-C2、CP1-CP2)信号的情况下, 将 ECA 加入到 CNN-Net 模型中不同位置, 探索 ECA 对 CNN-Net 模型分类性能的影响, 模型结构如图 4.10 所示。

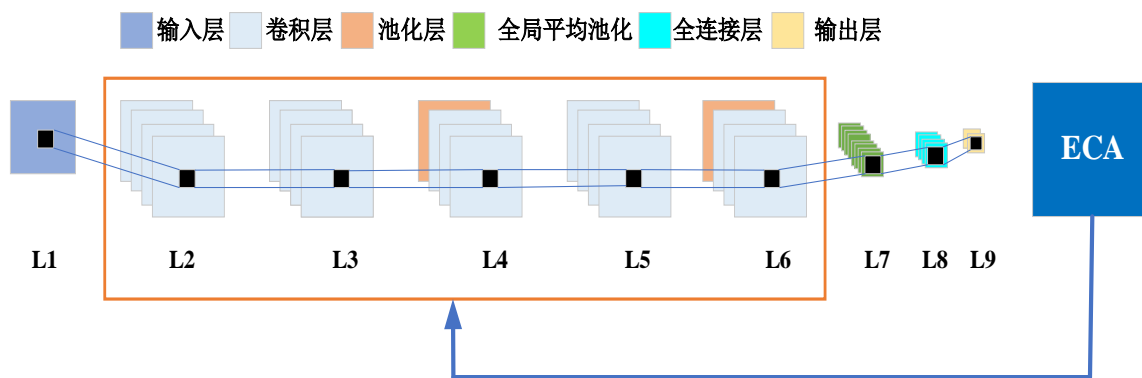


图 4.10 融合 ECA 的 CNN-Net 模型结构

#### (1) 4 通道下 ECA 的融合研究

将 ECA 加入到 CNN-Net 模型中不同位置, 使用数据集中 4 通道信号进行训练, 并分别在测试集中进行了 8 次预测试验, 得到了表 4.3 所示的实验结果。表中变化值表示平均值减去 94.90%(3.5.3 节中 CNN-Net 使用 4 通道信号分类的平均准确率)的差值, 图 4.11 可视化展示了表 4.3。

表 4.3 4 通道下 ECA 加入 CNN-Net 模型不同位置的分类准确率

试验编号	加入位置					
	L2、L3	L3、L4	L4	L4、L5	L5、L6	L6
1	93.99%	94.53%	95.31%	95.37%	94.17%	95.49%
2	93.14%	93.15%	96.15%	95.13%	95.43%	94.11%
3	94.01%	94.71%	95.25%	96.09%	96.93%	96.09%
4	94.71%	95.07%	95.79%	96.94%	95.67%	95.79%
5	94.11%	94.05%	95.13%	95.25%	95.43%	49.06%
6	94.59%	95.01%	94.89%	95.25%	95.79%	94.47%
7	96.09%	93.93%	94.71%	94.65%	93.93%	96.03%
8	95.26%	95.16%	95.67%	95.13%	96.8%	95.54%
平均值	94.49%	94.45%	95.36%	95.48%	95.52%	89.57%
变化值	-0.41%	-0.45%	0.46%	0.58%	0.62%	-5.33%




图 4.11 4 通道下 ECA 加入 CNN-Net 模型不同位置的平均准确率和准确率变化

图 4.11 显示 ECA 加入到网络 L4 的卷积层和池化层之间、L4 与 L5 之间、L5 与 L6 之间，分类的平均准确率都得到了提升。其中 ECA 加入到网络的 L5 和 L6 之间，分类的平均准确率提升了 0.62%，达到 95.52%，分类效果最好。当 ECA 加入网络 L2 与 L3 之间、L3 与 L4 之间、L6 卷积层和池化层之间，分类的平均准确率都下降了。当 ECA 添加到网络的 L6 的卷积层和池化层之间时，有一次试验的准确率都没有超过 50%，平均分类准确率下降了 5.33%，分类效果最差。综上分析，发现 ECA 加入到网络的中间层能相比于加入网络和浅层和深层取得了更好的分类效果。

## (2) 6 通道下 ECA 的融合研究

将 ECA 加入到 CNN-Net 模型中不同位置，使用数据集中 6 通道信号进行训练，并分别在测试集中进行了 8 次预测试验，得到了表 4.4 所示的实验结果。表中变化值表示平均值减去 94.40%(3.5.3 节中 CNN-Net 使用 6 通道信号分类的平均准确率)的差值，图 4.12 可视化展示了表 4.4。

表 4.4 6 通道下 ECA 加入 CNN-Net 模型不同位置的分类准确率

试验编号	加入位置					
	L2、L3	L3、L4	L4	L4、L5	L5、L6	L6
1	94.77%	93.81%	93.99%	92.31%	94.35%	95.49%
2	92.54%	92.96%	93.75%	94.11%	94.51%	94.13%
3	94.17%	94.47%	95.25%	93.93%	95.07%	93.21%
4	90.44%	92.48%	95.13%	95.07%	94.41%	93.33%
5	93.93%	91.11%	93.93%	95.79%	95.73%	95.32%
6	93.87%	95.07%	96.39%	95.55%	95.76%	94.95%
7	91.04%	88.83%	94.34%	94.60%	95.79%	95.13%
8	93.56%	95.07%	95.61%	95.07%	96.21%	93.26%
平均值	93.04%	92.98%	94.80%	94.55%	95.23%	94.35%
变化值	-1.36%	-1.42%	0.40%	0.15%	0.83%	-0.05%






图 4.12 6 通道下 ECA 加入 CNN-Net 模型不同位置的平均准确率和准确率变化

图 4.12 显示 ECA 加入到网络 L4 的卷积层和池化层之间、L4 和 L5 之间、L5 和 L6 之间，分类的平均准确率都得到了提升。其中 ECA 加到网络的 L5 和 L6 之间，分类的平均准确率提升了 0.83%，达到 95.23%，分类效果最好。当 ECA 加入到网络 L2 与 L3 之间、L3 与 L4 之间、L6 的卷积层和池化层之间，分类的平均准确率都出现了下降的情况。当 ECA 添加到网络的 L3 与 L4 之间，平均分类准确率下降了 1.42%，分类效果最差。综上分析，发现 ECA 加入到网络的中间层能相比于加入网络和浅层和深层取得了更好的分类效果。

#### 4.3.4 融合 CBAM 的 CNN-Net 的运动想象 EEG 分类研究

本节研究在使用 4 通道(FC3-FC4、C1-C2)信号和 6 通道(FC3-FC4、C1-C2、CP1-CP2)信号的情况下，将 CBAM 加入到 CNN-Net 模型中不同位置，探索 CBAM 对 CNN-Net 模型分类性能的影响，模型结构如图 4.13 所示。

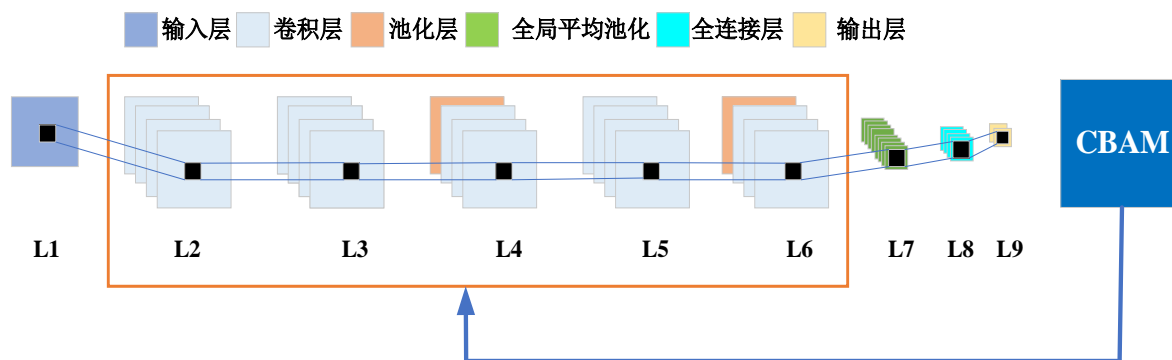


图 4.13 融合 CBAM 的 CNN-Net 模型结构

##### (1) 4 通道下 CBAM 的融合研究

将 CBAM 加入到 CNN-Net 模型中不同位置，使用数据集中 4 通道信号进行训练，并分别在测试集中进行了 8 次预测试验，得到了表 4.5 所示的实验结果。表中变化值表示平均值减去 94.90%(3.5.3 节中 CNN-Net 使用 4 通道信号分类的平均准确率)的差值，图 4.14 可视化展示了表 4.5。



表 4.5 4 通道下 CBAM 加入 CNN-Net 模型不同位置的分类准确率

试验编号	加入位置					
	L2、L3	L3、L4	L4	L4、L5	L5、L6	L6
1	95.01%	95.62%	95.73%	95.91%	94.05%	94.77%
2	93.87%	94.35%	95.91%	93.14%	93.93%	93.81%
3	95.25%	93.84%	94.61%	96.15%	94.17%	94.59%
4	92.49%	94.65%	95.72%	94.46%	93.57%	88.52%
5	93.87%	93.17%	96.49%	94.54%	93.93%	93.62%
6	92.97%	95.64%	94.59%	96.39%	94.95%	47.58%
7	94.83%	92.61%	92.84%	94.83%	95.91%	92.67%
8	94.56%	94.11%	94.65%	94.51%	95.64%	95.07%
平均值	94.11%	94.25%	95.07%	94.99%	94.52%	87.58%
变化值	-0.79%	-0.65%	0.17%	0.09%	-0.38%	-7.32%




图 4.14 4 通道下 CBAM 加入 CNN-Net 模型不同位置的平均准确率和准确率变化

图 4.14 显示 CBAM 加入到网络 L4 的卷积层和池化层之间、L4 和 L5 之间，分类准确率都得到了提升。其中 CBAM 加到网络 L4 的卷积层和池化层之间，分类的准确率提升了 0.17%，达到 95.07%，分类效果最好。当 CBAM 加入到网络 L2 与 L3 之间、L3 与 L4 之间、L2 与 L3 之间、L6 的卷积层和池化层之间，分类的准确率都出现了下降，当 CBAM 添加到网络的 L6 的卷积层和池化层之间，分类准确率下降了 7.32%，分类效果最差。综上分析，发现 CBAM 加入到网络的中间层能提升 CNN-Net 模型的分类性能，但是提升程度很小，最高只有 0.17%，CBAM 加入到网络的浅层和深层会降低 CNN-Net 模型的分类性能。

## (2) 6 通道下 CBAM 的融合研究

将 CBAM 加入到 CNN-Net 网络中不同位置，使用数据集中 6 通道信号进行训练，并分别在测试集中进行了 8 次预测试验，得到了表 4.6 所示的实验结果。表中变

化值表示平均值减去 94.40%(3.5.3 节中 CNN-Net 使用 6 通道信号分类的平均准确率)的差值, 图 4.15 可视化展示了表 4.6。

表 4.6 6 通道下 CBAM 加入 CNN-Net 模型不同位置的分类准确率

试验编号	加入位置					
	L2、L3	L3、L4	L4	L4、L5	L5、L6	L6
1	91.10%	96.27%	93.52%	94.8%	95.19%	49.28%
2	89.78%	95.01%	95.73%	90.86%	92.61%	95.79%
3	94.29%	93.45%	94.56%	94.56%	89.24%	95.06%
4	95.43%	93.45%	94.92%	95.61%	94.65%	92.73%
5	93.08%	94.71%	93.03%	95.34%	95.67%	94.95%
6	95.37%	96.51%	94.47%	94.13%	94.65%	94.05%
7	92.96%	91.76%	95.93%	95.14%	90.44%	50.17%
8	93.03%	93.68%	93.69%	96.05%	94.83%	95.12%
平均值	93.13%	94.36%	94.48%	94.56%	93.41%	83.39%
变化值	-1.27%	-0.04%	0.08%	0.16%	-0.99%	-11.01%




图 4.15 6 通道下 CBAM 加入 CNN-Net 模型不同位置的平均准确率和准确率变化

图 4.15 显示 CBAM 加入到网络 L4 的卷积层和池化层之间、L4 和 L5 之间, 分类的平均准确率都得到了提升。其中 ECA 加到网络的 L4 和 L5 之间, 分类的平均准确率提升了 0.16%, 达到 94.56%。当 CBAM 加入到网络 L2 与 L3 之间、L3 与 L4 之间、L5 与 L6 之间、L6 的卷积层和池化层之间, 分类的平均准确率都出现了下降, 当 CBAM 添加到网络的 L6 的卷积层和池化层之间, 平均分类准确率下降了 11.01%, 分类效果最差。综上分析, 发现 CBAM 加入到网络的中间层能提升 CNN-Net 模型的性能, 但是提升的准确率程度很小, 最高只有 0.16%, CBAM 加入到网络的浅层和深层会降低 CNN-Net 模型的性能。

## 4.4 实验结果与分析

### 4.4.1 对比分析

通过 4.3 节的试验可以得出在使用 4 通道、6 通道信号情况下, CNN-Net 不同位置加入 SENet、ECA、CBAM 注意力机制进行分类测试的平均准确率, 实验结果如表 4.7 所示, 图 4.16 可视化展示了该结果。

表 4.7 不同情况下融合注意机制的 CNN-Net 模型分类的平均准确率

加入位置	4 通道			6 通道		
	SENet	ECA	CBAM	SENet	ECA	CBAM
L2、L3	94.25%	94.49%	94.11%	93.62%	93.04%	93.13%
L3、L4	94.64%	94.45%	94.25%	94.73%	92.98%	94.36%
L4	95.53%	95.36%	<b>95.07%</b>	94.70%	94.80%	94.48%
L4、L5	<b>95.79%</b>	95.48%	94.99%	<b>94.82%</b>	94.55%	<b>94.56%</b>
L5、L6	95.24%	<b>95.52%</b>	94.52%	94.01%	<b>95.23%</b>	93.41%
L6	81.25%	89.57%	87.58%	82.75%	94.35%	83.39%




图 4.16 不同情况下融合注意机制的 CNN-Net 模型分类的平均准确率

从图 4.16 中可以看出在 4 通道下, SENet、ECA、CBAM 加入到 CNN-Net 网络中取得的最佳的平均分类准确率分别为 95.79%、95.52%、95.07, 都提升了 CNN-Net 的分类性能。其中 SENet 的效果最好, 分类准确率提升了 0.89%; ECA 的效果其次, 分类准确率提升了 0.62%; CBAM 的效果相对较差, 分类性能只提升了 0.17%。在 6 通道下, SENet、ECA、CBAM 加入到 CNN-Net 网络中取得的最佳的平均分类准确率分别为 94.82%、95.23%、94.56, 都提升了 CNN-Net 的分类性能。其中 ECA 的效果最好, 分类准确率提升了 0.83%; SENet 的效果其次, 分类准确率提升了 0.42%; CBAM 的效果相对较差, 分类性能只提升了 0.16%。图 4.16 中也能看出, 注意力机制加入到 CNN-Net 中不同位置会对分类性能造成不同的影响, 注意力机制添加到网络的中间层取得分类效果更好, 加入到网络的浅层和深层的分类效果会变差。在接

下来的 4.4.2 节，通过消融实验探究注意力机制加入到 CNN-Net 中不同位置对分类性能的影响。

#### 4.4.2 消融实验

通过 4.3 节的试验可以得出在使用 4 通道、6 通道信号情况下，CNN-Net 不同位置加入 SENet、ECA、CBAM 注意力机制相比于 CNN-Net 分类准确率的变化，即每个注意力机制在不同引入方式下对 CNN-Net 模型分类性能的贡献程度。得到了如表 4.8 所示的结果，图 4.17 可视化展示了该结果。

表 4.8 不同情况下融合注意机制的 CNN-Net 模型分类准确率的变化

加入位置	4 通道			6 通道		
	SENet	ECA	CBAM	SENet	ECA	CBAM
L2、L3	-0.65%	-0.41%	-0.79%	-0.78%	-1.36%	-1.27%
L3、L4	-0.26%	-0.45%	-0.65%	0.33%	-1.42%	-0.04%
L4	0.62%	0.46%	<b>0.17%</b>	0.30%	0.40%	0.08%
L4、L5	<b>0.89%</b>	0.58%	0.09%	<b>0.42%</b>	0.15%	<b>0.16%</b>
L5、L6	0.34%	<b>0.62%</b>	-0.38%	-0.39%	<b>0.83%</b>	-0.99%
L6	-13.65%	-5.33%	-7.32%	-11.65%	-0.05%	-11.01%

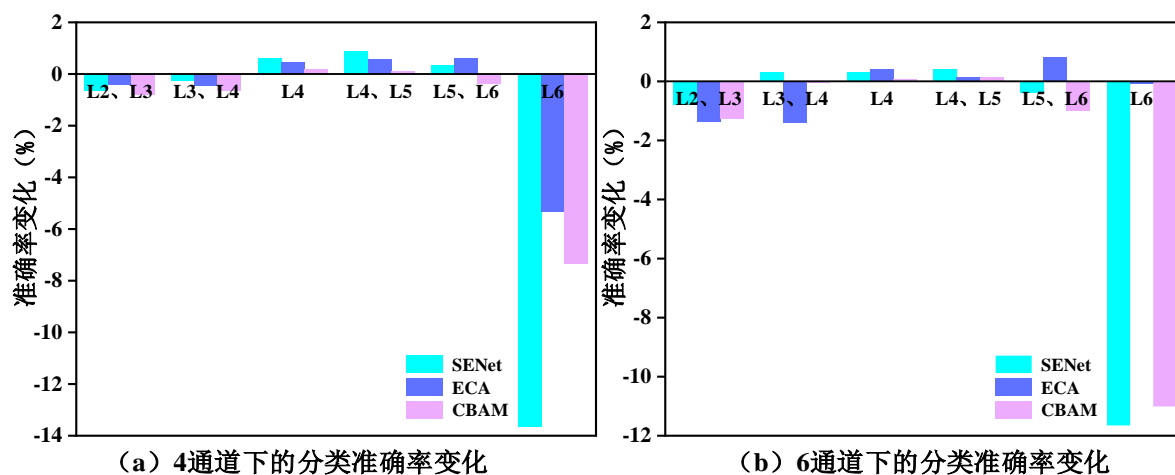


图 4.17 不同情况下融合注意机制的 CNN-Net 模型分类准确率的变化

从图 4.17 中可以看出注意力机制加入到 CNN-Net 的中间层能提升分类性能，加入到 CNN-Net 的浅层和深层会降低模型的性能。4 通道的情况下，SENet 加入位置为 L4、L5 时，对模型的性能提升最佳，准确率提升了 0.89%；ECA 加入位置为 L5、L6 时，对模型的性能提升最佳，准确率提升了 0.62%；CBAM 加入位置为 L4 时，对模型的性能提升最佳，准确率提升了 0.17%。6 通道的情况下，SENet 加入位置为 L4、L5 时，对模型的性能提升最佳，准确率提升了 0.42%；ECA 加入位置为 L5、L6 时，对模型的性能提升最佳，准确率提升了 0.83%；CBAM 加入位置为 L4 时，对模型的性能提升最佳，准确率提升了 0.16%。可以

看出注意力机制提升 CNN-Net 的分类性能，加入到 CNN-Net 都是网络的中间层。其中加入位置为 L4 和 L4、L5 时，SENet、ECA、CBAM 对模型的分分类都起到了提升的作用。当加入到网络的浅层和深层时，都降低了模型的分分类性能。当加入位置为 L6 时，降低模型分分类性能的情况最严重。4 通道下 SENet、ECA、CBAM 降低了模型的分分类准确率为 13.65%、5.33%、7.32%；6 通道下 SENet、ECA、CBAM 降低了模型的分分类准确率为 11.65%、0.10%、11.01%。

注意力机制的原理是训练过程中强化有用特征弱化无用特征，但也存在注意力强化无用特征弱化有用特征的情况，因此可能造成模型性能的下降。当注意力机制加入到模型的中间层，能够帮助模型更好地捕捉输入序列中的局部关系和上下文信息，使模型更加准确地理解输入序列中的重要信息，并在执行下游任务时更好地利用这些信息；并且在处理长序列时，将注意力机制添加到网络中间层可以帮助网络更好地捕捉序列中的关键信息，从而提升模型的分分类性能。当注意力机制加入到模型的浅层时，关注的特征往往比较简单，注意力机制可能无法有效地从输入数据中提取数据集的整体特征，从而造成了分分类性能的下降。当注意力机制加入到模型的深层时，通常需要计算和存储大量的注意力分数，这会增加模型的计算成本和内存使用量；还会增加模型的学习难度，难以分辨出有效特征，出现梯度消失或者梯度爆炸的情况，从而降低了模型的分分类性能。综上分析，注意力机制加入到网络的中间层能比加入到网络的浅层和深层取得更好分分类效果。

#### 4.4.3 综合对比分析

本章分别将 SENet、ECA、CBAM 融合到 CNN-Net 模型中，取得了相比于 CNN-Net 模型更好的分分类性能。为了进一步验证本章方法的有效性，选取本章融合不同注意力机制的 CNN-Net 分分类方法最佳引入情况下的平均分分类准确率与 3.6.2 章节中使用相同公开数据集的四种现有分分类方法和第三章设计的基于 CNN-Net 模型的分分类方法作比较。得到不同方法的对比结果，如表 4.9 所示，图 4.18 可视化展示了该结果。

表 4.9 不同算法的平均准确率对比

文献	分分类方法	准确率
Kumar <sup>[69]</sup> (2019)	CSP + LSTM	68.19%
Yu <sup>[70]</sup> (2021)	welch-PSD + MLP + IEFD	83.84%
Sadiq <sup>[71]</sup> (2021)	VMD + LR + CFNN	85.02%
Greear <sup>[72]</sup> (2021)	DR + SVM	92.60%
本文	CNN-Net	94.90%
本文	CNN-Net + CBAM	95.07%
本文	CNN-Net + ECA	95.52%
本文	CNN-Net + SENet	<b>95.79%</b>




图 4.18 不同算法的平均准确率对比

从图 4.18 中可以看出,融合注意力机制的 CNN-Net 模型的分类准确率相比于 CNN-Net 模型都得到了提升。其中融合 CBAM、ECA、SENet 的 CNN-Net 模型相比于第三章提出的 CNN-Net 模型分类准确率分别提升了 0.17%、0.62%、0.89%。证明了利用注意力机制和 CNN-Net 融合的方式能更好地提取到运动想象脑电信号的特征。融合 CBAM 的 CNN-Net 模型分类准确率相比于参考的四种分类方法的准确率分别提升了 26.88%、11.23%、10.05%、2.47%。融合 ECA 的 CNN-Net 模型分类准确率相比于参考的四种分类方法的准确率分别提升了 27.33%、11.68%、10.50%、2.92%。融合 SENet 的 CNN-Net 模型分类准确率相比于参考的四种分类方法的准确率分别提升了 27.60%、11.95%、10.77%、3.19%。综上分析,融合注意力机制的 CNN-Net 模型避免了复杂的特征提取过程,并有效地提升了分类精度,进一步验证了融合注意力机制的 CNN-Net 模型的有效性。其中融合 SENet 的 CNN-Net 模型取得了最佳的分类效果,准确率达到 95.79%。

## 4.5 本章小结

本章的研究主要融合注意力机制的 CNN-Net 的运动想象 EEG 分类,针对第三章提出的 CNN-Net,研究了注意力机制对网络模型分类性能的影响。通过改变注意力机制的种类以及注意力机制的添加位置,进行了一系列的对比实验,对实验结果的分析,发现注意力机制添加到网络的中间层相比于添加到网络的浅层和深层能取得更好的分类效果。并对比了现有的使用同一数据集的分类方法,得出本章融合注意力机制的 CNN-Net 模型在一定程度上提升了运动想象脑电信号的分类精度,分类性能优于大部分现有的研究方法,进一步验证了融合注意力机制的 CNN-Net 模型的有效性。

## 第5章 总结与展望

### 5.1 总结

近些年,在计算机技术迅猛发展的推动下,脑机接口研究技术也得到了极大的提升。运动想象脑机接口实现了一种全新的人机交互方式,得到了广泛的研究。利用运动想象过程中脑皮表层的脑电信号节律能量改变来解码大脑发出的运动信号,进而达到控制辅助设备的效果。脑机接口系统实现的关键在于如何精确解析运动想象脑电信号,而以往的脑电分析方法需要一定的先验知识,需要对脑电信号进行较为复杂的特征提取过程。基于深度学习方法强大的自学习能力,为了探索深度学习方法识别运动想象脑电信号的可行性,本文探索将深度学习方法应用于脑电信号分类任务中。本文的主要研究内容概括如下:

(1) 为了让深度学习网络训练的数据包含尽可能少的噪声和伪迹,对本文的数据集进行了相关的预处理。首先根据运动想象 EEG 的频率范围,对原始数据集进行 8Hz-30Hz 的带通滤波处理;为了去除噪声和伪迹的干扰,分别使用了重参考和独立成分分析;最后为了减小模型的训练参数,对数据进行了时间切分、降采样和通道选择,构建了运动想象脑电信号数据集。

(2) 使用 EEGNet、EEG-Inception 两种常用于脑电信号分类的模型和本文提出的 CNN-Net 模型在四种通道组合的情况下,进行了对比实验。通过对比实验结果,发现 CNN-Net 模型的分类性能优于 EEGNet 和 EEG-Inception,并通过对比现有的分类方法,进一步验证了 CNN-Net 模型的有效性。CNN-Net 模型在使用 4 通道(FC3-FC4、C1-C2)信号分类的平均准确率最高,为 94.90%,6 通道(FC3-FC4、C1-C2、CP1-CP2)信号分类的平均准确率其次,为 94.40%,取得了不错的分类效果。CNN-Net 模型同时具备特征提取和分类的功能,对 EEG 信号的处理进行了有效简化,避免了复杂的特征提取过程,在分类性能上优于现有的大部分方法,使其更容易被应用于实际应用场景中。

(3) 基于运动想象脑电信号在时域和空域方面的特征,本文将 SENet、ECA、CBAM 注意力机制分别融合到 CNN-Net 模型中,进行运动想象脑电信号的分类研究。选取了使用 4 通道信号和 6 通道信号这两种最好的分类情况,主要针对不同注意力机制以及注意力机制加入模型的位置进行了探究。通过分析实验结果,发现注意力机制加入网络模型的中间层更能提升模型的分类性能,加入网络模型的浅层和深层会降低模型的性能。不同注意力机制在最佳的引入方式下,分类准确率相比于 CNN-Net 模型都得到了提升。其中融合 SENet 的 CNN-Net 的模型取得了最佳的

类效果，平均准确率达到 95.79%，其分类性能优于现存的大部分方法，并避免了复杂的特征提取过程。本文的研究为运动想象脑电信号的分类研究提供了新的参考。

## 5.2 展望

本文主要研究了深度学习方法在运动想象脑电信号分类中的应用，虽然模型在脑电信号分类任务中表现出较为理想的效果，但受到时间及水平的限制，还存在着许多不足之处，值得未来的研究进一步探讨和完善。基于本文的工作，对未来的研究提出几点展望：

(1) 本文的研究是基于运动想象脑电的二分类任务。并且当前大多数研究也是二分类任务和四分类任务。在实际应用中，需要分析处理更多的分类任务，分类准确率是重要的评价指标，深度学习模型的构建以及优化还需要进行更深入的研究。

(2) 本文使用的是公开数据集，脑电信号是基于同一范式下采集的，可能不具有普遍性。在未来的研究中，可以自主采集多个范式下的脑电数据作为实验数据，并且需要采集不同人群的脑电数据，实现实验数据的多样性，从而更好地应用于实际中。

(3) 完整的 BCI 系统。理论技术的研究的目的是应用于生活当中，因此在后续的研究中，可以设计一套完整的脑电信号采集系统、脑电信号预处理系统以及脑电信号分类系统，再根据系统检测的结果生成相应指令，应用于生活当中的实际场景。



## 参考文献

- [1] Jedelman B, Johnson N, Sohrabpour A, et al. Systems neuroengineering: understanding and interacting with the brain[J]. Engineering, 2015, 1(3): 292-308.
- [2] 谭立忠, 吴勤, 张丽平. 脑科学技术发展与应用[M]. 北京: 中国宇航出版社, 2018: 1-5.
- [3] Iturrate I, Antelis J M, Kubler A, et al. A Noninvasive Brain-Actuated Wheelchair Based on a P300 Neurophysiological Protocol and Automated Navigation[J]. IEEE Transactions on Robotics, 2009, 25(3): 614-627.
- [4] Lin K, Cinetto A, Wang Y, et al. An online hybrid BCI system based on SSVEP and EMG[J]. Journal of Neural Engineering, 2016, 13(2): 026020.
- [5] Edelman B J, Meng J, Gulachek N, et al. Exploring cognitive flexibility with a noninvasive BCI using simultaneous steady-state visual evoked potentials and sensorimotor rhythms[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2018, 26(5): 936-947.
- [6] He B, Yuan H, Meng J, et al. Brain-computer interfaces[M]. Neural engineering. Cham, Switzerland: Springer, 2020: 131-183.
- [7] Sadiq M T, Yu X, Yuan Z, et al. Motor Imagery EEG Signals Decoding by Multivariate Empirical Wavelet Transform Based Framework for Robust Brain-Computer Interfaces[J]. IEEE Access, 2019, 7: 171431-171451.
- [8] TK M J, Sanjay M. Topography Based Classification for Motor Imagery BCI Using Transfer Learning[C]. 2021 International Conference on Communication, Control and Information Sciences (ICCISc). Idukki, India: IEEE, 2021, 1: 1-5.
- [9] Attallah O, Abougharbia J, Tamazin M, et al. A BCI system based on motor imagery for assisting people with motor deficiencies in the limbs[J]. Brain sciences, 2020, 10(11): 864.
- [10] Serrhini M, Dargham A. Toward incorporating bio-signals in online education case of assessing student attention with BCI[M]. Europe and MENA cooperation advances in information and communication technologies. Cham, Switzerland: Springer, 2017, 520: 135-146.
- [11] Subramanian R R, Varma K Y, Balaji K, et al. Multiplayer online car racing with BCI In VR[C]. 2021 5th International Conference on Intelligent Computing and Control Systems (ICICCS). Madurai, India: IEEE, 2021: 1835-1839.

- [12] Czech A. Brain-computer interface use to control military weapons and tools[C]. 2021 4th International Scientific Conference on Brain-Computer Interfaces (IC BCI). Cham, Switzerland: Springer, 2021, 1362: 196-204.
- [13] Craik A, He Y, Contreras-Vidal J L. Deep learning for electroencephalogram (EEG) classification tasks: a review[J]. Journal of Neural Engineering, 2019, 16(3): 031001.
- [14] Cai C. Research on Classification Algorithm of Self-Made Data Set of Motor Imagination EEG Based on Convolutional Network[J]. Artificial Intelligence and Robotics Research, 2021, 10 (01): 1-8.
- [15] Pfurtscheller G, Neuper C. EEG based brain computer communication[J]. The Neurophysiological Foundations of Mental and Motor Imagery, 2010: 203-212.
- [16] Wolpaw J R, McFarland D J. Control of a two-dimensional movement signal by a noninvasive brain-computer interface in humans[J]. Proceedings of the national academy of sciences, 2004, 101(51): 17849-17854.
- [17] Gomez-Rodriguez M, Peters J, Hill J, et al. Closing the sensorimotor loop: haptic feedback facilitates decoding of motor imagery[J]. Journal of neural engineering, 2011, 8(3): 036005.
- [18] 赵启斌, 张丽清, Cichocki A. 三维虚拟现实环境中基于 EEG 的异步 BCI 小车导航系统[J]. 科学通报, 2008, 53(23): 2888-2895.
- [19] Wang Y, Hong B, Gao X, et al, et al. Implementation of a Brain-Computer Interface Based on Three States of Motor Imagery[C]. 2007 29th Annual International Conference of the IEEE Engineering in Medicine and Biology Society. Lyon, France: IEEE, 2007: 5059-5062.
- [20] Li Y, Long J, Yu T, et al. An EEG-based BCI system for 2-D cursor control by combining Mu/Beta rhythm and P300 potential[J]. IEEE transactions on bio-medical engineering, 2010, 57(10): 2495-2505.
- [21] Long J, Li Y, Wang H, et al. A hybrid brain computer interface to control the direction and speed of a simulated or real wheelchair[J]. IEEE transactions on neural systems and rehabilitation engineering, 2012, 20(5): 720-729.
- [22] 徐宝国, 彭思, 宋爱国. 基于运动想象脑电的上肢康复机器人[J]. 机器人, 2011(03): 53-59.
- [23] Pawar D, Dhage S. Feature Extraction Methods for Electroencephalography based BrainComputer Interface: A Review[J]. IAENG International Journal of Computer Science, 2020, 47(3): 260-274.
- [24] Kousarrizi M R N, Ghanbari A R A, Teshnehlal M, et al. Feature extraction and classification of EEG signals using Wavelet transform, SVM and artificial neural

- networks for brain computer interfaces[C] 2009 international joint conference on bioinformatics, systems biology and intelligent computing. Shanghai, China: IEEE, 2009: 352-355.
- [25] Lin S, Guo S, Huang Z. Determining AR order for BCI based on motor imagery[C] International Conference on Biomedical Engineering & Informatics. Shenyang China: IEEE, 2015: 174-178.
- [26] Huang N E, Shen Z, Long S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis[J]. Proceedings Mathematical Physical & Engineering Sciences, 1998, 454(1971): 903-995.
- [27] Djamal E C, Abdullah M Y, Renaldi F. Brain computer interface game controlling using fast fourier transform and learning vector quantization[J]. Journal of Telecommunication, Electronic and Computer Engineering (JTEC), 2017, 9(2-5): 71-74.
- [28] Kumar S, Sharma R, Sharma A, et al. Decimation filter with common spatial pattern and fishers discriminant analysis for motor imagery classification[C]. 2016 International Joint Conference on Neural Networks (IJCNN). Vancouver, BC, Canada: IEEE, 2016: 2090-2095.
- [29] Park S-H, Lee S-G. Small sample setting and frequency band selection problem solving using subband regularized common spatial pattern[J]. IEEE Sensors Journal, 2017, 17(10): 2977-2983.
- [30] Pfurtscheller G, Neuper C, Guger C, et al. Current trends in Graz brain-computer interface(BCI) research[J]. IEEE Transactions on Rehabilitation Engineering, 2002, 8(2): 216-219.
- [31] 裴一飞, 杨淑娟. 运动想象脑电信号算法研究进展[J]. 北京生物医学工程, 2018, 37(02): 208-214.
- [32] Wang L, Xu G, Yang S, et al. Motor imagery BCI research based on sample entropy and SVM[C]. 2012 6th International Conference on Electromagnetic Field Problems and Applications. Dalian China: IEEE, 2012: 1-4.
- [33] Kim H S, Chang M H, Lee H J, et al. A comparison of classification performance among the various combinations of motor imagery tasks for brain-computer interface[C]. 2013 6th International IEEE/EMBS Conference on Neural Engineering (NER). San Diego, CA, USA: IEEE, 2013: 435-438.
- [34] Gupta S, Saini H. EEG features extraction using PCA plus LDA approach based on L1-norm for motor imaginary classification[C]. 2014 IEEE International Conference on Computational Intelligence and Computing Research. Coimbatore, India: IEEE, 2014: 1-5.

- [35] Tan P, Sa W, Yu L. Applying extreme learning machine to classification of EEG BCI[C]. 2016 IEEE International Conference on Cyber Technology in Automation, Control, and Intelligent Systems (CYBER). Chengdu, China: IEEE, 2016: 228-232.
- [36] Isa N E M, Amir A, Ilyas M Z, et al. The performance analysis of K-nearest neighbors (K-NN) algorithm for motor imagery classification based on EEG signal[C]. MATEC web of conferences. Arau, Perlis: EDP Sciences, 2017, 140: 01024.
- [37] Pinheiro O R, Alves L R G, Souza J R D. EEG signals classification: Motor imagery for driving an intelligent wheelchair[J]. IEEE Latin America Transactions, 2018, 16(1): 254-259.
- [38] Fu R, Tian Y, Bao T, et al. Improvement motor imagery EEG classification based on regularized linear discriminant analysis[J]. Journal of medical systems, 2019, 43(6): 1-13.
- [39] Shi M, Wang C, Li X, et al. EEG signal classification based on SVM with improved squirrel search algorithm[J]. Biomedical Engineering/Biomedizinische Technik, 2020, 66(2): 137-152.
- [40] Dose H, Møller J S, Iversen H K, et al. An end-to-end deep learning approach to MI-EEG signal classification for BCIs [J]. Expert Systems with Applications, 2018, 114: 532-542.
- [41] Lawhern V J, Solon A J, Waytowich N R, et al. EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces[J]. Journal of neural engineering, 2018, 15(5): 056013.
- [42] 胡章芳, 张力, 黄丽嘉等. 基于时频域的卷积神经网络运动想象脑电信号识别方法[J]. 计算机应用, 2019, 39(08): 2480-2483.
- [43] Amin S U, Alsulaiman M, Muhammad G, et al. Deep Learning for EEG motor imagery classification based on multi-layer CNNs feature fusion[J]. Future Generation computer systems, 2019, 101: 542-554.
- [44] Ingolfsson T M, Hersche M, Wang X, et al. Eeg-tcnnet: An accurate temporal convolutional network for embedded motor-imagery brain-machine interfaces[C] 2020 IEEE International Conference on Systems, Man, and Cybernetics (SMC). Toronto, ON, Canada: IEEE, 2020: 2958-2965.
- [45] Santamaria-Vazquez E, Martinez-Cagigal V, Vaquerizo-Villar F, et al. EEG-Inception: A Novel Deep Convolutional Neural Network for Assistive ERP-Based Brain-Computer Interfaces[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2020, 28(12): 2773-2782.
- [46] Musallam Y K, AlFassam N I, Muhammad G, et al. Electroencephalography-based

- motor imagery classification using temporal convolutional network fusion[J]. Biomedical Signal Processing and Control, 2021, 69: 102826.
- [47] Luo T, Zhou C, Chao F. Exploring spatial-frequency-sequential relationships for motor imagery classification with recurrent neural network[J]. BMC bioinformatics, 2018, 19(1): 1-18.
- [48] Zhang G, Davoodnia V, Sepas-Moghaddam A, et al. Classification of hand movements from EEG using a deep attention-based LSTM network[J]. IEEE Sensors Journal, 2019, 20(6): 3113-3122.
- [49] 王薇. 基于深度学习的脑电分类识别方法[D]. 南京: 南京邮电大学, 2020: 22-25.
- [50] Su Z, Xu X, Ding J, et al. Intelligent wheelchair control system based on BCI and the image display of EEG[C]. 2016 IEEE Advanced Information Management, Communicates, Electronic and Automation Control Conference (IMCEC). Xi'an, China: IEEE, 2016: 1350-1354.
- [51] Kai Keng Ang, Zheng Yang Chin, Haihong Zhang, et al. Filter Bank Common Spatial Pattern in Brain-Computer Interface[C]. 2008 IEEE International Joint Conference on Neural Networks. Hong Kong, China: IEEE, 2008: 2390-2397.
- [52] Meisel C, Bailey K A. Identifying signal-dependent information about the preictal state: A comparison across ECoG, EEG and EKG using deep learning[J]. EBioMedicine, 2019, 45: 422-431.
- [53] Rajashekhar U, Neelappa, K. Viswanath. Automated Artifact Removal in EEG Signals of BrainComputer Interface using Wavelets and ICA[J]. International Journal of Innovative Technology and Exploring Engineering (IJITEE), 2019, 8(12): 896-909.
- [54] Md.Asadur Rahman, Md.Foisal Hossain, Mazhar Hossain, et al. Employing PCA and t-statistical approach for feature extraction and classification of emotion from multichannel EEG signal[J]. Egyptian Informatics Journal, 2020, 21(1): 23-35.
- [55] 于淑月, 李想, 于功敬等. 脑机接口技术的发展与展望[J]. 计算机测与控制, 2019, 27(10): 5-12.
- [56] Ojha M K, Mukul M K. A Novel Approach Based on EMD to improve the Performance of SSVEP Based BCI System[J]. Wireless Personal Communications, 2021: 1-13.
- [57] Zhang Y, Brown K, Yu Y, et al. Nuclear condensates of p300 formed through the structured catalytic core can act as a storage pool of p300 with reduced HAT activity[J]. Nature Communications, 2021, 12(1): 4618.
- [58] Won K, Kwon M, Ahn M, et al. Selective Subject Pooling Strategy to Improve Model Generalization for a Motor Imagery BCI[J]. Sensors, 2021, 21(16): 5436.
- [59] 郭雅萍. 基于深度学习的运动想象脑电信号分类方法[D]. 南昌: 南昌大学, 2022: 12.

- [60] Neuper C, Wörtz M, Pfurtscheller G. ERD/ERS patterns reflecting sensorimotor activation and deactivation[J]. *Progress in Brain Research*, 2006, 159(1): 211-222.
- [61] Craik A, He Y, Contreras-Vidal J L. Deep learning for electroencephalogram (EEG) classification tasks: a review[J]. *Journal of neural engineering*, 2019, 16(3): 031001.
- [62] 李奇, 卢朝华. 基于卷积神经网络的 P300 电位检测及在脑机接口系统中的应用[J]. *吉林师范大学学报(自然科学版)*, 2018, 39(03): 116-122.
- [63] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. *Nature*, 1986, 323(6088): 533-536.
- [64] H. Cho, M. Ahn, S. Ahn, et al. EEG datasets for motor imagery brain-computer interface[J]. *Gigascience*, 2017, 6(7): 1-8.
- [65] Mirzaei S, Ghasemi P. EEG motor imagery classification using dynamic connectivity patterns and convolutional autoencoder[J]. *Biomedical Signal Processing and Control*, 2021, 68: 102584.
- [66] Belwafi K, Gannouni S, Aboalsamh H, et al. A dynamic and self-adaptive classification algorithm for motor imagery EEG signals[J]. *Journal of Neuroscience Methods*, 2019, 327: 108346.
- [67] Lun X, Yu Z, Chen T, et al. A Simplified CNN Classification Method for MI-EEG via the Electrode Pairs Signals[J]. *Frontiers in Human Neuroscience*, 2020, 14: 388.
- [68] Xu B, Zhang L, Song A, et al. Wavelet Transform Time-Frequency Image and Convolutional Network based Motor Imagery EEG Classification[J]. *IEEE Access*, 2018, 7: 6084-6093.
- [69] Kumar S, Sharma A, Tsunoda T. Brain wave classification using long short-term memory network based OPTICAL predictor[J]. *Scientific Reports*, 2019, 9(1): 1-13.
- [70] Yu X, Aziz M Z, Hou Y, et al. An Extended Computer Aided Diagnosis System for Robust BCI Applications[C]. 2021 IEEE 9th International Conference on Information, Communication and Networks. Xi'an, China: IEEE, 2021: 475-480.
- [71] Sadiq M T, Yu X, Yuan Z, et al. Toward the Development of Versatile Brain-Computer Interfaces[J]. *IEEE Transactions on Artificial Intelligence*, 2021, 2(4): 314-328.
- [72] Grear T, Jacobs D. Classifying EEG motor imagery signals using supervised projection pursuit for artefact removal[C]. 2021 IEEE International Conference on Systems, Man, and Cybernetics (SMC). Melbourne, Australia: IEEE, 2021: 2952-2958.
- [73] 朱张莉, 饶元, 吴渊等. 注意力机制在深度学习中的研究进展[J]. *中文信息学报*, 2019, 33(06): 1-11.
- [74] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. *计算机学报*, 2017, 40(6): 1229-1251.

- [75] 李宸严, 刘继. 基于注意力与 Bi-LSTM 混合算法的车企舆情情感分析[J]. 信息技术与网络安全, 2021, 40(1): 45-49.
- [76] Li D, Xu J, Wang J, et al. A Multi-Scale Fusion Convolutional Neural Network Based on Attention Mechanism for the Visualization Analysis of EEG Signals Decoding[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2020, 28(12): 2615-2626.
- [77] Xin Q, Hu S, Liu S, et al. An Attention-Based Wavelet Convolution Neural Network for Epilepsy EEG Classification[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2020, 30: 957-966.
- [78] Zhang R, Zhang N, Chen C, et al. Motor Imagery EEG Classification with Self-attention-based Convolutional Neural Network[C]. 2022 7th International Conference on Intelligent Informatics and Biomedical Science (ICIIBMS). Nara, Japan: IEEE, 2022: 195-199.
- [79] Liu S, Wang X, Zhao L, et al. 3DCANN: A Spatio-Temporal Convolution Attention Neural Network for EEG Emotion Recognition[J]. IEEE Journal of Biomedical and Health Informatics, 2022, 26(11): 5321-5331.